



Lukas Preitler, MSc (Econ.), B.A. (Econ.)

Unterrichtet unsere Schule Seximus?

**Eine Analyse der zugänglichen Unterrichtsliteratur für österreichische
Schulen mittels neuronalen Netzwerken**

BACHELOR THESIS

for the attainment of the degree of

Bachelor of Computer Science

submitted to

Graz University of Technology

Supervisor:

Assoc. Prof. Dipl.-Ing. Dr. Elisabeth Lex

Advisor:

Dipl.-Ing. Markus Reiter-Haas

Institute of Interactive Systems and Data Science

02. September 2022

EIDESSTATTLICHE ERKLÄRUNG

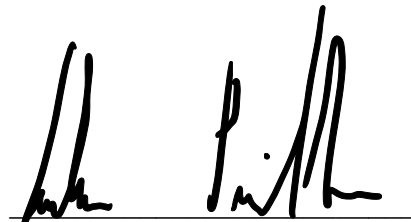
AFFIDAVIT

Ich erkläre an Eides statt, dass ich die vorliegende Arbeit selbstständig verfasst, andere als die angegebenen Quellen/Hilfsmittel nicht benutzt, und die den benutzten Quellen wörtlich und inhaltlich entnommenen Stellen als solche kenntlich gemacht habe. Das in TUGRAZonline hochgeladene Textdokument ist mit der vorliegenden Masterarbeit/Diplomarbeit/Dissertation identisch.

I declare that I have authored this thesis independently, that I have not used other than the declared sources/resources, and that I have explicitly indicated all material which has been quoted either literally or by content from the sources used. The text document uploaded to TUGRAZonline is identical to the present master's thesis/diploma thesis/doctoral dissertation.

02.09.2022

Datum / Date



Unterschrift / Signature

Abstract

This work investigates whether the teaching literature in Austrian schools has an unwanted gender bias, or rather they teach sexism.

To help clarify this question word embedding models are trained and calculated the cosine similarity for gender-related words like mother, wife, etc. and female first name against various professions and analyzed with Word Embedding Association Test (WEAT) on 16 different X-, Y-categories, which contains words which maybe carries a gender bias, called target words. The WEAT compares the similarity of both target word groups with both gender word groups.

As a new method, the first names are replaced by one female and one male name token in preprocessing. The idea is to prevent a selection bias for the first names when performing WEAT and similarity tests. However, this method is not a benchmark comparison to previous works on first name selections.

The work is limited to the accessible literature of two publishers in the educational in suspect German reduced.

The results are consistent with research by Geißler [20] on German-language children's literature. In the book series of both publishers, there are 2 or 4 of the 16 or 15 WEAT X-, Y-categories that have a statistically significant gender bias. In the case of the professions, one publisher has a male gender bias in 8 professions with a similarity greater than 0.17.

In summary: The author teams of the book series are coming close to the intention of the Ministry of Education, that both genders should be treated equal but still have some opportunities to improve their book series in the representation of gender, **but both book series are not likely to teach sexism.**

Zusammenfassung

Diese Arbeit geht der Frage nach, ob die Unterrichtsliteratur in Österreichs Schulen einen unerwünschten Genderbias aufweist, beziehungsweise ob sie Sexismus unterrichtet.

Um einen Beitrag zur Klärung dieser Frage zu leisten, werden Word-Embeddings-Modelle trainiert und mittels Ähnlichkeit-Kosinus für geschlechterbezogene Wörter (Mutter, Frau, etc., weiblicher Vorname) und verschiedenen Berufen errechnet und schließlich Analysen mit WEAT mit 16 verschiedenen X-, Y-Kategorien durchgeführt. Als neue Methode werden im Preprocessing die Vornamen durch weibliche und männliche Token ersetzt; dies soll einen Auswahl-Bias beim Erstellen der WEAT verhindern. Diese Methode wird jedoch keinen Benchmark Vergleich zu bisherigen Vornamen-Auswahlen unterzogen.

Die Arbeit ist leider auf die zugängliche Literatur von zwei Verlagen im Unterrichtsfach Deutsch reduziert.

Die Ergebnisse sind im Einklang mit der Forschung von Geißler [20] zur deutschsprachigen Kinderliteratur. In den Buchserien beider Verlage gibt es in 2 bzw. 4 der 16 bzw. 15 WEAT X-, Y-Kategorien einen statistisch signifikanten Genderbias und bei den Berufen ein Verlag bei 8 Berufe mit einem männlichen Genderbias größer als 0,17.

Zusammengefasst: Die Autor:innen-Teams der beiden Buchserien kommen Zielvorgaben bezüglich Gendersensibilität des Bildungsministeriums sehr nahe, weisen jedoch noch einige Baustellen zur Verbesserung ihrer Buchserien in der Darstellung von Gender auf, **aber zu einem sexistischen Unterricht tragen beide Buchserien wahrscheinlich nicht bei.**

Danksagungen

An dieser Stelle möchte ich mich bei allen bedanken, welche mich im Studium und beim Erstellen dieser Arbeit unterstützt haben.

Vielen Dank an Frau Professor Dr. DI Elisabeth Lex für die Betreuung meiner Bachelorarbeit und an DI Markus Reiter-Haas für die Unterstützung, immer wenn ich mich in einer falschen Idee verrannt habe.

Ohne die Bereitstellung der benötigten Schulliteratur wäre diese Arbeit nicht möglich, daher gilt mein Dank den beiden Verlagen, welche bereit waren, einige ihrer Bücher digital bereit zustelle.

Ein Dank gebührt auch meinem Arbeitgeber, der „Greenbox Studentenheimbetreiber GmbH“ und ihrem Geschäftsführer Stefan Hausberger, mit dem ich eine Bildungsteilzeit für die intensiven Phasen des Studiums vereinbaren konnte.

Ein weiterer Dank geht an die Menschen, welche mich bei meinem Studium begleitet haben, DI Oliver Tazl und DI Stefan Simon, welche mir mit Studienplanung und Tipps den Einstieg erleichtert haben. Ebenso Danke an Sabrina Hiden, Alina Shaiakhmetova, Markus Huber und Andrey Lalin, welche mit mir viele Prüfungen abgelegt haben, sowie für die gegenseitige Motivation, Stunden um Stunden mit dem Lernstoff zu verbringen, bis wir alle gut vorbereitet waren.

Der größte Dank gilt meiner Ehefrau Astrid Leutschacher-Preitler, die mich zum erneuten Studium motiviert hat und mir im nicht universitären Leben den Rücken freigehalten hat und bei allen Krisen immer ein Leuchtturm und eine Stütze war.

Diese Arbeit möchte ich meiner Tochter Flora widmen, mögest du in einer Welt aufwachsen, in der Sexismus ein Relikt aus der Geschichte ist, und diese Art von Arbeit nicht mehr gebraucht wird.

Inhaltsverzeichnis

Einleitung	1
Struktur der Arbeit	2
Gender und Schule	4
Erkenntnisse zur Genderforschung in der Schule	4
Schulbücher und Gendern	6
Die Messung von Gender-Biases mittels Word-Embeddings	10
Detektion von Gender Biases in Texten	11
Herausforderungen für deutschsprachige Word-Embeddings	14
Daten	16
Datengewinnung	17
Preprocessing	17
Modell	21
Hyperparameter	22
Modell Validation	29
Ergebnisse	36
Ergebnisse aus dem Preprocessing	36
Ergebnisse aus dem Modell	40
Schluss	44
Literaturverzeichnis	48
Quellenverzeichnis	55
Anhang	58

Abbildungsverzeichnis

1	Repräsentation, das Konzept des Denkens in Knoten	10
2	VerlagA: Dichtefunktion zur Worthäufigkeit	20
3	VerlagB: Dichtefunktion zur Worthäufigkeit	21
4	Zusammenhang: Kosinus und Wort-Ähnlichkeit	22
5	VerlagA: Die Delta-Losses für die Top4 Testmodelle und das statisch ermittelte Modell	26
6	VerlagB: Die Delta-Losses für die Top4 Testmodelle und das statisch ermittelte Modell	30
7	VerlagA: Die Wortvektoren des Modells auf zwei Dimensionen gefaltet	33
8	VerlagB: Die Wortvektoren des Modells auf zwei Dimensionen gefaltet	34
9	VerlagA: Die häufigsten genderneutralen Vornamen	37
10	VerlagA: Die häufigsten weiblichen Vornamen	37
11	VerlagA: Die häufigsten männlichen Vornamen	38
12	VerlagB: Die häufigsten genderneutralen Vornamen	38
13	VerlagB: Die häufigsten weiblichen Vornamen	39
14	VerlagB, die häufigsten männliche Vornamen	39

Tabellenverzeichnis

1	VerlagA: Top4 Testmodelle	23
2	VerlagA: Permutation Test Epochs	24
3	VerlagA: Permutation Test Mindestworthäufigkeit	24
4	VerlagA: Permutation Test Window-Size	25
5	VerlagA: Permutation Test Vektorgröße	25
6	VerlagA: Permutation Test Negativ Sample	26
7	VerlagB: Top4 Testmodell	27
8	VerlagB: Permutation Test Epochs	27
9	VerlagB Permutation Test Mindestworthäufigkeit	28
10	VerlagB: Permutation Test Window-Size	28
11	VerlagB: Permutation Test Vektorgröße	28
12	VerlagB: Permutation Test Negativ Sample	29
13	Zusammenfassung der Modelle für die Experimente	35
14	Die Anzahl der Vornamen je Geschlecht	36
15	Die Anzahl der Vornamen je Geschlecht, ohne genderneutrale Vornamen	36
16	Unterschiedliche Vornamen, verwendet bei den Verlagen	39
17	VerlagA: Auswahl Berufe aus Tabelle 28	41
18	VerlagB: Auswahl Berufe aus Tabelle 29	41
19	VerlagA: WEAT Ergebnisse	43
20	VerlagB: WEAT Ergebnisse	44
21	Ergebnisse von Geißler zur deutschsprachigen Kinderliteratur	47
22	VerlagA: WEAT-Zielgruppen Worthäufigkeit vom verschiedenen Mi- nima Wortanzahl	59
23	VerlagB: WEAT-Zielgruppen Worthäufigkeit vom verschiedenen Mi- nima Wortanzahl	60
24	VerlagA: Testmodelle	67

25	VerlagB: Testmodelle	74
26	VerlagA: WEAT Zielgruppenwörter	76
27	VerlagB: WEAT Zielgruppenwörter	77
28	VerlagA: Verschiedene Berufe und ihr Gendergaps	79
29	VerlagB: Verschiedene Berufe und ihr Gendergaps	81

Abkürzungsverzeichnis und Begriffserklärungen

IAT = Implicit Association Test

WEAT = Word Embedding Association Test

NLP = Natural Language Processing

VerlagA = Anonymisierter Schulbuch Verlag

VerlagB = Anonymisierter Schulbuch Verlag

Epochs = Trainingsiterationen

\emptyset = Arithmetisches Mittel

Word Embedding = Wörterrepräsentation durch Vektoren

Losses = Verluste, Abweichung der Vorhersage zum tatsächlichen Vektor

Einleitung

Die Schule ist nach dem Kindergarten die zweite Institution, in der sich Menschen außerhalb des Familienverbands entwickeln, und für viele Menschen sind die Schuljahre die prägendsten ihres Lebens.

Deswegen erscheint es wesentlich, welche Werte in der Schule vermittelt und als gemeinsame, über die Familie hinaus gehenden gesellschaftliche Werte etabliert werden. Die Diskriminierungsfreiheit zwischen Frau und Mann ist in der westlichen Welt ein gesetzlich zugesicherter Wert, aber noch immer vielfach nicht realisierte. Ob und wie in unserer Gesellschaft in Zukunft dieser Wert der Gleichberechtigung der Geschlechter gelebt werden wird, könnte nicht zuletzt damit zusammenhängen, welche Geschlechter- und Rollenbilder heutzutage in der Schule erlernt werden.

Die Forschungshypothese für diese Bachelorarbeit ist: „Kann in Texten österreichischer Schulbücher Genderbias festgestellt werden?“

Ziel dieser Arbeit ist es nun mittels Word-Embedding die zugängliche österreichische Schulbuchliteratur auf mögliche Genderbias zu untersuchen. Unter „Gender“ versteht man das Sozialgeschlecht (Englisch Gender), im Gegensatz zu „Geschlecht“ (Englisch Sex), welches nicht durch die Biologie determiniert wird, sondern durch die soziale Zuschreibung und die damit verbunden Erwartungen an dieses (soziale) Geschlecht [22, S. 2].

Um mögliche Genderbias zu finden, werden bewährte Methoden wie Textanalysis (vektorbasierte Ähnlichkeitsanalysen) [12] und WEAT (Word Embeddings Associationstests) [16] verwendet. Beim WEAT werden, beispielsweise, zwei Wörtergruppen gebildet, welche möglicherweise eine Genderbias aufweisen, wie „typisch weiblich, typisch männliche“ Berufe, und mit Wörtern verglichen, die Genderinformationen beinhalten, wie „Frau, Mann, Mädchen, Junge, weiblich, männlich“ verglichen

Da sich die Arbeit mit österreichischer Schulbuchliteratur beschäftigt und aus diesem Grund wahrscheinlich von höherem Interesse für Lehramtsstudierende, Lehrer:innen, Schulbuchautor:innen, Schulbuchverlagsmitarbeiter:innen und in der Zulassung beteiligten Personen als für die internationale Diskussion der Word-Embeddings ist, und um diesen Zielgruppen einen niederschweligen Zugang zu ermöglichen, habe

ich mich entschieden, diese Arbeit in deutscher Sprache zu verfassen.

Struktur der Arbeit

Am Beginn der Arbeit in Kapitel Gender und Schule wird die Theorie von „Gender“ im Kontext der Schule diskutiert. Es werden Genderbiases im Schulkontext extrahiert und versucht zu erklären, welche Konsequenzen aus den Genderbiases für Schüler:innen entstehen können. Dieses Kapitel soll die genderwissenschaftliche Basis für die weitere Arbeit legen, um die Bedeutung der Ergebnisse im Schulkontext einordnen zu können. Auch werden die unterschiedlichen Arten von Genderbias diskutiert und herausgearbeitet, welche mit den verwendeten Methoden analysiert werden können, und wofür es einen alternativen Ansatz bräuchte.

Im Kapitel Die Messung von Gender-Biases mittels Word-Embeddings wird darauf eingegangen, wie ein Word-Embedding funktioniert und wie dieses genutzt werden kann, um Texte zu quantifizieren, um daraus Erkenntnisse zu gewinnen. und der Zusammenhang zwischen „Implicit Association Test (IAT)“ und Word-Embedding wird präsentiert, damit die Einordnung zu Ideen der Psychologie zum Aufbau von menschlichen semantischen Netzwerken, welche für Personen aus dem Schulbetrieb sicherlich bekannt sind, und damit einen guten Anknüpfungspunkt zur NLP der Computerwissenschaft darstellt. Wie diese Messung von Genderbiases durchgeführt wird, wird im Unterkapitel Detektion von Gender Biases in Texten herausgearbeitet. Es werden die Methoden Test auf Kosinus-Ähnlichkeit und Word-Embeddings Assoziations Test präsentiert. Welche Herausforderungen dabei in (deutschen) Texten entstehen, wird im Unterkapitel Herausforderungen für deutschsprachige Word-Embeddings beschrieben, damit wird die Basis für die weiteren Experimente erarbeitet und

Nach der Erarbeitung der Theorie wird in den folgenden zwei Kapiteln die Entwicklung von der Idee zum Modell beschrieben. Im Kapitel Daten wird erläutert, wie Daten für das Modell gewonnen wurden. Wie der Weg zu den Quellen war und warum eine Analyse der gesamten Schulbuchliteratur der Pflichtschulen in Österreich nicht möglich, eventuell nicht erwünscht ist, und warum am Ende nur Daten von zwei Verlagen bearbeitet wurden. Des Weiteren wird erarbeitet, wie aus den Quellen die Texte extrahiert wurden (Unterkapitel Datengewinnung). Schließlich wird im Unter-

kapitel Preprocessing besprochen, welche Schritte notwendig sind, um die Quelltexte für die Modelle aufzubereiten. Wie aus den Texten durch Tokenisierung, Namens-Listen, Stop-Liste und Lemmatisierung die Worttoken erstellt wurden, mit welchen die Modelle trainiert wurden. Im Kapitel Modell wird geklärt, wie die Hyperparameter (Unterkapitel Hyperparameter) bestimmt wurden, wozu hierfür 210 Modelle benötigt wurden, und wo trotz dieses Aufwands noch Potenzial für ein besseres Modell liegt. Dass die Modelle für die Daten der beiden Verlage für die Forschungsfrage genutzt werden können, wird im Unterkapitel Modell Validation grafisch validiert. Es kann durch die Faltung auf zwei Dimensionen gezeigt werden, dass die Wortvektoren mit Genderinformationen Cluster in der Wolke der Wortvektoren bilden.

Schließlich werden im Kapitel Ergebnisse die Ergebnisse, welche nach dem Preprocessing (Unterkapitel Ergebnisse aus dem Preprocessing und welche aus dem Modell (Unterkapitel Ergebnisse aus dem Modell) gewonnen wurden, präsentiert, um die Frage zu klären, ob und wie stark die zur Verfügung stehenden Texte Genderbiases aufweisen. Hierfür wurde die Repräsentanz der Geschlechter ermittelt, die Vektorähnlichkeit mit ausgewählten Jobs berechnet und eine Reihe von WEATs durchgeführt.

Im Kapitel Schluss werden die Einschränkungen der Modelle, aber welche Aussagen trotzdem getroffen werden können, diskutiert. Es wird kurz aufgezeigt, warum die Digitalisierung der öffentlichen Verwaltung diese Forschungsfragen in Zukunft leichter erforschbar machen, aber warum auch danach noch Grenzen der empirischen Forschung bestehen. Die gewonnenen Ergebnisse werden in dem Kontext der Arbeit von Geißler [20] diskutiert und eine Aussage getroffen, ob die Analyse, die zur Verfügung stehenden Schulbuchserien zu einem sexistischen Unterricht beitragen oder nicht.

Gender und Schule

In Österreich ist es ein erklärtes Bildungsziel, dass die Schule alle Geschlechter fördert, deren Gleichberechtigung und Reflexion über etwaige Benachteiligungen ermöglicht. Diese Ziele werden im Grundsatzerlass „Reflexive Geschlechterpädagogik und Gleichstellung“ [14] des Bundesministeriums für Bildung, Wissenschaft und Forschung festgehalten. So wird im Erlass festgehalten, dass die Schule als staatliche Einrichtung

„durch geeignete und präventive Maßnahmen auch im Bildungsbereich die Gleichstellung der Geschlechter zu fördern, insbesondere auch durch den Abbau von kulturell tradierten Geschlechterstereotypen und patriarchalen Rollenzuweisungen. [14]“

Erkenntnisse zur Genderforschung in der Schule

Diese Ziele scheinen aber in einigen Bereichen der Schule noch nicht erreicht zu sein. Im Schulfach Mathematik lassen sich Genderbiases in unterschiedliche Richtungen finden; einen Leistungs-Genderbias zugunsten der männlichen Schüler und einen Beurteilungs-Genderbias für Schülerinnen bei einer männlichen Lehrkraft [51, S. 27]. Der Leistungs-Genderbias könnte von einer falschen Selbsteinschätzung durch gesellschaftliche Rollenbilder entstehen, was zu einem verminderten Fachinteresse führt. So unterschätzen Schülerinnen ihre Leistungen in Naturwissenschaften und männliche Schüler überschätzen diese [37, S. 3]. Diese Wahrnehmung wird oft unbewusst von Lehrkräften verstärkt, in dem diese annehmen, männliche Schüler kennen die Antwort, Schülerinnen nicht. So kommt Faulstich-Wieland zu der These: Das Lehrer:Innen durch ihr implizites wie explizites Feedback Schüler:Innen in der Unterschätzung ihrer Leistung bestärken und Schüler bei der Überschätzung verstärken [32, S. 16]. Dies Prozess der Interaktion mit der Gesellschaft, in dem sich jede Person befindet und in dem geschlechtliche Rollenerwartungen reproduziert werden, nennt man Doing Gender [75]. Diese reproduzierten Rollenbilder können jedoch durchbrochen werden. So haben männliche Schüler in den Pisa-Untersuchungen deutlich schlechtere Lese-Ergebnisse, aber diese Ergebnisse liegen weniger an einer Genderbegabung, sondern am Interesse. Männliche Schüler, die Interesse an Lesen haben, verfügen über eine hohe Lesekompetenz. Deswegen ist es wichtig, dass Lehrer:innen

die Interessen der Schüler:innen fördern [32, S. 15]. Daraus lässt sich ableiten, dass durch Steigerung der Motivation der Leistungs-Bias zwischen den Geschlechtern wahrscheinlich geschlossen werden kann.

Gendern und Sprache

Für zahlreiche Linguist:innen und Soziolog:innen ist Sprache das zentrale Symbol-system, in dem Gendererwartungen gebildet und reproduziert werden [52, S. 161]. Für den englischen Sprachraum haben Hegarty et al. herausgefunden, dass auch bei gleichgeschlechtlichen Paaren die:der maskuliner empfundene:r Partner:in zuerst genannt wird, wie in England üblicherweise auch bei heterosexuellen Paaren männliche Partner vor der weiblichen Partnerin genannt wird [35]. In der deutschen Sprache, ist die Geschlechterreihenfolge umkehrt, zu der der englischen Sprache. Sprachliche Diskriminierung findet in der deutschen Sprache oft unbewusst statt. Häufig werden maskuline Wörter als Bezeichnung für zusammengefasst weibliche und männliche Gruppen (die Schüler statt die Schülerinnen und Schüler) oder Berufsbezeichnungen (wie Pilot) verwendet [40, S. 177–178]. Diese in der deutschen Sprache übliche Verwendung des generischen Maskulinums kann zu inhaltlichen Missverständnissen führen, wenn eine männliche Person erwartet wird, diese aber tatsächlich weiblich ist [62, S. 132]. Um die gedankliche Repräsentation von weiblichen Personen zu gewährleisten, ist die Nennung beider Geschlechter in Texten wichtig [47, S. 289]. Die Verwendung von weiblichen Bezeichnungen der maskulinen Stammform führt zu einem Genderbias, da sie eine Abweichung von der Norm (das Maskulinum) darstellt. Es wird nie von sehenden Menschen (Norm), sondern von blinden Menschen (Abweichung) geschrieben/gesprochen. Merkmale, die als explizite Norm gelten, werden im Sprachgebrauch nicht erwähnt [40, S. 178], daher ist auch die Verwendung von femininen Ergänzungen zur maskulinen Stammform nicht unproblematisch.

Ein weiteres Phänomen, welches die Sprachgenderforschung aufgedeckt hat, ist Folgendes:

Wenn nur die maskuline Form verwendet wird, um Gruppen bestehend aus allen Geschlechtern zu beschreiben, lässt sich ein Bias zugunsten von Männern feststellen. Als Beispiel lässt sich aufzählen, dass signifikant mehr Sänger als Sängerinnen aufgezählt werden, wenn nach Sängern (korrekte grammatische Form), als wenn nach Sängerinnen und Sängern (gendersensible Form) gefragt wird (obwohl die Fragen inhaltlich ident sind). Dies konnte in mehreren Studien nachgewiesen werden, unter

anderem in [26], [38] [29] und [46]. Dieser Effekt ist für die Sprachen Englisch, Französisch und Deutsch beobachtbar und fast ident [29] und ist statistisch signifikant in 25 Sprachen [46, S. 1023].

Eine weitere Form des Sexismus ist, die Leistung von Frauen nicht als Leistung zu würdigen, sondern in Beziehung zum Geschlecht und stereotypen Rollenbildern zu setzen (z. B. die Frau von XY). Oder wenn ihre Leistungen aberkannt werden (z. B. Care-Arbeit kann jeder, wo ist die Leistung?) oder sie als Person lächerlich gemacht werden und eine Hierarchie zu männlichen Personen hergestellt wird. [40, S. 177].

Für diese Art von Sexismus gibt es den unter anderem den Finkbeiner Test:

Um den Finkbeiner Test zu bestehen, darf ein Bericht nicht beinhalten:

- Die Tatsache, dass sie eine Frau ist,
- der Job des Partners,
- ihre Kinderbetreuungslösung,
- ihr Erziehungsstil,
- dass sie von der Konkurrenz in ihrem Gebiet überrascht wurde,
- dass sie ein Vorbild für andere Frauen ist, und
- dass sie die „erste Frau“ in ihrem Gebiet ist [5]

Folglich werden in dieser Arbeit zwei Gender-Sprach-Aspekte betrachtet:

1. Die Repräsentanz der Geschlechter in Schulbüchern (siehe Ergebnisse aus dem Preprocessing),
2. sowie die Beschreibung der Geschlechterrollen, welche durch Kontext determiniert werden, also die indirekten Genderbiases [12, S. 10] (siehe Ergebnisse aus dem Modell).

Schulbücher und Gendern

Die Schulbücher sind Leitmedien, welche in ihrer Relevanz weit über z. B. Belletristik, Lyrik, Brett- und Computerspiele, sowie Zeitungen hinausgeht. Deswegen sind sie Gegenstand von vielen Fragen und Diskussionen in der Bildungspolitik [69,

S. 47]. Schulbücher haben primär die Funktion, den Unterricht oder das selbstständige Erarbeiten von Fakten- und Methodenwissen zu unterstützen. Aber sie bilden nicht nur die Fakten didaktisch ab, sondern transportieren auch Werte. Dies nicht ausschließlich durch die Auswahl der als relevant verstandenen Fakten, welche von verschiedenen Akteuren ausgehandelt haben [11]. Somit tragen Schulbücher dazu bei, wie Gender neu verhandelt oder konserviert wird [43, S. 3]. Noch in den 1990er-Jahren galt für Deutschland, dass Lehrbücher in Bezug auf Geschlechterrollen als mehrheitlich konservativ betrachtet werden mussten, da sie Frauen- und Männer-Rollenbilder konservierten, anstatt bei der Öffnung zu einer fairen Gesellschaft zu helfen, argumentiert Kegyes [43, S. 9] auf Basis der Analyse von Fichera [24]. In Deutschland gibt es Forschung zur Entwicklung von Mathematik-Schulbüchern von der Wilhelminischen und Adenauer-Zeit bis zur Gegenwart. Sie zeigen eine eindeutige Entwicklung zur geschlechtlichen Gleichstellung von Frau und Mann auf, aber stellen fest, dass noch immer problematische Gender-Rollen vermittelt werden, wie die Abbildung des Mannes als Familienernährer [52, S. 164]. In ihrer Forschung hält Ott fest, dass die deutschen Schulbuchmacher:innen noch immer stärker an gelebten Genderrollenbildern festhalten, als am Gleichheitsideal. [52, S. 164]

Besonders stark scheinen in Fremdsprachen-Büchern, die unterschiedlichen Erwartungen an Geschlechterrollen transportiert zu werden [43, S. 4]. Eine weitere Form der Geschlechterungerechtigkeit in Schulbüchern ist, dass bei Gruppen von Menschen immer nur die maskuline Form verwendet wird. Statt von Schülerinnen und Schülern wird nur von Schülern geschrieben. Dies führt zu einer subtilen Herstellung von Gender-Ungleichheit, da die weibliche Form immer als Abweichung der Norm dargestellt wird [50, S. 79-80].

Bei Schulbüchern handelt es sich um Autor:innen-Werke, welche zwar in Österreich von einer Kommission geprüft werden, aber zu deren Implementation in den Schulen weder Testserien auf Tauglichkeit noch empirische Studien zum Lernerfolg erstellt werden [41, S. 5], [60, S. 47]. So finden Neu-Einführungen und -Überarbeitungen von Schulbüchern nicht durch Studien zur ihr Tauglichkeit, sondern durch Lehrplanänderung oder Lehrregeländerungen statt [34, S. 9]. Schulbücher unterliegen bei ihrer Entstehung verschiedenen Einflüssen. Schön et al. zählen sechs Einflussphären auf die Schulbücher: 1) der Staat mit seinen rechtlichen Vorgaben, aus Verfassung, Lehrplänen, Richtlinien, Zulassungsverfahren, Schulbuchfi-

finanzierung und Rechtschreibreform, 2) Fachwissenschaft, 3) Fachdidaktik, 4) Schüler:Innenzahlen, 5) Markt und 6) Schulbuchverlage mit ihrem unternehmerischen Kalkül aus Produktionspolitik, Distributionspolitik, Preispolitik, Kommunikationspolitik und Marketingmix [60, S. 36].

Testserien oder empirische Untersuchungen zu Schulbüchern sind nicht vorgesehen und haben auch keinen Einfluss auf die Entstehung [34, S. 10].

Schulbücher und Forschung

Schulbücher haben einen großen Einfluss auf die Unterrichtsgestaltung, da Lehrkräfte bei Widerspruch zwischen Lehrplan und Lehrbuch, eher auf das Lehrbuch vertrauen [41, S. 5]. Sie strukturieren das Unterrichtsjahr [60, S. 47] und gelten sogar als „Geheimer Lehrplan“ [23, S. 2], und haben damit eine Qualitätssicherungsfunktion im Unterricht [41, S. 6].

Schulbücher nehmen folglich eine zentrale Rolle in der Unterrichtsgestaltung ein. Dennoch gibt es sehr wenig empirische Forschung über Schulbücher und ihren Einfluss auf den Lernerfolg und das erfolgreich vermittelte Wissen [41, S. 4], wenngleich Lehrkräfte wie auch Schüler:innen sie als wertvoll erachten [28, S. 75]. Die wenigen existenten Forschungsergebnisse weisen einen deutlichen Bias zugunsten von Mathematik und Naturwissenschaften auf, die Schulbücher der anderen Schulfächer werden noch weniger erforscht. [28, S. 75]. Dabei ist unklar, ob Schulbücher zum Lernerfolg beitragen. Kuecken und Valfort haben keine Verbesserung in den durchschnittlichen Testergebnissen gefunden [44, S. 314]. Ein weiterer wichtiger Aspekt in der Schulbuchforschung ist, dass der Effekt von Schulbüchern auf den Lernerfolg von vielen anderen Faktoren wie die soziale Herkunft und der sozioökonomischer Status beeinflusst wird [28, S. 72]. So konnte von Kuecken und Valfort zwar kein Einfluss vom Schulbuchzugang nachgewiesen werden, aber sozioökonomisch privilegierte Schüler:innen konnten durch Schulbuch-Sharing ihre Leistungen steigern [44, S. 314–315]. Frölich und Michealowa hingegen finden: Dass Schulbücher einen positiven externen Effekt auf den Lernerfolg von Schüler:innen haben, daher ist es im öffentlichen Interesse den Schulbucherwerb zu unterstützen [27, S. 486]. Die Empfehlung wird mit einer allgemeinen Unterschätzung der Schulbücher auf den Lernerfolg begründet, da es neben direkten Effekten für die Buchbesitzer:in auch externe Effekte für die Mitschüler:innen gibt [27, S. 484] (denselben Effekt, den Kuecken und Valfort nachweisen konnten).

In Österreich wurde 1967 die Schulbuchaktion im Nationalrat beschlossen:

„§ 31. (1) Zur Erleichterung der Lasten, die den Eltern durch die Erziehung und Ausbildung der Kinder erwachsen, sind Schülern, die eine öffentliche oder mit dem Öffentlichkeitsrecht ausgestattete Pflichtschule, mittlere oder höhere Schule [...], die für den Unterricht notwendigen Schulbücher im Ausmaß eines Höchstbetrages nach Maßgabe der folgenden Bestimmungen unentgeltlich zur Verfügung zu stellen [57]“

Die Republik Österreich tätigt im Vergleich zu den deutschen Bundesländern sehr hohe Ausgaben für Schulbücher pro Schüler:in und Schuljahr (im Vergleich ungefähr die vierfache Aufwendung), was sich auch in der Art der Schulbücher niederschlägt. Sind es in Deutschland hauptsächlich Nachschlagewerke, die von Schüler:in zu Schüler:in weiter gegeben werden, werden in Österreich hauptsächlich Arbeitsbücher verwendet, welche im Besitz des:r jeweiligen Schüler:in verbleiben [60, S. 35]. Schön et al. argumentieren, dass die Ausstattung von Schulbüchern in Österreichs Schulen ausreichend ist, da Eltern mit 20 € pro Schuljahr und Schüler:in im Schuljahr 2016 nur wenig Mittel für „Bücher und Medien“ der Schüler:in aufwenden mussten [60, S. 35]. Es kann also davon ausgegangen werden, dass in Österreich die Forderung von Frölich und Michealowa, nach ausreichend öffentlicher Finanzierung von Schulbüchern (siehe oben), erfüllt sind. Die Befragung der Eltern ist allerdings nicht mehr auf der Webseite der österreichischen Arbeiterkammer verfügbar. Bei der Befragung 2021 kamen auf Eltern Kosten von 137 € pro Schuljahr und Schüler:in für „allgemeine Schulsachen und Bücher“ an [61] zu. Ob der deutliche Unterschied durch eine Änderung der Kategorie oder andere Ursachen zustande gekommen ist, lässt sich ohne Zugang zur Originalstudie nicht klären.

Da die Ausstattung mit Schulbüchern in Österreich gegeben scheint, die Bewertung allerdings auf qualitativen Kriterien aufbaut (siehe Anhang D: Gesetzestext für Gutachterkommission), welche auch

„§ 9. (1) i) der Gleichbehandlung von Frauen und Männern und der Erziehung zur partnerschaftlichen Gestaltung der gesellschaftlichen Entwicklungen. [58]“

beinhalten, wird im folgenden Kapitel aufgezeigt, wie man Word-Embeddings für die quantitative Untersuchung von Gender-Biases in Schulbüchern verwenden kann.

Die Messung von Gender-Biases mittels Word-Embeddings

Sprachmuster wie den Gender-Bias in der Sprache zu quantifizieren, ist keine Idee des maschinellen Lernens, sondern wird von Psycholog:innen schon länger praktiziert. Eine Möglichkeit Gender-Bias zu messen basiert auf der Assoziation von Wörtern. Meyer und Schvaneveldt konnten mit einem Experiment, dass „yes“ und „same“ Antworten deutlich schnell sind, bei Wortpaaren, die miteinander assoziiert sind, als wenn diese keine Assoziation haben [48, S. 227]. Von dieser Beobachtung wurde die Idee abgeleitet, dass Menschen ihr Wissen in Knoten organisieren (siehe Grafik 1) und daher Begriffspaare, die zusammengehören, in denselben Knoten „legen“ und daher Wörter, die inhaltlich zusammengehören, viel schneller abgerufen werden als Wörter, bei denen keine Assoziation vorliegt.

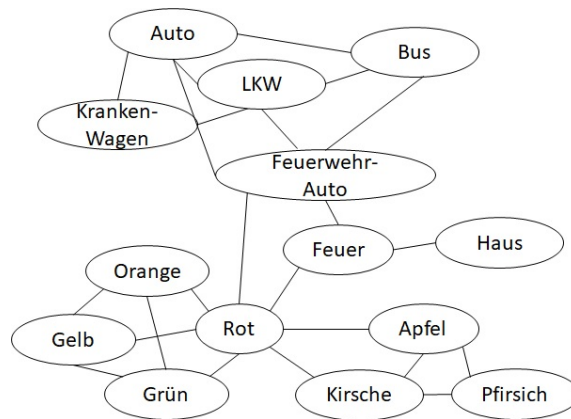


Abbildung 1: Repräsentation, das Konzept des Denkens in Knoten, je kürzer die Striche zwischen den Wörtern, desto stärker sind sie assoziiert; eigene Darstellung, basiert auf [19, S. 412]

Basierend auf der Idee, dass Menschen ihr Wissen im Gehirn in Knoten verknüpfen und daher schneller auf die benachbarten Begriffe zugreifen können, wurde der „Implicit Association Test (IAT)“ entwickelt, bei dem die Reaktionszeit der Versuchsteilnehmer:innen gemessen wird, während sie Wortpaare klassifizieren [45, S. 2]. Dadurch haben die Testteilnehmer:innen Gender-Biases offenbart, welcher sie sich selbst nicht bewusst waren oder nicht angegeben haben [12, S. 5].

Word-Embedding ist eine Methode, bei welcher Inputwörter aus einem Vektor, in welchen diese als Zahlen repräsentiert werden, in einem Prozess in einen Vektorraum transferiert werden, in welchen die semantisch ähnlichen Wörter nahe beieinander liegen, sowohl im IAT als auch im Word-Embedding wird Assoziation zwischen Wörtern durch die Nähe gefunden (IAT: Zeit, Word-Embedding: Vektorraum). Viele

Studien konnten dadurch zeigen, dass die Word-Embeddings einen Gender-Bias von den Texten reflektieren, mit denen sie trainiert wurden [77, S. 1]. Daher kann ein Word-Embedding, welches mit einer Serie von Schulbüchern trainiert wurde, Rückschlüsse über mögliche Gender-Biases liefern, welche in der Buchserie vorhanden sind.

Detektion von Gender Biases in Texten

Bei Word-Embeddings wird die Idee des IAT neu interpretiert. Statt der Reaktionszeit wird die Distanz im Vektorraum, typischerweise über die Kosinusähnlichkeit zwischen den Wortvektoren errechnet, genutzt, um zusammen assoziierte Wörter zu finden. [45, S. 4]

Um den Vektorraum der Wörter zu erstellen, wird „maschinelles Lernen“ verwendet. Genauer betrachtet wird die Natural Language Processing (NLP)-Technik Word2Vec (eine Technik, bei welcher jedes Wort im Text durch einen Vektor repräsentiert wird. Es wird versucht anhand eines Kontextfensters (beispielsweise fünf Wörter vor und nach dem aktuellen Wort), das aktuelle Wort richtig vorher zusagen, daraus wird Vektorraum erstellt, der die Beziehung der Wörter repräsentiert, ähnliche Wörter, liegen näher beieinander) verwendet [49]. Die Vektoren werden aus dem Kontext gebildet, in dem das Wort vorkommt. Der Text wird Wort für Wort gelesen und die Beziehung zu den benachbarten Wörtern festgehalten in einer Matrix.

Diesen Prozess kann man sich als Gravitationsprozess vorstellen, bei dem die Wörter durch wiederholtes Updaten der Vektorwerte immer näher an ihre „richtigen“ Orte im Vektorraum geschoben werden. Sind sie am „richtigen“ Ort, endet die Veränderung und sie bleiben stabil [59, S. 5]. Wörter, die häufig im analysierten Text zu finden sind, erreichen dadurch einen stabilen Ort im Vektorraum [42, S. 4], Wörter, die selten im Text sind, können größere „Sprünge“ zurücklegen.

Schließlich können mit der Repräsentation der Wörter als Vektoren Berechnungen durchgeführt werden. Berühmte Beispiele sind:

König – Mann + Frau =? (= Königin)

Mann ist Arzt, verhält sich wie Frau? (= Krankenschwester)

Welches Wort passt nicht zu den anderen: Apfel, Birne, Laptop? (=Laptop)

Test auf Kosinus-Ähnlichkeit

Bolukbasi et al. [13, S. 42] stellen zwei Methoden zur Messung von Gender-Biases vor.

1. Man misst, ist die Distanz zwischen Wörtern (z. B. Arzt und „sie“ und „er“. Zieht man $\overrightarrow{Wort; sie}$ von $\overrightarrow{Wort; er}$ ab, bei annähernd null, kein Gender-Bias, sonst ist ein Gender-Bias vorhanden (positiv männlich, negativ weiblich).
2. Wie sind die Analogien für „er:Wort :: sie:“?“. Hierfür wird der Wortvektor von „er“ vom Wortvektor „Wort“ subtrahiert und der Wortvektor von „sie“ addiert, der dadurch entstandene Wortvektor zeigt auf die Analogie.

Word-Embeddings Assoziations Test

Caliskan et al [16] haben den Word-Embeddings Assoziations Test (WEAT) entwickelt, um u. a. Gender-Biases zwischen Wortgruppen zu messen.

Für den Vergleich werden die Mittelwerte aus dem Ähnlichkeit-Kosinus für Vektoren (Kosinus-Ähnlichkeit) der $\overrightarrow{Kategorie Wörtern}$ und den $\overrightarrow{Genderwörtern}$ bestimmt, für alle Wörter jeweiligen Kategorien, mit den Attributen Wörtergruppen (in Fall dieser Arbeit Genderwörter für weiblich und männlich).

$$s(X, Y, M, F) = \sum_{x \in X} s(x, M, F) - \sum_{y \in Y} s(y, M, F) \quad (1)$$

wobei

$$s(w, M, F) = mean_{m \in M} cos(\vec{w}, \vec{m}) - mean_{f \in F} cos(\vec{w}, \vec{f}) \quad (2)$$

ist. Wobei: X Liste der Wörter der Ziel-Kategorie X, Y Liste der Wörter der Ziel-Kategorie Y, F Liste der Wörter für Attribut „Weiblich“, M Liste der Wörter für Attribut „Männlich“, f für ein Wort aus der weiblich Liste, m für ein Wort aus der männlich Liste und w für ein Wort aus der Liste X oder Y.

Für die statische Interpretation kann mittels eines Random-Permutationstests ein p-Value errechnet und die statistische Signifikanz bestimmt werden.

$$p = Pr_i[s(X_i, Y_i, M, F) > s(X, Y, M, F)] \quad (3)$$

Wobei X_i und Y_i neu zusammen Kombinationen aus den Kategorie-Wörtern sind,

welche unterschiedlich zu X und Y sind.

Die effektive Größe kann dann mit der Cohen's d [18] interpretiert werden:

- klein: $[0, 2 - 0, 5[$
- mittel: $[0, 5 - 0, 8[$
- groß: $> 0, 8$

Um den Genderbias mit dem Cohen's d (effektive Größe) zu berechnen:

$$effect\ size = \frac{mean_{x \in X} s(x, M, F) - mean_{y \in Y} s(y, M, F)}{sdt_dev_{w \in X \cap Y} s(w, M, F)} \quad (4)$$

Die Gleichungen 1 bis 4 sind von Caliskan et al [16, S. 184-185].

Geißler [20] verwendete diese Techniken für deutschsprachige Texte, und für die weiblichen und männlichen Attribute folgende Listen:

- male = er, Sohn, sein, ihm, Vater, Mann, junge, männlich, Bruder, söhne, Väter, Männer, Brüder, Onkel, Neffe, Neffen, Cousin, Cousins, Papa, Papas
- female = sie, Tochter, ihres, ihr, Mutter, Frau, Mädchen, weiblich, Schwester, Töchter, Mütter, Frauen, Schwestern, Tante, Nichte, Nichten, Cousine, Cousinen, Mama, Mamas

[20, S. 51]

Diese wurden mit 16 (X, Y)-Kategorien von Wörtern verglichen.

- | | |
|--------------------------------|-------------------------------------|
| 1. pleasant vs. unpleasant | 10. male vs. female sports |
| 2. career vs. family | 11. active vs. quiet games |
| 3. maths vs. arts | 12. male vs. female adjective |
| 4. science vs. arts | 13. male vs. female professions |
| 5. thinking vs. feeling | 14. male vs. female qualities |
| 6. intelligence vs. appearance | 15. dominant vs. obedient |
| 7. strength vs. weakness | 16. male vs. female school subjects |
| 8. outdoor vs. indoor | |
| 9. male vs. female toys | |

Für die 16 WEAT-Kategorien Listen ist für „1. pleasant v.s unpleasant“ [45, S. 5] und für „5. thinking vs. feeling“ [45] die Quellen, sich teilweise auf [16] bezieht. Die

anderen Kategorien sind Listen von Geißler [20], der ebenfalls Teile von [16] verwendet, und um [39] und [17] ergänzt hat. Die vollständigen Listen der verwendeten Wörter können den Tabellen 26 und 27 entnommen werden.

Herausforderungen für deutschsprachige Word-Embeddings

Bei Wörtern wird erwartet, dass der nächste Nachbar eines Wortes die eigene Pluralform ist [42, S. 5]. Diese Herausforderung wird in dem hier verwendeten Modell durch die Anwendung des Hannover Tagger von Christian Wartena [73] (Details in Lemmatisierung der Token 19) umgangen, da alle Wörter durch ihre Stammform ersetzt werden. Zusätzlich wird das Problem gelöst, dass in der deutschen Sprache die Wörter durch Prä- und Postsilben ergänzt werden, sich aber in ihrer eigentlichen Bedeutung nicht ändern, sondern vom Kontext (grammatikalische Zeit und Person) abhängig sind. Unberücksichtigt bleiben für diese Arbeit die zusammengesetzten Wörter der deutschen Sprache. So werden diese als eigene Wörter behandelt und nicht in ihre Teilwörter zerlegt.

Untersuchungen haben gezeigt, dass das Vorhandensein von grammatikalischen Geschlechtern, welche sich vom semantischen Geschlecht unterscheidet, in Word-Embeddings gelernt wird [77, S. 2]. Zwar liegt eine Kosinus-Ähnlichkeit vor, es scheint wenig überraschend, dass semantisch weibliche Wörter auch in den meisten Fällen grammatikalische weibliche Wörter sind, dennoch werden Wörter, die semantisch ohne Geschlechtsbedeutung sind als solche erkannt, wie Zhou zeigen konnte [77, S. 4]. Somit ist eine Analyse des semantischen Geschlechts durch das grammatikalische nicht beeinträchtigt. Daher wird für die weitere Arbeit das grammatikalische Geschlecht nicht weiter berücksichtigt.

Sprache mit grammatikalischem Gender haben beinhalten Wörter wie „Schüler“, welche entweder einen männlichen Schüler oder einen Schüler im Allgemeinen bezeichnen. Um dieses Problem zu lösen, wäre es notwendig, eine Ebene im Preprocessing durchzuführen, indem zuerst das semantische Geschlecht gelernt und in einem weiteren Schritt jedes dieser Wörter aus dem Kontext durch einen Token mit und ohne Geschlecht-Zusatz ersetzt wird. Dies liegt jedoch außerhalb der Möglichkeiten dieser Arbeit. Dasselbe Problem besteht bei „sie“ und „er“. In englischsprachigen Arbeiten sind „she“ und „he“ Quellen für Genderbezug [13, S. 42], in der deutschen Sprache wäre hier wieder ein vortrainiertes System notwendig, welches zwischen „sie“

als weibliche Person oder einer Gruppe von Menschen unterscheidet. Auch dies wird in dieser Arbeit nicht behandelt und der Vorlage der Stop-Liste (siehe Anhang B: Listen Stop-Liste und Artefakte) gefolgt und „sie“ und „er“ als Stop-Wörter aussortiert.

Schwierig nachzuweisen ist einer Form des indirekten Sexismus (siehe 6), wenn Frauen durch Zuschreibungen als Objekte dargestellt oder diskriminiert werden, selbst wenn diese als Komplimente formuliert sind. Glick und Fiske haben dafür ein Score-System erstellt [30]. In dieser Arbeit wird diese Form des Sexismus allerdings nur anhand der Kosinus-Ähnlichkeit von Eigenschaftswörtern im Verhältnis zu den Geschlechtern untersucht.

In Word-Embeddings gibt es keine Subjekte oder Objekte [12, S. 6], der Satzbau wird komplett ignoriert und nur der Kontext (Nähe zu den Wörtern) betrachtet.

Daten

Der ursprüngliche Titel der Arbeit war: „Unterrichtet unsere Schule Sexismus; eine Analyse der **zugelassenen** Unterrichtsliteratur für österreichische Schulen mittels neuronaler Netzwerke“. Hierfür war die Herangehensweise, ein neuronales Netzwerk aller Schulbücher, welche für den Unterricht im Pflichtschulbereich zugelassen sind, zu trainieren und dann zu analysieren, welche Inhalte dieses künstliche Gehirn über Gender gelernt hat. Daher wurde versucht, die hierfür benötigten Schulbücher zu Verfügung gestellt zu bekommen. Es wurde angenommen, dass in jeder Universitätsbibliothek der Hochschulen mit Lehramtsstudien E-Book-Versionen vorhanden sein müssten, da diese von den Studierenden zur Unterrichtsplanung benötigt werden (siehe auch Geheimer Unterrichtsplan, Seite 8). Die meisten Werke sind jedoch weder in Print noch in E-Book-Versionen vorhanden, ebenso wenig an der Technischen Universität Graz oder der Karl-Franzens-Universität Graz.

Im nächsten Schritt wurden die benötigten Schulbücher im Bundesministerium für Bildung, Wissenschaft und Forschung in Österreich angefragt, da diese dort zum Schulunterricht zugelassen werden, aber auch hier war keine Sammlung verfügbar. Die dort zuständige Abteilung der Schulbuchaktion [15] legt aktuell weder eine digitale noch analoge Sammlung an.

Das Interesse an der Schulbuchsammlung vonseiten des Ministeriums scheint begrenzt zu sein, so hat Kissling dokumentiert, dass im Archive des Bundesministeriums neben der historisch wertvollen Sammlung Lebensmittel von der Kantine gelagert wurden und 2006 wurde das Archiv gänzlich aufgelöst [72, S. 2]. Aktuell liegt also die Schulbuchsammlung in der Universitätsbibliothek in der Teinfaltstraße der Universität Wien[36] auf. Am 21.02.2022 konnte im Zuge der Recherchen in einem Telefonat herausgefunden werden, dass dort die Schulbuchsammlung ausgestellt und zugänglich ist, allerdings vonseiten der Bibliothek kein aktuelles Interesse besteht, eine digitale oder maschinell erforschbare Sammlung aufzubauen[66]. Schließlich war für die Beantwortung meiner These an diesem Punkt die Suche nach einer öffentlichen oder im Besitz der Allgemeinheit liegenden Quelle beendet.

Der nächste Versuch war, direkt über die Verlage der Schulbücher einen Zugang zu digitalen Ausgaben der betreffenden Bücher zu erhalten. Allerdings stellte sich im weiteren Verlauf heraus, dass keiner der kontaktierten Verlage eine Forschungsschnittstelle betreibt. Schließlich erklärte sich ein Verlag sofort bereit, seinen Best-

seller zur Verfügung zu stellen und stellte für diesen einen Download von JSON-Files bereit.

Andere Verlage haben angeboten, Daten bereitzustellen, wenn der Fokus dieser Arbeit auf wenige Bücher gelegt wird. Daher ist diese Arbeit nun beschränkt auf die verfügbare Literatur im Unterrichtsfach Deutsch für die Mittelschule in Österreich. Nach dieser Einschränkung wurde von zwei Verlagen der Zugang zu ihren Deutsch-Unterrichtsbüchern über digi4school.at gestellt, wenngleich ein Download der Texte von dort nicht möglich ist, da die Textinhalte kodiert sind. Der Kundensupport teilte im direkten Kontakt mit, dass sie aus rechtlichen Gründen die Texte nicht zur Verfügung stellen könnten. Daraufhin wurden von einem der zwei betreffenden Verlage Bücher als PDF-Dateien zur Verfügung gestellt. Deswegen werden in weiterer Folge die Buchserien von diesen beiden Verlagen analysiert (zur Anonymisierung VerlagA und VerlagB).

Datengewinnung

Die Texte von VerlagA wurden aus den JSON-Files extrahiert („title“ und „text“) und in ein TXT-File gespeichert, welches inkl. Artefakte 152.793 gezählte Wörter beinhaltet und den Corpus VerlagA darstellt.

Aus den PDF-Files von VerlagB wurden mittels des PDFMiner [76] die Texte aus den Files extrahiert, hier ließen sich 393.315 gezählte Wörter darstellen.

Die beiden Textkörper sind im Kontext von NLP kleinere Texte, was eine Analyse erschwert, aber nicht unmöglich macht.

Preprocessing

Bevor die Daten mittels Word2Vec bearbeitet werden konnten, mussten diese noch vorbereitet werden; dieser Vorgang nennt sich Preprocessing und beinhaltet mehrere Schritte.

Tokenisierung

Um die Verarbeitung zu erleichtern, werden die Wörter in Token umgewandelt (siehe Listing 1). Dafür wird jede Zeile (Sentence) für Zeile eingelesen und in eine Liste umgewandelt, welche dann die Wörter beinhaltet. Am Ende der Tokenisierung wird der

Text als eine Liste (Text) von Listen (Zeilen), welche die Token (Wörter) beinhaltet, dargestellt. Für diese Aufgabe wurde dem Tutorium von Wartena (HS Hannover [74]) gefolgt und das Tool nltk [1] und codecs [54] verwendet.

```
sentences = nltk.sent_tokenize(texts , language='german ')\n\nsentences_token = [nltk.tokenize.word_tokenize(sent ,\n                    language='german ')\n                    for sent in sentences]
```

Listing 1: Tokenisierung

Stop-Liste und Artefakte

Es gibt Wörter, die wenig Information auf den Kontext enthalten, wie „aber, allgemein, deshalb ...“; diese Wörter haben keinen Mehrwert für die Analyse und können entfernt werden. Ein weiterer Effekt durch die Entfernung ist, dass die relative Kontextweite erhöht wird [31, S. 5]. Ich verwendete für meine Stop-Liste die Liste von Tatman[65] (siehe Anhang B: Listen Stop Liste). Zusätzlich zur Stop-Liste wurden alle Token, die kleiner als zwei Zeichen sind, entfernt, da es in der deutschen Sprache keine Wörter gibt, welche aus einem Buchstaben bestehen. Beim Auslesen des Textes mittels dem PDFMiner entstanden schließlich Artefakte in der Form „cid:[zahl]“, welche mit einer Regulär-Expression „cid:*?“ entfernt wurden. Der Hanover Tagger von Wartena ersetzt Satzzeichen durch „-“, diese wurden in die Stop-Liste aufgenommen und ebenso entfernt.

Gender-Token statt Namen

In Schulbüchern für Kinder werden häufig Namen statt den Personalpronomen „er“ und „sie“ verwendet. Da für die Analyse in dieser Arbeit die Namen Anna und Jasmin dieselbe Bedeutung haben, wurden von der Webseite <https://www.vita34.at> [67] je eine Liste mit weiblichen [68] und männlichen Vornamen heruntergeladen. In beiden Listen befinden sich 2716 weibliche und 2541 männliche internationale Vornamen (siehe Anhang B: Listen Liste weiblicher Vornamen und Liste männlicher Vornamen). Daraufhin wurden beide Listen manuell auf Einträge, welche in deutscher Sprache wahrscheinlich keine Namen darstellen, sondern eher einen Ort oder

etwas anderes bezeichnen, untersucht.

Es wurden aus der Liste die weiblichen Namen = [Cheyenne, Christin, Europa, Fee, Mercedes, Ninja, Paris, Rose, Sydney, Tsunami, Venus] entfernt.

Aus der Liste männlicher Namen wurden = [Kader, Kosmo, Sydney, Veit, Veith, Yale, York] ausgeschlossen.

Die beiden Listen wurden auf doppelte Einträge untersucht und diese von beiden Listen entfernt. Diese 265 Namen wurden in einer separaten Liste für genderneutrale Namen (siehe Anhang B: Listen Liste genderneutrale Vornamen) zwischengespeichert. Da in dieser Liste viele internationale Namen enthalten sind, gibt es auch Einträge, welche in der deutschen Sprache einem Gender zugewiesen können. Folglich wurde die Liste wiederum manuell untersucht. Die verwendeten Quellen zur Zuordnung sind im Anhang B: Listen Liste genderneutrale Vornamen

105 Namen wurden als weiblich identifiziert Liste genderneutrale Vornamen und 28 als männlich Liste genderneutrale Vornamen, es verblieben 132 genderneutrale Namen.

In nächsten Schritt wurden alle weiblichen Vornamen in den Texten durch *female_token*, männliche Vornamen durch *male_token* und *gender_neutral* Token ersetzt.

Die Idee ist, dass alle Namen durch ihr Geschlecht repräsentiert werden und nicht mehr jeder Name durch einen eigenen Token repräsentiert wird.

Lemmatisierung der Token

Aufgrund der für NLP sehr kurzen Texte erscheint es sinnvoll, alle Wörter auf ihre Stammform zurückzuführen und durch die Token der Stammform repräsentieren zu lassen, um mehr Wiederholungen im Text zu erzeugen, ohne etwas am Kontext zu verändern. Hierfür wird erneut die Anleitung [74] herangezogen, basiert auf der Arbeit Wartena [73].

```
from HanTa import HanoverTagger as ht

tagger = ht.HanoverTagger( 'morphmodel_ger.pgz' )
...
for sent in sentences_token:
    ...
```

```

for index, word in enumerate(sent):
    ...
    if tagger.analyze(word)[0] != "":
        sent[index] = tagger.analyze(word)[0]
    ...

```

Listing 2: Lemmatisierung

Es wird durch alle Listen durch iteriert und alle Token durch die Stammform ihres jeweiligen Tokens ersetzt (siehe Listing 2).

Wie man in Abbildung 2 sehen kann, sind knapp die Hälfte der Token nur einmal in Corpus und nur 20 % der Token häufiger als dreimal vorhanden.

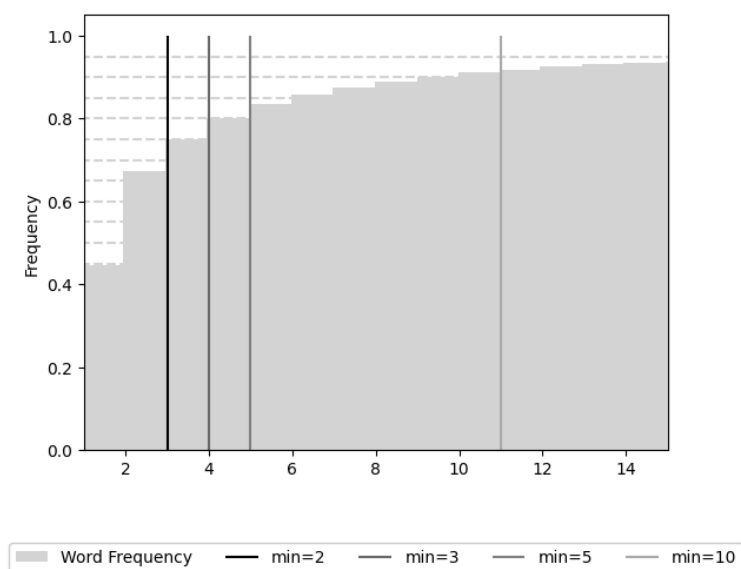


Abbildung 2: VerlagA: Dichtefunktion zur Worthäufigkeit; eigene Darstellung.

Die Balken geben die Anzahl der Wörter wieder, die mindestens so häufig vorkommen, wie die Zahl links von ihnen. Die Striche geben die jeweilige Grenze an, alles links von der Grenze geht nicht in Analyse ein, wenn die Mindestwörterhäufigkeit größer als der Wert gewählt wird.

Wie man in Abbildung 3 sehen kann, sind auch in diesem Corpus mehr als die Hälfte der Token nur einmal im Corpus vertreten und nur etwas weniger als 20 % öfter als fünfmal.

Um die Texte auf Gender-Biases untersuchen zu können, müssen die Texte genügend Wörter aus den Zielkategorien der WEATs (Seite 12) und genug Genderwörter enthalten, wodurch die maximale Mindestwörterhäufigkeit für VerlagA drei und für VerlagB fünf ist.




Abbildung 3: VerlagB: Dichtefunktion zur Worthäufigkeit; eigene Darstellung

Die Balken geben die Anzahl der Wörter wieder, die mindestens so häufig vorkommen, wie die Zahl links von ihnen. Die Striche geben die jeweilige Grenze an, alles links von der Grenze geht nicht in Analyse ein, wenn die Mindestworthäufigkeit größer als der Wert gewählt wird.

Modell

Um Aussagen über die semantische Darstellung der Geschlechter in Schulbüchern treffen zu können, wird ein neuronales Netzwerk trainiert und dieses danach zu dem Erlernten „befragt“.

Zur Erstellung des Modells wird Word2Vec aus der Gensim Library von Radim Řehůřek und Petr Sojka verwendet[55] verwendet. Bolukbasi, Chang et al. [12, S. 3] haben gezeigt, dass in Word-Embeddings geschlechtsbezogene Wörter Cluster bilden, wodurch zwischen semantisch weiblich, neutralen und männlichen Wörtern unterscheiden werden kann. Demzufolge entstehen unterschiedliche Distanzen im Vektorraum zu anderen Wortvektoren. Je nach Ergebnis besteht ein schematischer Zusammenhang (oder nicht) zwischen den beiden Wörtern (siehe Abbildung 4).

Zur Erstellung des Modells bedarf es Hyperparameter, welche zu wählen sind. Die Hyperparameter, welche in dieser Arbeit von den Default-Werten von Gensim abweichend sind, sind Epochs (wie viel Durchläufe über dem Corpus wird trainiert), Mindestworthäufigkeit (wie oft muss ein Token im Corpus vorkommen, um berücksichtigt zu werden), Fensterbreite (wie weit ist der berücksichtigte Kontext), Vektorgröße (wie viele „Neuronen“ werden trainiert) und das Negativ Sample (dieser

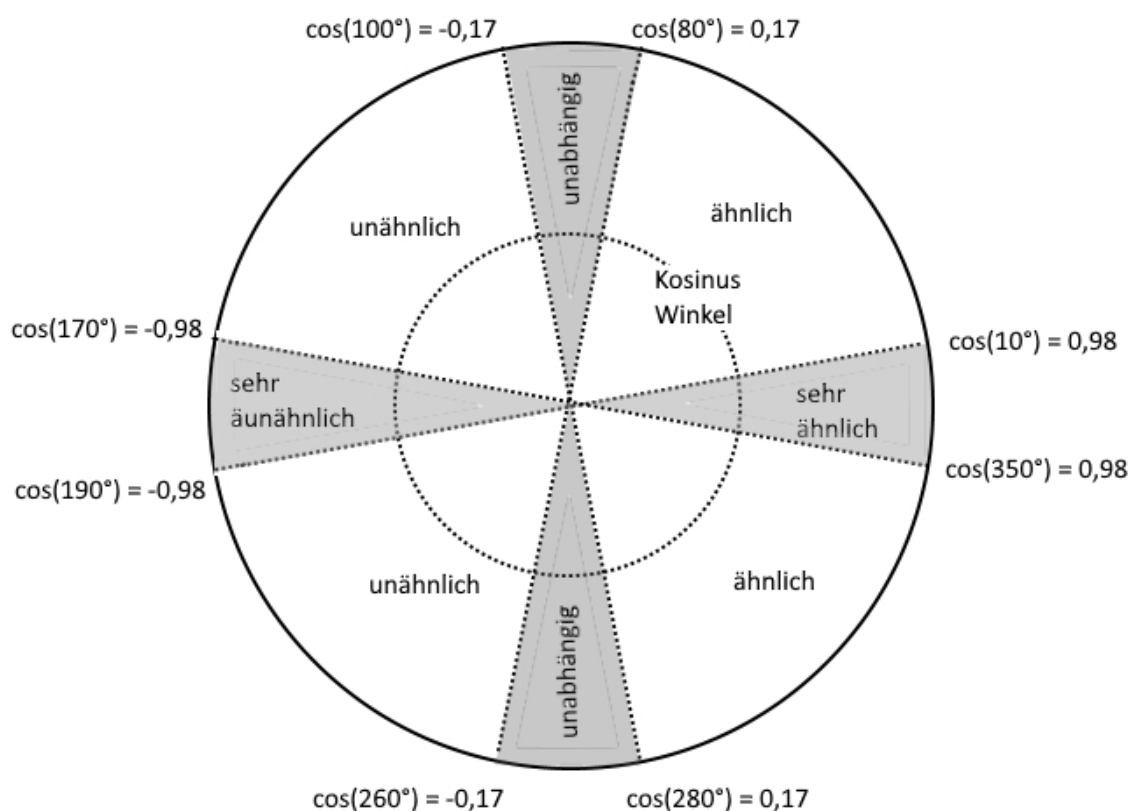


Abbildung 4: Zusammenhang: Kosinus und Wort-Ähnlichkeit, eigene Darstellung basierten auf der Darstellung von [21]

Je näher bei 1 die Kosinus Vektorähnlichkeit ist, desto mehr gemeinsame Kontexte teilen sich beiden Wortvektoren, $> 0,98$ sehr ähnlich, $> 0,17$ ähnlich, negative Vorzeichen drehen die Bedeutung um.

Parameter gibt die Anzahl der Token an, welche zufällig ermittelt werden, wenn sie nicht im aktuellen Fenster sind, und als nicht Kontext korrigiert werden).

Hyperparameter

Um die passenden Hyperparameter für das jeweilige Modell zu finden, wurden für VerlagA und für VerlagB 210 Modelle trainiert, mit Epochs [45, 50, 55, 60, 65, 70, 80, 85, 90] Fenstergröße (Window-Size) [1, 2, 3, 5, 8, 13], Vektorgröße [25, 50, 100, 200, 300, 400, 500] und für negatives Sampling [1, 5, 10, 15, 20, 25, 30].

Für die Mindestworthäufigkeit wurde für den VerlagA [1, 2, 3] trainiert, da mehr als drei dazu führen würden, dass nur mehr sechs (oder weniger) WEAT mit vier oder mehr Wörtern in beiden Ziellisten durchgeführt werden können (siehe Tabelle 22).

Für den VerlagB wird aus demselben Grund (siehe Tabelle 23) eine Mindestwort-häufigkeit von fünf als Maximum gewählt und mit [1, 2, 3, 4, 5] trainiert.

Zu validieren wird die Gensim-Loss-Funktion verwendet. Allerdings funktioniert diese nicht für Negativ Sample 0, weshalb dieser Hyperparameter aus technischen Gründen ausgeschlossen wurde.

Jedes der 210 Modelle wird mit zufällig ausgewählten Hyperparameter-Kombinationen trainiert und der Durchschnitt der Verluste (Losses) aus den letzten fünf Epochs gespeichert, um die Modelle miteinander vergleichen zu können. Um das optimale Modell für den jeweiligen Datensatz zu finden, wird mittels modifizierten Permutationstests (Modifizierter Permutation Test für den Hyperparameter-Vergleich, mit 1000 Iterationen) ermittelt, welcher Hyperparameter aus jeder Kategorie generiert. Dazu werden alle Hyperparameter derselben Kategorie als Testgruppe und Kontrollgruppe genutzt. Die Ergebnisse werden nicht als klassische p-Values interpretiert, es wird nur die Richtung genutzt, um den besseren Hyperparameter für das finale Modell zu ermitteln. Jeder Hyperparameter ist zumindest 21 Mal (Kategorie Epochs) und in gleicher Anzahl wie Hyperparameter aus derselben Kategorie im finalen Datensatz zum Vergleich vertreten.

Hyperparameter VerlagA

Für das Modell von VerlagA waren die erfolgreichsten Test-Modelle aus Tabelle VerlagA: Top4 Testmodelle am erfolgreichsten. Damit werden ca. 85 % der Token beim letzten Epoch richtig vom Modell vorhergesagt (1 - Losses / Token in Corpus (siehe 29)).

VerlagA: Top4 Testmodelle

Test Modell	Epochs	Min-Word	Window	Vector	NegSample	Losses
36	100	2	1	200	3	11.216,565
198	95	2	2	300	3	11.347,876
186	100	1	13	300	3	11.378,045
114	95	3	3	300	2	11.410,540

Tabelle 1: VerlagA: Top4 Testmodelle

Mit den Losses der Test-Modelle (VerlagA: Testmodelle) wurden die Hyperpara-

meter mittels Permutation getestet. Für den Hyperparameter Epochs (siehe Tabelle 2) sind 95 Epochs optimal, dies sogar statistisch signifikant für die gemessenen Losses.

VerlagA: Training Epochs

	55	60	65	70	75	80	85	90	95	100	Ø
55		0,967	1,000	1,000	0,999	1,000	1,000	1,000	1,000	1,000	0,996
60	0,039		0,995	0,989	0,932	0,998	1,000	1,000	1,000	0,992	0,883
65	0,000	0,004		0,643	0,145	0,872	0,929	0,974	1,000	0,801	0,596
70	0,000	0,005	0,351		0,120	0,696	0,835	0,905	0,998	0,706	0,513
75	0,002	0,090	0,833	0,869		0,985	0,983	0,998	1,000	0,944	0,745
80	0,000	0,000	0,139	0,309	0,029		0,742	0,867	1,000	0,589	0,408
85	0,000	0,000	0,063	0,176	0,015	0,239		0,681	0,968	0,472	0,290
90	0,000	0,000	0,029	0,084	0,002	0,139	0,301		0,892	0,304	0,195
95	0,000	0,000	0,000	0,003	0,000	0,003	0,032	0,107		0,083	0,025
100	0,000	0,007	0,183	0,296	0,056	0,422	0,531	0,673	0,922		0,343

Tabelle 2: VerlagA: Permutation Test Epochs

Für den Hyperparameter Mindestwörthäufigkeit (siehe Tabelle 3) sind zwei und drei deutlich statistisch signifikant besser als eins. Drei etwas besser als zwei.

VerlagA: Mindestwörthäufigkeit

	1	2	3	Ø
1		0,991	0,999	0,995
2	0,011		0,695	0,353
3	0,002	0,288		0,145

Tabelle 3: VerlagA: Permutation Test Mindestwörthäufigkeit

Für den Hyperparameter Window-Size (siehe Tabelle 4) zeigt sich, dass der Parameter eins am besten funktioniert, wobei acht fast genauso gut funktionieren würde.

Für den Hyperparameter Vektorgröße zeigt sich, dass 300 besser funktioniert als die anderen Größen (siehe Tabelle 5).

VerlagA: Window Size

	1	2	3	5	8	13	0
1		0,171	0,092	0,032	0,419	0,014	0,146
2	0,834		0,366	0,174	0,774	0,120	0,454
3	0,926	0,642		0,280	0,877	0,181	0,581
5	0,968	0,819	0,729		0,959	0,416	0,778
8	0,602	0,227	0,157	0,043		0,025	0,211
13	0,982	0,886	0,812	0,581	0,973		0,847

*Tabelle 4: VerlagA: Permutation Test Window-Size**VerlagA: Vektorgröße*

	25	50	100	200	300	400	500	0
25		0,995	0,998	0,999	1,000	1,000	1,000	0,999
50	0,007		0,794	0,730	0,966	0,761	0,924	0,697
100	0,000	0,201		0,406	0,826	0,450	0,719	0,434
200	0,000	0,260	0,572		0,856	0,541	0,784	0,502
300	0,000	0,031	0,177	0,137		0,126	0,305	0,129
400	0,002	0,255	0,542	0,472	0,863		0,768	0,484
500	0,000	0,063	0,280	0,227	0,692	0,244		0,251

Tabelle 5: VerlagA: Permutation Test Vektorgröße

Für das negative Sample ist eins statistisch signifikant besser als die anderen Werte (siehe Tabelle 6). Allerdings wurde 0 als Wert ausgeschlossen, da die Gensim-Loss-Funktion mit einem negative Sample von 0 nicht funktionieren.

Die Analyse der Test-Modelle führt zur Empfehlung des Modells **Epochs = 95**, **Mindestworthäufigkeit = 3**, **Window-Size = 1**, **Vektorgröße = 300**, **Negativ Sample = 1**.

Das statistische Modell hat weniger durchschnittliche Losses in den letzten fünf Epochs als die Top4 Modelle (siehe Bild 5). Das ausgewählte Modell für den VerlagA hat 4.166 unterschiedliche Token (Wortschatz) in einem Corpus von 72.852 Token.

VerlagA: Negative Sample

	1	2	3	5	8	13	0
1		0,011	0,008	0,002	0,000	0,000	0,004
2	0,989		0,397	0,397	0,004	0,000	0,357
3	0,992	0,603		0,460	0,007	0,000	0,412
5	0,998	0,603	0,540		0,004	0,000	0,429
8	1,000	0,996	0,993	0,996		0,000	0,797
13	1,000	1,000	1,000	1,000	1,000		1,000

Tabelle 6: VerlagA: Permutation Test Negativ Sample




Abbildung 5: Die Delta-Losses für die Top4 Testmodelle und das statisch ermittelte Modell für VerlagA; eigene Darstellung.

Der Vergleich der Entwicklung der Delta-Losses der verschiedenen Modelle. Man sieht, wie alle Modelle gegen einen Grenzwert an Delta-Losses streben. Die strichlierten Linien zeigen die durchschnittlichen Delta-Losses der letzten fünf Epochs des jeweiligen Modells. Im herausgehobenen Bereich ist sichtbar, dass das Modell mit statistisch ermittelten Hyperparametern die beste Performance zeigt.

Hyperparameter VerlagB

Wie für die Daten von VerlagA werden von VerlagB die Testmodelle ermittelt (siehe Tabellen 24 und 25). Die besten vier Modelle sind in Tabelle VerlagB: Top4 Testmo-

dell, was bedeutet, dass ca. 12 % der Token falsch vorhergesagt werden im Modell ($losses/Token$ im Corpus (siehe 29))

VerlagB: Top 4 Modelle

Test Modell	Epochs	Min-Word	Window	Vector	NegSample	Losses
148	100	3	1	100	2	20.498,244
187	100	3	2	300	2	21.810,660
81	100	2	1	200	3	21.829,566
205	100	3	5	200	1	22.089,208

Tabelle 7: VerlagB: Top4 Testmodell

Für die Epochs des VerlagB sind 80 und 90 am besten. 90 Epochs funktionieren in der Statistik etwas besser (siehe Tabelle 8).

VerlagB: Training Epochs

55	60	65	70	75	80	85	90	95	100	Ø
	0.447	0.872	0.873	0.952	1.000	0.682	1.000	0.988	0.963	0.864
0.558		0.858	0.860	0.936	1.000	0.724	1.000	0.966	0.960	0.874
0.115	0.171		0.694	0.786	1.000	0.473	1.000	0.910	0.883	0.670
0.101	0.110	0.317		0.521	0.974	0.280	0.986	0.648	0.709	0.516
0.054	0.052	0.204	0.496		0.989	0.279	0.988	0.711	0.710	0.498
0.000	0.000	0.000	0.027	0.012		0.017	0.627	0.050	0.168	0.100
0.313	0.284	0.514	0.679	0.702	0.985		0.987	0.839	0.833	0.682
0.000	0.000	0.000	0.015	0.004	0.388	0.008		0.039	0.127	0.065
0.020	0.024	0.083	0.321	0.290	0.952	0.203	0.967		0.562	0.380
0.037	0.043	0.100	0.313	0.261	0.834	0.167	0.879	0.419		0.339

Tabelle 8: VerlagB: Permutation Test Epochs

Die Mindestworthäufigkeit ist auch für das Modell vom VerlagB am besten für die höchstmögliche, in diesem Fall fünf (siehe Tabelle 9).

Auch für die Fenstergröße (siehe Tabelle 10)

Die optimale Vektorgröße für das Modell von VerlagB ist 300 (siehe Tabelle 11).

VerlagB: Mindestworthäufigkeit

	1	2	3	4	5	Ø
1		0,787	0,931	0,842	0,993	0,888
2	0,202		0,717	0,530	0,915	0,591
3	0,057	0,328		0,343	0,836	0,391
4	0,128	0,426	0,658		0,878	0,523
5	0,010	0,110	0,184	0,107		0,103

Tabelle 9: VerlagB Permutation Test Mindestworthäufigkeit

VerlagB: Fenstergröße

	1	2	3	5	8	13	Ø
1		0,109	0,070	0,066	0,009	0,081	0,067
2	0,918		0,441	0,340	0,074	0,327	0,420
3	0,907	0,537		0,424	0,115	0,415	0,480
5	0,922	0,682	0,603		0,162	0,487	0,571
8	0,992	0,951	0,897	0,816		0,817	0,895
13	0,935	0,662	0,622	0,509	0,166		0,579

Tabelle 10: VerlagB: Permutation Test Window-Size

VerlagB: Vektorgröße

	25	50	100	200	300	400	500	0
25		0,936	1,000	1,000	1,000	0,999	1,000	0,989
50	0,073		0,985	1,000	1,000	0,995	1,000	0,842
100	0,000	0,010		0,630	0,838	0,518	0,804	0,467
200	0,000	0,005	0,409		0,772	0,402	0,732	0,387
300	0,000	0,000	0,143	0,221		0,156	0,451	0,162
400	0,000	0,006	0,455	0,575	0,837		0,812	0,448
500	0,000	0,000	0,198	0,267	0,580	0,186		0,205

Tabelle 11: VerlagB: Permutation Test Vektorgröße

und Negativ Sample (siehe Tabelle 12) zeigt sich eins als der statisch beste Hyperparameter für das Modell für VerlagB wie für VerlagA.

Das statistisch beste Modell kann, gemessen an den Losses der Gensim-Loss-Funktion, besser als die generierten Modelle sein (siehe Abbildung 6), allerdings sind

VerlagB: Negative Sample

	1	2	3	5	8	13	Ø
1		0,225	0,015	0,000	0,000	0,000	0,048
2	0,774		0,055	0,000	0,000	0,000	0,166
3	0,989	0,951		0,014	0,000	0,000	0,391
5	1,000	1,000	0,990		0,000	0,000	0,598
8	1,000	1,000	1,000	0,998		0,000	0,800
13	1,000	1,000	1,000	1,000	1,000		1,000

Tabelle 12: VerlagB: Permutation Test Negativ Sample

die Unterschiede sehr gering und die Gensim-Loss-Funktion gibt keinen konstanten Wert bei der Wiederholung des Versuches zurück, sondern könnte sich geringfügig ändern. Für die weitere Untersuchung ist es ausreichend, dass das statistisch ermittelte Modell das beste seinen könnte. Somit ergibt sich ein statistisch bestes Modell mit den Hyperparametern **Epochs = 90**, **Mindestworthäufigkeit = 5**, **Fenstergröße = 1**, **Vektorgröße = 300**, **Negativ Sample = 1**.

Das Corpus für das Modell für den VerlagB hat einen Wortschatz von 5.013 unterschiedlichen Token und umfasst insgesamt 170.597 Token.

Modell Validation

Am Ende des Trainings hat das Modell alle Worttoken (siehe Kapitel Preprocessing) im Vektorraum als Vektoren dargestellt (siehe Seite 11).

Über das Netzwerk, welches die Vektoren bilden, kann der semantische Zusammenhang zwischen den Wörtern errechnet werden.

In den Abbildungen 7 und 8 sind alle Token der 300 Dimensionen neuronalen Netzwerken auf zwei Dimensionen gefaltet und die Isoquanten der Wortvektordichte im Raum für „weibliche“ und „männliche“, Wortvektoren, welche für WEAT-Listen verwendet werden, in Grün und Rot hervorgehoben.

Diese Visualisierung des Vektorraums folgt der Idee präsentiert in [56], welche für diese Arbeit wie folgt angepasst wurden (siehe 3):

```
print_step("Calculate Frame Pole")
all_words = model_Schoolbooks.wv.index_to_key
```




Abbildung 6: Die Delta-Losses für die Top4 Testmodelle und das statisch ermittelte Modell für VerlagB; eigene Darstellung.

Der Vergleich der Entwicklung der Delta-Losses der verschiedenen Modelle. Man sieht, wie alle Modelle gegen einen Grenzwert an Delta-Losses streben. Die strichlierten Linien zeigten die durchschnittlichen Delta-Losses der letzten fünf Epochs des jeweiligen Modells. Im herausgehobenen Bereich ist sichtbar, dass das Modell mit statistisch ermittelten Hyperparametern die beste Performance zeigt.

```
fp_all = FramePole("all", all_words, model_Schoolbooks.wv)
fp_all.compute_centroid()

print_step("Reduce to two dimensions")
fitted_reducer =
    umap.UMAP(n_components=2,
              n_neighbors=15,
              min_dist=0.3,
              random_state=42).fit(fp_all.pole_vecs)

projection = fitted_reducer.transform(fp_all.pole_vecs)
x = projection[:, 0]
```

```
y = projection[:, 1]

plot_df = pd.DataFrame(projection, columns=["x", "y"])
plot_df['Gender'] = gender_identifier
plot_df['Token'] = model_Schoolbooks.wv.index_to_key

dict_color = {'female': "green",
              'male': "red",
              'word': "grey"}

options = ['female', 'male']
plot_df_only_gender =
    plot_df[plot_df['Gender'].isin(options)]

plt.figure(figsize=(5, 5))

sns.kdeplot(data=plot_df_only_gender,
            x="x", y="y",
            hue="Gender",
            levels=4,
            palette=dict_color,
            fill=True,
            alpha=.1
            )

ax = sns.scatterplot(
    data=plot_df, x="x", y="y",
    hue="Gender", hue_order=['female', 'male', 'word'],
    palette=dict_color,
    style="Gender",
    style_order=['female', 'male', 'word'],
    size="Gender",
    sizes={'female': 20, 'male': 20, 'word': 1},
    markers={'female': "P", 'male': "X", 'word': "o"},
```

```

        alpha=1
    )
    ...

```

Listing 3: Visualisierung; eigene Darstellung basierend auf [56]

Bei der Visualisierung sind keine Achsenbeschriftungen abgebildet, da die Achsen keine (für Menschen) interpretierbare Information enthält, sondern durch den Falt-Prozess entstanden sind. Auch wird kein Koordinatensystem angegeben, da das System ordinale ist. Das heißt, wenn der Abstand zwischen zwei Wortvektoren d ist, und der Abstand zu einem dritten Vektor $2 * d$ ist, kann der Zusammenhang der Wortvektoren nicht als halb so ähnlich interpretiert werden. Daher wäre ein kardinales Koordinatensystem eventuell irreführend.

Validation VerlagA

Wie in der Abbildung 7 zu sehen, bilden die Nomen der Geschlechter Wörter ein Cluster rechts am Rand der Wortvektoren-Wolke. Das einzige Adjektiv „weiblich“ hat einen großen Abstand zu den Nomen und befindet sich weit links in der Wolke. Es ist deutlich zu sehen, dass die Wortvektoren mehr als nur eine Information tragen (z. B. Wortart), sondern, wie erwartet, eine Vielzahl von Informationen beinhalten.

Die Information über die Geschlechter wird sichtbar, durch die unterschiedlichen Ausformungen der Isoquanten Flächen, der Dichte der Geschlechter-Wortvektoren. Die Ausreißer unter den Nomen (Schwester, Onkel und male_name) könnten durch die geringe Anzahl (72.852) an Worttoken im Text entstanden sein, und würden bei mehr Daten eventuell näher an die anderen Wortvektoren aus ihrer Geschlechtergruppe heranrücken/gravieren (siehe 11).

Durch das Trainieren des neuronalen Netzwerks mit den Daten von VerlagA und (Hyper-)Parametern aus Tabelle 13, ist ein Modell entstanden, welches die Worttoken, welche für die WEATs verwendet werden als semantisch zusammengehörend, aber für die beiden Geschlechter geringfügig unterschiedliche Dichte im gefalteten Netzwerk erzeugt. Somit ist eine Analyse mittels Wort-Kosinus-Ähnlichkeit (siehe Kapitel Test auf Kosinus-Ähnlichkeit) und WEAT (Word-Embeddings Assoziations




Abbildung 7: Die Wortvektoren des Modells für VerlaGA auf zwei Dimensionen gefaltet; eigene Darstellung. Die Abbildung hat keine Achsenbeschriftung, weil die Achsen keine interpretierbare Bedeutung haben. Bei den Interpretationen der Abstände zwischen den Wortrepräsentationen ist zu beachten, dass diese eine ordinale System bilden. Es gibt einen Cluster von Geschlechtern Token, mit vier Ausreißern, erstes das Wort weiblich als einziges Adjektiv, dass Nomen und Adjektive unterschiedlichen liegen, ist wenig überraschend. Zweitens Schwester, Onkel, male_name, diese Ausreißer dürften der geringen Datenmenge (nur 72.852 Token) geschuldet sein.



Abbildung 8: Die Wortvektoren des Modells für VerlagB auf zwei Dimensionen gefaltet, eigene Darstellung. Die Abbildung hat keine Achsenbeschriftung, weil die Achsen keine interpretierbare Bedeutung haben. Bei den Interpretationen der Abstände zwischen den Wortrepräsentationen ist zu beachten, dass diese eine ordinale System bilden. Es gibt einen eindeutigen Cluster von Geschlechtern Token, und die beiden Eigenschaftswörtern, „weiblich“ und „männlich“, etwas außerhalb vom liegen Vektoren für die Worttoken „Sohn“ und „Mann“

Test) möglich, für den VerlagA.

Validation VerlagB

Die Abbildung 8 bildet die Vektoren für die Worttoken des VerlagB ab, von 300 Dimensionen auf zwei gefaltet. Wie auch beim VerlagA bildet sich ein Cluster der Geschlechter Nomen, die beiden Adjektive („weiblich“ und „männlich“) befinden sich oben und rechts von den Nomen der Geschlechterworttoken. Die ausgewählten Worttoken, mit Geschlechter Bedeutung, haben ihre Wortvektoren alle links unten in der Vektoren-Wolke. Wie bei VerlagA sind die Geschlechterwortvektoren in einem Cluster beisammen, aber die Isoquanten der Häufigkeit der Wörter für die beiden Geschlechter ist unterschiedlich.

Die Ausreißer unter den Nomen könnten durch die geringe Anzahl (170.597) an

Worttoken im Text entstanden sein, und würden bei mehr Daten eventuell näher an die anderen Wortvektoren aus ihrer Geschlechtergruppe heranrücken/gravieren (siehe 11).

Der Cluster im Wortvektorraum zeigt, dass die vorausgewählten weiblichen und männlichen Token für die Experimente semantisch ähnlich sind (was zu erwarten ist, da sie Geschlechtsinformationen transportieren), und die Dichte der Verteilung nach Geschlechtern zeigt, dass „weiblich“ und „männlich“, unterschiedliche Bedeutungen haben. Somit ist eine Analyse mittels Wort-Kosinus-Ähnlichkeit (siehe Kapitel Test auf Kosinus-Ähnlichkeit) und WEAT (Word-Embeddings Assoziations Test) möglich, für den VerlagB.

Modelle für die Experimente

	VerlagA	VerlagB
Wortschatz	4.166	5013
Anzahl der Token	72.852	170.597
Epochs	95	90
Mindestworthäufigkeit	3	5
Fenstergröße	1	1
Vektorgöße	300	300
Negativ Sample	1	1

Tabelle 13: Zusammenfassung der Modelle für die Experimente

Ergebnisse

Erste Ergebnisse über mögliche Gender-Biases können schon im Preprocessing gewonnen werden, wie die Anzahl der Nennungen der weiblichen und männlichen Vornamen.

Für semantische Analysen werden die erstellten Modelle genutzt.

Ergebnisse aus dem Preprocessing

Für beide Verlage gilt, dass in beiden Deutschbuch-Serien für die Mittelschule männliche Vornamen deutlich häufiger vorkommen als weibliche (siehe Tabelle 14). Ein Gender-Bias durch unterschiedliche Repräsentation scheint gegeben zu sein.

Geschlechter Repräsentanz nach Vornamen

	weiblich	neutral	männlich
VerlagA	438 (42,36 %)	11 (1,06 %)	585 (56,58 %)
VerlagB	1.427 (38,71 %)	103 (2,79 %)	2.156 (58,49 %)

Tabelle 14: Die Anzahl der Vornamen je Geschlecht, welche durch einen passenden Token ersetzt wurden, und ihre jeweilige Prozentzahl an den gesamten Vornamen Nennungen.

Aber selbst unter der Annahme, alle neutralen Namen aus Tabelle 14 wären weibliche Vornamen, bleibt ein deutlicher Repräsentationen-Gender-Bias (siehe Tabelle 15).

Geschlechter Repräsentanz nach Vornamen

	weiblich	männlich
VerlagA	449 (43,42 %)	585 (56,58 %)
VerlagB	1.530 (41,51 %)	2.156 (58,49 %)

Tabelle 15: Die Anzahl der Vornamen je Geschlecht, unter der sicherlich falschen Annahme alle genderneutrale Vornamen würden weibliche Personen bezeichnen, und ihre jeweilige Prozentzahl an den gesamten Vornamen Nennungen.

Aus den Abbildungen 10 bis 14 sieht man zwei Dinge:

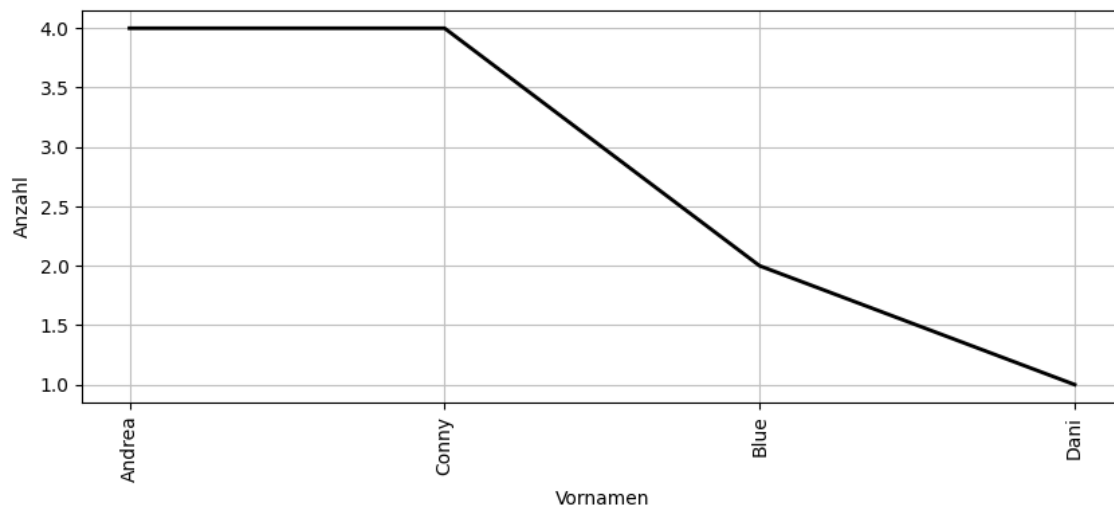


Abbildung 9: VerlagA: Die häufigsten genderneutralen Vornamen; eigene Darstellung




Abbildung 10: VerlagA: Die häufigsten weiblichen Vornamen; eigene Darstellung

- Es gibt ein klares Gefälle vom häufigsten zu den weniger häufigen Namen, eine gleichmäßige Verwendung von Namen scheint bei beiden Verlagen kein Ziel zu sein.
- In den Top 30 Namen gibt es bei beiden Verlagen Wiederholungen (u. a. Till, Anna, sind bei beiden der häufigste Name), aber auch Unterschiede, die auf regionale Gewohnheiten der Autor:Innen hinweisen könnten.

Interessant ist auch, dass bei VerlagA die Top 3 weiblichen Namen (Anna, Wiebke,




Abbildung 11: VerlagA: Die häufigsten männlichen Vornamen; eigene Darstellung




Abbildung 12: VerlagB: Die häufigsten genderneutralen Vornamen; eigene Darstellung

Tina) knapp beisammen sind, während die männlichen schon zwischen den Top 3 einen deutlichen Häufigkeitsabfall gibt.

Bei VerlagB ist es genau umgekehrt, bei den männlichen Namen sind die Top 6 (Till, Lukas, Mats, Max, Peter, Felix) ähnlich häufig, während zwischen den Top2 (Anna und Lisa) schon ein deutlicher Unterschied besteht.

Grundsätzlich dürfte der Versuch gemacht werden, möglichst viele Schüler:innen durch verschiedene Namen anzusprechen (siehe Tabelle 16), aber die Häufigkeit ei-




Abbildung 13: VerlagB: Die häufigsten weiblichen Vornamen; eigene Darstellung

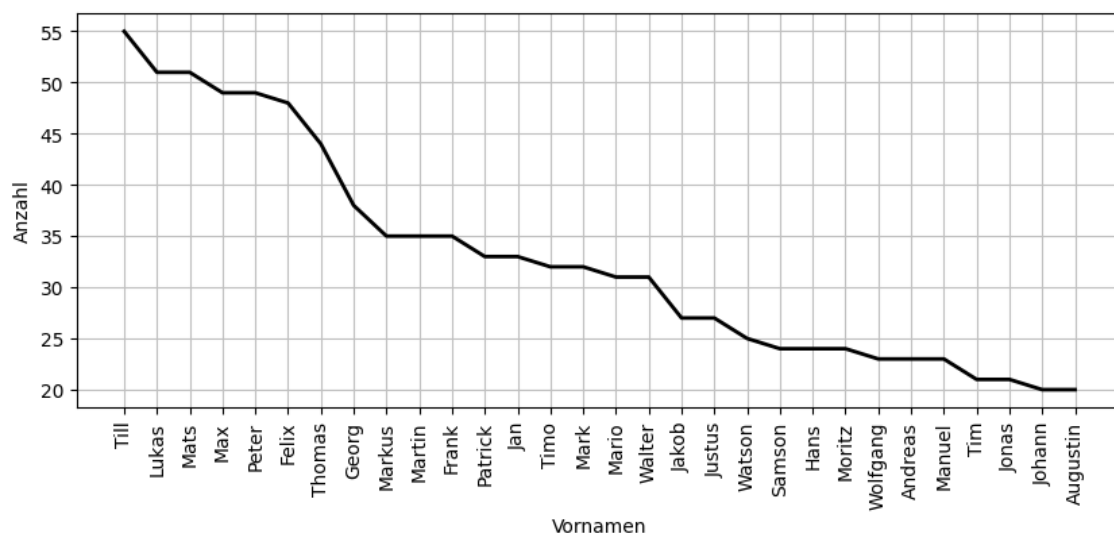


Abbildung 14: VerlagB, die häufigsten männliche Vornamen; eigene Darstellung

Absolute Zahlen der Vornamen nach Geschlecht

	Unterschiedliche Vornamen		
	weiblich	neutral	männlich
VerlagA	89	4	130
VerlagB	267	21	317

Tabelle 16: Unterschiedliche Vornamen, verwendet bei den Verlagen

niger weniger Namen zeigt, dass es kein zentrales Anliegen sein dürfte.

Ergebnisse aus dem Modell

Die Experimente, welche durch die Modelle ermöglicht werden, werden mit der Methode `Word2Vec.wv.similarity(Token, Token)` aus der Gensim Library durch geführt:

- Die Vektorähnlichkeit (siehe Seite 12) zwischen einem Token (=Beruf) und den Geschlechter-Worttoken aus der WEAT-Liste. Diese Methode wird verwendet, um herauszufinden, welche Berufe mit welchem Geschlecht korrelieren und ob eine Kosinus-Ähnlichkeit besteht.
- Der WEAT (siehe Seite 12) wird für die Worttoken aus den 16 Kategorien verwendet, siehe Kategorien Listen (Seite 75 und 76).

Kosinus-Ähnlichkeitstests VerlagA

Da die Schule den Grundstein für die weitere berufliche (Aus-)Bildung legt, ist die Darstellung von Berufen und ihren Geschlechtern besonders sensibel (siehe Tabelle 17). Auffällig ist, dass 49 Berufe stärker mit männlichen Wörtern korrelieren als mit weiblichen. Sieben von diesen Wörtern haben signifikante Kosinus-Ähnlichkeit (mehr als 0,17 nach Abbildung 4 nach Zusammenhang: Kosinus und Wort-Ähnlichkeit), bei den weiblich korrelieren ist es kein einziges Wort. Interessant ist die Gegenüberstellung von Meister (-0.17) und Lehre (0.13), und, dass sogar Berufe, die bei den beliebtesten Lehrberufen bei weiblichen Personen (Orange markiert in der Tabelle 17) eine Tendenz zu männlichen Wörtern besteht.

VerlagA: Ausgewählte Berufe

Beruf	Gendergap
Feuerwehrmann	-0.212
Dichter	-0.199
König	-0.196
Forscher	-0.188
Inspektor	-0.188

– Fortsetzung nächste Seite –

– Fortsetzung: Ausgewählte Berufe VerlagA

Beruf	Gendergap
Meister	-0.175
Ordensbruder	-0.171
Wirt	-0.134
Maurer	-0.106
Kaufmann	-0.089
Friseur	-0.086
Köchin	-0.056
Maurerin	0.007

Tabelle 17: VerlagA: Auswahl Berufe aus Tabelle 28.
Negative Werte zeigen eine Bias zu Männern, positive Werte eine Bias zu Frauen. TOP10 der beliebtesten Lehrberufe für *Frau*, *Männer* und beide Geschlechter, Quelle: [2]

Kosinus-Ähnlichkeitstests VerlagB

Auch für den VerlagB wurden die Genderbiases für die Berufe berechnet, ihr sind die 32 von 46 Berufen mit Tendenz zu weiblichen Wörtern, allerdings liegen alle Genderbiases zwischen -0.17 und 0.17. Also liegt keine Kosinus-Ähnlichkeit zu Geschlechtern vor (siehe Tabelle 18).

VerlagB: Ausgewählte Berufe

Beruf	Gendergap
Händler	-0.064
Apotheker	-0.037
Verkäufer	0.036
Kaufmann	0.042
Assistentin	0.063
Zimmermann	0.076

Tabelle 18: VerlagB: Auswahl Berufe aus Tabelle 29.
Negative Werte zeigen eine Bias zu Männern, positive Werte eine Bias zu Frauen. TOP10 der beliebtesten Lehrberufe für *Frau*, *Männer* und beide Geschlechter, Quelle: [2]

WEAT VerlagA

Für den VerlagA gibt es in vier der 15 WEAT X, Y Kategorien einen statistisch signifikanten Gender-Bias.

Anhand der WEAT (siehe Tabelle 19) werden weibliche Personen im VerlagA dargestellt als angenehm, leise spielend, mit Mädchenspielzeug, aber stark (alle mit großem Effekt). Für männliche Personen gilt der gegenteilige Fall, sie sind widerlich, schwach, laut wenn sie spielen mit ihrem Bubenspielzeug.

Zwar gibt es mit Mathematik-Kunst (weiblich), dominant-gehorsam (männlich) zwei Kategorien mit einem großen Cohen'd und mit Naturwissenschaft-Kunst (männlich), denk-fühlen (männlich), draußen-drinnen (männlich), männliche-weibliche Qualitäten (männlich) Kategorien mit mittlere Cohen'd und männlich-weiblich Sport eine mit kleinen Cohen'D, diese sind alle statistisch nicht signifikant.

Positiv fällt auf, dass Karriere und Familie von beiden Geschlechtern fast gleich besetzt wird (vergleiche Karriere und Familie in Schulbüchern aus Deutschland, Seite 7), dass weibliche und männliche Personen nur minimal unterschiedlich sind, was die Darstellung von Intelligenz und Äußerlichkeiten betrifft (Seite 6) und in einem Schulbuch besonders wichtig in denselben Schulfächern assoziiert werden (Seite 4).

WEAT VerlagB

Für den VerlagB sind nur zwei von den 16 WEAT statistisch signifikante Gender-Biases (siehe Tabelle 20). Die Kategorie männliche Sportarten werden von weiblichen Personen betrieben (großer Effekt) und dafür weibliche Sportarten von männlichen Personen, welche auch dominant sind, dafür sind weibliche Personen (großer Effekt) gehorsam.

Nicht statistisch signifikant, aber mit einem großen Cohen'D sind die männlichen, weiblichen Adjektive, Qualitäten und Berufe, wobei die letzten zwei es bei $\alpha = 10\%$ und 15% wären. Genauso wie männliche und weibliche Aktivitäten; diese haben aber nur einen mittleren Cohen'd-Effekt. Einen Mittleren Cohen'D-Effekt, hat ebenso denken-fühlen (männlich). Einen kleinen Effekt Karriere-Familie (weiblich), stärke-schwäche (männlich), draußen-drinnen (weiblich), männliches-weibliches Spielzeug (männlich) und männlich und weibliche Schulfächer (weiblich). Ausgewogen ist die geschlechtliche Darstellung für Mathematik-Kunst, Naturwissenschaft-Kunst und

VerlagA: WEAT Ergebnisse

Kategorie	p-Value	Cohens'd
pleasant vs. unpleasant	0.044	1.192
career vs. family	0.378	0.150
maths vs. arts	0.335	1.779
science vs. arts2	0.748	-0.651
thinking vs. feeling	0.771	-0.654
intelligent vs. appearance	0.470	0.043
strength vs. weakness	0.006	1.371
outdoor vs. indoor	0.868	-0.774
male vs. female toys	1.000	-2.102
male vs. female sports	0.667	-0.354
active vs. quiet games	0.972	-1.017
male vs. female adjectives	0.750	-0.717
male vs. female professions	NaN	NaN
male vs. female qualities	0.732	-0.524
dominant vs. obedient	0.800	-1.073
male vs. female subjects	0.567	-0.101

Tabelle 19: VerlagA: WEAT Ergebnisse
Graue Ergebnisse sind statistisch signifikant mit $\alpha < 0.05$.

Intelligenz-Erscheinung.

VerlagB: WEAT Ergebnisse

Kategorie	p-Value	Cohens'd
pleasant vs. unpleasant	0.428	0.100
career vs. family	0.279	0.428
maths vs. arts	0.571	-0.167
science vs. arts2	0.581	-0.066
thinking vs. feeling	0.773	-0.670
intelligent vs. appearance	0.554	-0.060
strength vs. weakness	0.758	-0.433
outdoor vs. indoor	0.246	0.418
male vs. female toys	0.738	-0.475
male vs. female sports	1.000	-1.862
active vs. quiet games	0.866	-0.672
male vs. female adjectives	0.336	0.944
male vs. female professions	0.935	-1.688
male vs. female qualities	0.892	-1.022
dominant vs. obedient	0.000	1.771
male vs. female subjects	0.287	0.355

Tabelle 20: VerlagB: WEAT Ergebnisse
Graue Ergebnisse sind statistisch signifikant mit $\alpha < 0.05$.

Schluss

Die Forschungshypothese, „kann in Texten österreichischer Schulbücher Genderbias festgestellt werden?“, können, durch die zugängliche Literatur, Aussagen getroffen werden.

Die aus den zugänglichen Daten erstellten Modelle wurden für diese speziellen Datensätze trainiert und sind daher auf diese limitiert, auch kann nicht ausgeschlossen werden, dass ein nicht getesteter Hyperparameter zu einem aussagekräftigeren Modell als die gewählten führt. Im Speziellen ein Negativ Sample von 0, da durch die Vornamen-Token diese in hoher Zahl im Modell Corpus präsent sind und eventuell zu häufig korrigiert werden.

Eine weitere Einschränkung kommt erneut aus der Methode der Vornamen-Token. Diese beruhen darauf, dass die Namen in der Quellenliste vorhanden sind. Ist dies nicht der Fall, werden diese nicht als solche erkannt und bleiben als eigener Token im Modell erhalten. Dies führt zu einer Verzerrung im jeweiligen Vornamen-Token.

Trotzdem bevorzuge ich diesen Ansatz gegenüber dem Ansatz, eine Auswahl von Vornamen für das WEAT zu verwenden, da diese einen noch stärkeren verzerrten Effekt haben würden. Ob die Vornamen-Token die Qualität der Modelle erhöhen, sollte in einer weiteren Benchmark-Studie geklärt werden. Interessant wäre auch, die Namen eventuell nach mehreren Merkmalen zu sortieren, wie es andere Autor:innen (z. B. James [39] für ihre WEAT nach Vorkommen in verschiedenen Weltregionen getan haben.

Die Idee für die Arbeit lieferte, die Frage, „ob unsere Schulsystemsexismus unterrichtet?“, kann nicht beantwortet werden. Es fehlen im Wesentlichen an Daten:

1. wie im Kapitel Daten beschrieben, ist der Zugang zur vollständigen Literatur nicht gegeben.
2. Selbst wenn dieser hoffentlich bald gegeben ist, wäre es notwendig zu wissen, welche Bücher in welchen Kombinationen und welche Kapitel genutzt werden.
3. Und selbst dann: die Schulbücher stellen zwar den „geheimen Lehrplan“ (siehe Seite 8) unserer Schulen dar, sind aber nicht die einzigen möglichen Quellen für Sexismus (siehe Seite 4) und ebenso kann nichts über Korrekturmechanismen außerhalb der Schulbücher ausgesagt werden.

Zumindest die Punkte 1 und 2 sollten in den nächsten Jahren durch die Digitalisierung der öffentlichen Verwaltung keine Herausforderung für zukünftige Arbeiten in diesem Bereich mehr darstellen. Der dritte Punkt müsste in einer umfangreichen Studie zur Beantwortung der Frage wahrscheinlich durch eine qualitative Studie zu quantitativen Schulbuchstudien ergänzt werden. „Ob unsere Schulsystemsexismus unterrichtet?“ musste daher als Forschungsfrage für diese Arbeit verworfen werden, und auf die zugängliche Schulbuchliteratur begrenzt werden.

Trotz dieser Einschränkung konnten Erkenntnisse über zugängliche Schulbuchliteratur gewonnen werden. Ob diese allgemeine Gültigkeit haben, lässt sich aber nicht feststellen. Allerdings stellen diese Arbeit aber einen Beitrag, zu erfahren, ob das vom Bundesministerium für Bildung, Wissenschaft und Forschung erklärte Bildungsziel, welches vorsieht, dass Schule alle Geschlechter fördert und deren Gleichberechtigung

durch die analysierte Literatur unterstützt oder unterlaufen wird.

Es zeigt sich in den Schulbüchern von VerlagA (56,58 %) wie auch von VerlagB (58,49 %) (siehe Tabelle 14) eine deutliche Über-Repräsentation von männlichen Vornamen. Das entspricht weder dem österreichischen Bevölkerungsverhältnis über alle Altersgruppen (49,22 %, [64], Stichtag 01.01.2021) noch dem der 10- bis 14-Jährigen (51,29 %, [63], Jahr 2021), also dem Mittelschulalter, für welches die Bücher geschrieben wurden.

Bei Statistik Austria sind derzeit fünf non-binäre Personen erfasst ([64], Stichtag 01.01.2021). Für Deutschland wird angenommen, dass Transgenderpersonen ca. 0,5 % bis 0,8 % der Bevölkerung ausmachen [53]. Das lässt vermuten, dass die Erfassung bei Statistik Austria nicht vollständig ist. Da es keine eindeutig genderneutralen Namen gibt, wäre es notwendig für eine semantische Analyse der Token in ihrem jeweiligen Kontext zu klären, ob sie eine weibliche, männliche oder Transgender-Person bezeichnen (siehe Seite 14). Zukünftige Studien in diesem Bereich sollten die Geschlechtervielfalt berücksichtigen, da bei einer durchschnittlichen Klassengröße von 25 Schüler:innen statistisch in jeder achten Klasse eine Schüler:in sitzt, die eine non-binäre Person ist.

Aus der Analyse des Modells kann ausgesagt werden, dass kaum Gender-Biases für die verschiedenen Kategorien der WEAT-Tests errechnet wurden; vier von 15 für das Modell von VerlagA und zwei von 16 für das Modell von dem VerlagB. Das zeigt zwar Handlungsbedarf in der Geschlechterdarstellung in den betroffenen Kategorien, aber keine insgesamt generell problematische Darstellung auf. Interessanterweise liegt man damit aber ungefähr auf dem Niveau der Kinderliteratur von 1800 bis 1925 der deutschsprachigen Gutenberg Sammlung (Gutenberg) und der von 1975 bis heute aus der Deutschen Nationalbibliothek (DNB) 21, was nicht ganz dem Anspruch des Leitmediums Schulbuch (siehe Seite 7) entsprechen sollte (siehe Tabelle 21).

Ergebnisse von Geißler zur deutschsprachigen Kinderliteratur

Kategorien	DNB	Gutenberg
career vs. family	0,729	1,349
maths vs. arts	-0,072	-1,036
science vs. arts	0,329	0,006
intelligence vs. appearance	-0,792	-0,615
strength vs. weakness	0,174	0,766
outdoor vs. indoor	-0,271	0,297
male vs. female toys	0,850	0,804
male vs. female sports	-0,473	-0,446
activ vs. quite games	0,520	0,139
male vs. female adjective	0,681	-0,068
male vs. female professions	NaN	1,251
male vs. female adjectives	-1,193	-0,991
dominant vs. obedient	-0,326	1,238

Tabelle 21: Ergebnisse der WEAT zur deutschen Kinderbuchliteratur, basierten auf Tabelle 9.5 von [20, S. 68]. **Fett** symbolisiert statistische Signifikanz auf p -Value $< 0,05$ für die jeweilige Kategorie

Bei der Darstellung der Berufe, welche aufgrund des möglichen Einflusses auf eine spätere Berufs- und Lehrstellenwahl (siehe Berufswahl 7) besonders interessant sind, dürfte durch den VerlagB keine Reproduktion von traditionellen Geschlechterrollen verstärkt werden und durch den VerlagA nur ein leichter Einfluss bestehen, da lediglich sechs abgefragte Berufe einen leichten Genderbias bei den Kosinus-Ähnlichkeitstests haben. Eine anschließende Forschungsfrage könnte sich mit der Frage beschäftigen, ob die Schule (und ihre Literatur) Einfluss auf die Berufswünsche und Entscheidungen für diese entsprechende Karriere anzustreben hat und ob dieser Effekt, wenn vorhanden, eine Gender-Bias-Komponente hat, durch die Leistungserwartung der Lehrkräfte (siehe Seite 4) und die Darstellung in Schulbüchern.

Zusammengefasst: Die Autor:innen-Teams der beiden Buchserien kommen dem Anspruch aus dem Bildungserlass (siehe Seite 4) sehr nahe, weisen jedoch noch einige Baustellen zur Verbesserung ihrer Buchserien in der Darstellung von Gender auf, **aber zu einem sexistischen Unterricht tragen beide Buchserien wahrscheinlich nicht bei.**

Literaturverzeichnis

- [1] Tom Aarsen u. a. *NLTK :: Natural Language Toolkit*. 2022. URL: <https://www.nltk.org/> (besucht am 3. Mai 2022).
- [5] C. Aschwanden. *The finkbeiner test: What matters in stories about women scientists*. 2013. URL: <https://web.archive.org/web/20130310035650/http://www.doublexscience.org/the-finkbeiner-test/> (besucht am 5. Mai 2022).
- [11] Melanie Bittner. *Schulbücher: Geschlechterbilder und Darstellung von Lesben, Schwulen, bisexuellen, trans* und inter* Menschen (LSBTI)*. Hrsg. von Lesben- und Schwulenverband. 2022. URL: <https://www.lsvd.de/de/ct/902-Schulbuecher-Geschlechterbilder-und-Darstellung-von-Lesben-Schwulen-bisexuellen-trans-und-inter-Menschen-LSBTI> (besucht am 6. März 2022).
- [12] Tolga Bolukbasi u. a. “Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings”. In: *Advances in Neural Information Processing Systems 29 (NIPS 2016)*. Hrsg. von D. Lee and M. Sugiyama and U. Luxburg and I. Guyon and R. Garnett. 2016. URL: <https://arxiv.org/pdf/1607.06520>.
- [13] Tolga Bolukbasi u. a. *Quantifying and Reducing Stereotypes in Word Embeddings*. arXiv, 2016. DOI: 10.48550/arXiv.1606.06121.
- [14] Bundesministerium für Bildung, Wissenschaft und Forschung. *Grundsatzertlass „Reflexive Geschlechterpädagogik und Gleichstellung“*. 2018. URL: https://www.bmbwf.gv.at/Themen/schule/schulrecht/rs/2018_21.html (besucht am 9. Feb. 2022).

- [15] Bundesministerium für Bildung, Wissenschaft und Forschung. *Schulbuchaktion*. Wien, 2022. URL: <https://www.bmbwf.gv.at/Themen/schule/schulpraxis/ugbm/schulbuchaktion.html> (besucht am 27. Apr. 2022).
- [16] Aylin Caliskan, Joanna J. Bryson und Arvind Narayanan. “Semantics derived automatically from language corpora contain human-like biases”. In: *Science (New York, N.Y.)* 356.6334 (2017), S. 183–186. DOI: 10.1126/science.aal4230. URL: https://purehost.bath.ac.uk/ws/files/168480066/CaliskanEtAl_authors_full.pdf.
- [17] Kaytlin Chaloner und Alfredo Maldonado. “Measuring Gender Bias in Word Embeddings across Domains and Discovering New Gender Bias Word Categories”. In: *Proceedings of the First Workshop on Gender Bias in Natural Language Processing* (2019), S. 25–32. DOI: 10.18653/v1/W19-3804. URL: <https://aclanthology.org/W19-3804/>.
- [18] J. Cohen. “Statistical power analysis for the behavioral”. In: *Sciences. Hillsdale (NJ): Lawrence Erlbaum Associates* (1988), S. 18–74.
- [19] Allan M. Collins und Elizabeth F. Loftus. “A spreading-activation theory of semantic processing”. In: *Psychological Review* 82.6 (1975), S. 407–428. ISSN: 0033-295X. DOI: 10.1037/0033-295x.82.6.407. URL: <http://dx.doi.org/10.1037/0033-295x.82.6.407>.
- [20] Dominique Geißler. “Gender Bias in English and German Children’s Literature: A Computational Analysis Using Word Embeddings”. Diss. Twente: Universität Twente, 2021. (Besucht am 17. Mai 2022).
- [21] Don Cowan. *Cosine Similarity*. San Francisco, 2022. URL: <https://www.ml-science.com/cosine-similarity> (besucht am 17. Mai 2022).
- [22] Doris Guggenberger. “Gender Mainstreaming: Eine Strategie zur Erreichung der Gleichstellung von Frauen und Männern”. In: *SCHUG* 13 (2002). URL: http://www.genderkompetenz.info/w/files/gkompzpdf/info_schule_bmbwk_oesterreich_2002.pdf (besucht am 9. Feb. 2022).
- [23] Martin Ebner und Sandra Schön. “Editorial zum Schwerpunktthema Wandel von Lern- und Lehrmaterialien”. In: *Bildungsforschung* 1.9 (2012), S. 1–10. URL: https://www.pedocs.de/frontdoor.php?source_opus=8305.

- [24] Ulrike Fichera. *Die Schulbuchdiskussion in der BRD - Beiträge zur Neugestaltung des Geschlechterverhältnisses: Bestandsaufnahme und Sekundäranalyse: Zugl.: Frankfurt (Main), Univ., Diss., 1995*. Bd. Bd. 670. Europäische Hochschulschriften Reihe 11, Pädagogik. Frankfurt am Main: Lang, 1996. ISBN: 3631491514.
- [26] Friederike Braun, Sabine Sczesny und Dagmar Stahlberg. “Das generische Maskulinum und die Alternativen: Empirische Studien zur Wirkung generischer Personenbezeichnungen im Deutschen”. In: *undefined* (2002). URL: <https://www.semanticscholar.org/paper/Das-generische-Maskulinum-und-die-Alternativen%3A-zur-Braun-Sczesny/2c8a8fa2ba58793bd8d50b553cc8cc740b843664>
- [27] Markus Frölich und Katharina Michaelowa. “Peer effects and textbooks in African primary education”. In: *Labour Economics* 18.4 (2011), S. 474–486. ISSN: 0927-5371. DOI: 10.1016/j.labeco.2010.11.008. URL: <http://dx.doi.org/10.1016/j.labeco.2010.11.008>.
- [28] Eckhardt Fuchs und Inga Niehaus. *Das Schulbuch in der Forschung: Analysen und Empfehlungen für die Bildungspraxis*. Bd. 4. Eckert. Expertise. Göttingen: V&R unipress, 2014. ISBN: 9783847103851.
- [29] Ute Gabriel u. a. *Au-pairs are rarely male: Role names’ gender stereotype information across three languages*. 2008. URL: <https://doc.rero.ch/record/209023>.
- [30] Peter Glick und Susan T. Fiske. “The Ambivalent Sexism Inventory: Differentiating hostile and benevolent sexism”. In: *Journal of Personality and Social Psychology* 70.3 (1996), S. 491–512. ISSN: 1939-1315. DOI: 10.1037/0022-3514.70.3.491. URL: <http://dx.doi.org/10.1037/0022-3514.70.3.491>.
- [31] Yoav Goldberg und Omer Levy. *word2vec Explained: deriving Mikolov et al.’s negative-sampling word-embedding method*. 2014. URL: <https://arxiv.org/pdf/1402.3722.pdf> (besucht am 28. Apr. 2022).
- [32] Hannelore Faulstich-Wieland. “Welchen Einfluss hat die Schule auf das Berufswahlverhalten von Mädchen und Jungen”. In: *Welche Rolle spielt das Geschlecht*. Hamburg: Behörde für Soziales und Familie Amt für Familie, Jugend und Sozialordnung Referat Gleichstellung, 2005, S. 12–26. URL: <https://>

- epub.sub.uni-hamburg.de/epub/volltexte/2009/2976/pdf/berufswahl.pdf (besucht am 8. März 2022).
- [34] Nelly Heer. “Innovation - Tradition - Praxistauglichkeit: Lehrmittelkonzeptionen und ihre Grenzen”. In: *Babylonia* 1 (2012), S. 8–11. URL: http://babylonia.ch/fileadmin/user_upload/documents/2012-1/Baby2012_1heer.pdf.
- [35] Peter Hegarty u. a. “When gentlemen are first and ladies are last: effects of gender stereotypes on the order of romantic partners’ names”. In: *The British journal of social psychology* 50.Pt 1 (2011), S. 21–35. ISSN: 0144-6665. DOI: 10.1348/014466610X486347.
- [36] Horst Prillinger. *Zeitschriftensaal Teinfaltstraße*. Hrsg. von Universität Wien, Bibliotheks- und Archivwesen. Wien, 2022. URL: <https://bibliothek.univie.ac.at/hauptbibliothek/en/teinfaltstrasse.html> (besucht am 27. Apr. 2022).
- [37] Ilse Bartosch. *UNDOING GENDER IM MNI-UNTERRICHT: Kurzfassung*. Wien, 2008. URL: https://www.imst.ac.at/imst-wiki/images/d/d2/Kurzfassung_Bartosch2008.pdf (besucht am 9. Feb. 2022).
- [38] Lisa Irmen, Daniel V. Holt und Matthias Weisbrod. “Effects of role typicality on processing person information in German: Evidence from an ERP study”. In: *Brain Research* 1353 (2010), S. 133–144. ISSN: 0006-8993. DOI: 10.1016/j.brainres.2010.07.018. URL: <https://www.sciencedirect.com/science/article/pii/S0006899310015805>.
- [39] H. L. James. *Compare embedding bias*. 2019. URL: <https://github.com/hljames/compare-embedding-bias/blob/master/configs/histwords.json> (besucht am 24. Mai 2022).
- [40] Judith Schneider. “Geschlechtergerechtes Deutsch: Gegenwärtige Sprachveränderungen im Deutschen”. In: *Das Wort. Germanistisches Jahrbuch Russland* (2018), S. 175–185. URL: https://wort.daad.ru/wort2017/12_Wort_Schneider_175_185.pdf (besucht am 8. März 2022).
- [41] Jürgen Oelkers. *Fachunterricht und Interdisziplinarität*. Collegium Helveticum, 2009. URL: <http://www.ife.uzh.ch/research/emeriti/oelkersjuergen/vortraegeprofoelkers/vortraege2009/collegiuimhelveticum.pdf>.

- [42] Koushik Varma Kalidindi. *Deconstructing Word Embeddings*. arXiv, 2019. DOI: 10.48550/arXiv.1902.00551.
- [43] Erika Kegyes. “Gender in den Sprachbüchern aus der Sicht der Feministischen Pädagogik”. In: *Theorie und Praxis von Pädagogik* 1.2 (2009), S. 3–10. URL: <http://www.irisro.org/theorieundpraxis/TPP-02.pdf#page=3> (besucht am 11. März 2022).
- [44] Maria Kuecken und Marie-Anne Valfort. “When do textbooks matter for achievement? Evidence from African primary schools”. In: *Economics Letters* 119.3 (2013), S. 311–315. ISSN: 0165-1765. DOI: 10.1016/j.econlet.2013.03.012. URL: <http://dx.doi.org/10.1016/j.econlet.2013.03.012>.
- [45] Mascha Kurpicz-Briki. “Cultural Differences in Bias? Origin and Gender Bias in Pre-Trained German and French Word Embeddings”. In: *5th SwissText & 16th KONVENS Joint Conference 2020*. Hrsg. von Mark Cieliebak und Martin Volk. Zürich: SwissText & Konvens, 2020. DOI: 10.24451/ARBOR.11922. URL: <https://arbor.bfh.ch/11922/> (besucht am 4. Mai 2022).
- [46] Molly Lewis und Gary Lupyan. “Gender stereotypes are reflected in the distributional structure of 25 languages”. In: *Nature Human Behaviour* 4.10 (2020), S. 1021–1028. ISSN: 2397-3374. DOI: 10.1038/s41562-020-0918-6. URL: <https://www.nature.com/articles/s41562-020-0918-6>.
- [47] Marlis Hellinger. “Empfehlungen für einen geschlechtergerechten Sprachgebrauch im Deutschen”. In: *Adam, Eva und die Sprache*. Hrsg. von Karin M. Eichhoff-Cyrus. Bd. Band 5. Dudenverlag, 2004, S. 275–291. URL: <http://gbv.eblib.com/patron/FullRecord.aspx?p=2079834>.
- [48] David E. Meyer und Roger W. Schvaneveldt. “Facilitation in recognizing pairs of words: Evidence of a dependence between retrieval operations”. In: *Journal of Experimental Psychology* 90.2 (1971), S. 227–234. ISSN: 0022-1015. DOI: 10.1037/h0031564. URL: <http://dx.doi.org/10.1037/h0031564>.
- [49] Tomas Mikolov u. a. “Efficient Estimation of Word Representations in Vector Space”. In: *arXiv preprint arXiv:1301.3781* (2013). URL: <https://arxiv.org/pdf/1301.3781>.

- [50] Franziska Moser, Bettina Hannover und Judith Becker. “Subtile und direkte Mechanismen der sozialen Konstruktion von Geschlecht in Schulbüchern: Vorstellung eines Kategoriensystems zur Analyse der Geschlechter(un)gerechtigkeit von Texten und Bildern”. In: *Gender : Zeitschrift für Geschlecht, Kultur und Gesellschaft* 5.3 (2013), S. 77–93. DOI: 10.7892/BORIS.79243.
- [51] Gerhard Nagy. *Geschlechteraspekte in der schulischen Leistungsbewertung*. Linz, 2011. URL: <https://www.transcript-verlag.de/media/pdf/89/78/5c/oa9783839403242DvKaCUbCvnNVw.pdf> (besucht am 9. Feb. 2022).
- [52] Christine Ott. “Geschlechterstereotypen auf der Spur: Ein Plädoyer für mehr Linguistik in der Bildungsforschung,” in: *Bildung und Differenz*. Hrsg. von Carola Groppe, Gerhard Kluchert und Eva Matthes. Wiesbaden: Springer VS, 2016, S. 161–183.
- [53] Petra Weitzel, Alexander Regh und Sandra Wißgott. *Zahlenspiele*. 2022. URL: <https://dgti.org/2021/08/12/zahlenspiele/> (besucht am 6. Mai 2022).
- [54] Python Software Foundation. *codecs: Codec registry and base classes: Python 3.10.4 documentation*. 2022. URL: <https://docs.python.org/3/library/codecs.html> (besucht am 5. März 2022).
- [55] Radim Řehůřek und Petr Sojka. “Software Framework for Topic Modelling with Large Corpora”. In: *Proceedings of the LREC 2010 Workshop on New*. Hrsg. von Radim Řehůřek and Petr Sojka. Valletta, Malta: ELRA, 2010, S. 45–50.
- [56] Markus Reiter-Haas, Simone Kopeinik und Elisabeth Lex. “Studying Moral-based Differences in the Framing of Political Tweets”. In: *Proceedings of the International AAAI Conference on Web and Social Media*. Bd. 15. 2021, S. 1085–1089.
- [57] RIS. *Familienlastenausgleichsgesetz 1967 §31*. 2022. URL: <https://www.ris.bka.gv.at/GeltendeFassung.wxe?Abfrage=Bundesnormen&Gesetzesnummer=10008220> (besucht am 13. März 2022).
- [58] RIS. *Gutachterkommissionen zur Eignungserklärung von Unterrichtsmitteln*. 2022. URL: <https://www.ris.bka.gv.at/GeltendeFassung.wxe?Abfrage=Bundesnormen&Gesetzesnummer=10009918> (besucht am 13. März 2022).

- [59] Xin Rong. “word2vec Parameter Learning Explained”. In: *arXiv preprint arXiv:1411.2738* (2014). URL: <https://arxiv.org/pdf/1411.2738>.
- [60] Sandra Schön u. a. “Mögliche Wege zum Schulbuch als Open Educational Resources (OER). Eine Machbarkeitsstudie zu OER-Schulbüchern in Österreich”. In: *InnovationLab Arbeitsberichte* 7 (2017). URL: https://www.salzburgresearch.at/wp-content/uploads/2017/11/machbarkeitsstudie_submission_final.compressed.pdf.
- [61] Sora & AK Wien. *AK-Schulkostenstudie 2020/21 Factsheet Wien*. 2021. URL: https://wien.arbeiterkammer.at/service/presse/Schulkostenstudie_Factsheet_Wien.pdf (besucht am 13. März 2022).
- [62] Dagmar Stahlberg und Sabine Sczesny. “Effekte des generischen Maskulinums und alternativer Sprachformen auf den gedanklichen Einbezug von Frauen”. In: *Psychologische Rundschau* 52.3 (2001), S. 131–140. ISSN: 0033-3042. DOI: 10.1026//0033-3042.52.3.131. URL: <http://dx.doi.org/10.1026//0033-3042.52.3.131>.
- [66] Uni-Wien-Bib-Hotline. *E-Book in der Schulbuchsammlung: Telefonat*. Hrsg. von Hotline (01 427715160) Universität Wien - Zeitschriftensaal Teinfaltstraße in Wien. 21. Feb. 2022.
- [69] Gernot Vlaj. *Das OER-Schulbuch*. Bd. 8. Beiträge zu offenen Bildungsressourcen. Norderstedt: Books on Demand, 2014. ISBN: 9783735721518. URL: https://o3r.eu/images/band8_Schulbuch.pdf.
- [72] Walter Kissling. “Ankündigung des Proseminars „Österreichische Bibliotheken und Archive bildungswissenschaftlicher Relevanz I: Die Schulbücher- und Schulschriftensammlung des BMBWK in Geschichte und Gegenwart“: (WS 2006/07)1”. In: *Die Schulbücher- und Schulschriftensammlung des BMUKK als pädagogische Quellensammlung*. Hrsg. von Walter Kissling. Wien: Universität Wien, 2007, S. 1–3. URL: https://www.univie.ac.at/bildungswissenschaft/pb/pdf/Schulbuecher_kl_Katalog.pdf (besucht am 27. Apr. 2022).
- [73] Christian Wartena. *A Probabilistic Morphology Model for German Lemmatization*. 2019. DOI: 10.25968/opus-1527. (Besucht am 4. Mai 2022).
- [74] Christian Wartena. *Preprocessing*. 2020. URL: <https://textmining.wp.hs-hannover.de/Preprocessing.html> (besucht am 3. Mai 2022).

- [75] Candace West und Don H. Zimmerman. “Doing Gender”. In: *Gender and Society* 1.2 (1987), S. 125–151. ISSN: 08912432. URL: <http://www.jstor.org/stable/189945>.
- [76] Yusuke Shinyama, Philippe Guglielmetti und Pieter Marsman. *pdfminer.six*. 2019. URL: <https://pdfminersix.readthedocs.io/en/latest/index.html> (besucht am 3. Mai 2022).
- [77] Pei Zhou u. a. *Examining Gender Bias in Languages with Grammatical Gender*. arXiv, 2019. DOI: 10.48550/arXiv.1909.02224.

Quellenverzeichnis

- [2] AMS. *Arbeitsmarktprofile 2021 Österreich*. 2022. URL: http://www.arbeitsmarktprofile.at/teil_06.html (besucht am 25. Mai 2022).
- [3] Thomas Arni. *Leonie.io - Deine Vornamen-Expertin*. 2022. URL: <http://www.leonie.io/>.
- [4] Thomas Arni. *Vorname Kawai - Bedeutung, Herkunft, Populärität | Deutschland*. 2022. URL: <http://www.leonie.io/de/vornamen/Kawai> (besucht am 4. Mai 2022).
- [6] Baby-Vornamen.de. *Baby-Vornamen.de: 50.000+ Namen mit Bedeutung & Beliebtheit*. 2022. URL: <https://www.baby-vornamen.de/> (besucht am 4. Mai 2022).
- [7] BabyCenter. *BabyCenter Homepage: Alles über Kinderwunsch, Schwangerschaft, Geburt, Neugeborene, Babys und Kinder*. 2022. URL: <https://www.babycenter.de/> (besucht am 4. Mai 2022).
- [8] Babynames.com. *Baby Names and Meanings at BabyNames.com*. 2022. URL: <https://babynames.com/> (besucht am 4. Mai 2022).
- [9] Babynamesmeaningz.com. *Baby Names And Meanings*. 2022. URL: <https://babynamemeaningz.com/> (besucht am 4. Mai 2022).
- [10] Becky Anders. *Baby Names, Boy Names, Girl Names and Meanings - The Name Meaning*. 2022. URL: <https://www.thenamemeaning.com/> (besucht am 4. Mai 2022).
- [25] firstname.de. *Vornamen - Lexikon - firstname.de*. 2022. URL: <https://www.firstname.de/> (besucht am 4. Mai 2022).
- [33] hawaiiurlaub. *Hawaii Urlaub - individuell - Tipp - Hawaiiurlaub.de*. 2022. URL: <https://www.hawaiiurlaub.de/> (besucht am 4. Mai 2022).

- [63] Statistik Austria. *Bevölkerung zu Jahresbeginn 2002-2022 nach fünfjährigen Altersgruppen und Geschlecht*. 2022. URL: https://www.statistik.at/web_de/statistiken/menschen_und_gesellschaft/bevoelkerung/bevoelkerungsstruktur/bevoelkerung_nach_alter_geschlecht/index.html (besucht am 14. Mai 2022).
- [64] Statistik Austria. *Bevölkerung zu Quartalsbeginn seit 2020 nach detailliertem Geschlecht*. 2022. URL: https://www.statistik.at/web_de/statistiken/menschen_und_gesellschaft/bevoelkerung/bevoelkerungsstruktur/bevoelkerung_nach_alter_geschlecht/126498.html (besucht am 14. Mai 2022).
- [65] Rachael Tatman. *Stopword Lists for 19 Languages: german*. 2017. URL: <https://www.kaggle.com/datasets/rtatman/stopword-lists-for-19-languages> (besucht am 5. März 2022).
- [67] Vita 34. *NAMENSLISTE VORNAMEN FÜR JUNGEN*. 2022. URL: <https://www.vita34.at/namenslisten/vornamen-fuer-jungen/> (besucht am 18. Feb. 2022).
- [68] Vita 34. *NAMENSLISTE VORNAMEN FÜR MÄDCHEN*. 2022. URL: <https://www.vita34.at/namenslisten/vornamen-fuer-maedchen/> (besucht am 18. Feb. 2022).
- [70] vorname.com. *Alles zu Vornamen und Babynamen mit Namensbedeutung*. 2022. URL: <https://www.vorname.com/> (besucht am 4. Mai 2022).
- [71] Vornamen.blog. *Vornamen.blog | Beliebte Vornamen, Babynamen und Kindernamen*. 2022. URL: <https://vornamen.blog/> (besucht am 4. Mai 2022).

Anhang

Anhang A: Tabellen

VerlagA: Anzahl der Wörter je WEAT Zielgruppenwörter nach Mindestwort

	1	2	3	4	5	6	7	8	9	10
female list	7	6	6	6	5	5	5	5	5	5
male list	7	6	6	6	6	6	6	6	6	6
pleasant	6	6	6	6	6	5	5	5	5	4
unpleasant	7	4	4	3	3	3	2	2	2	2
career	5	3	2	1	1	1	1	1	1	1
family	6	6	5	5	4	4	4	4	4	4
maths	4	2	2	1	1	1	1	1	1	1
arts	4	2	1	0	0	0	0	0	0	0
science	5	4	3	3	2	2	2	2	1	1
arts2	4	2	1	0	0	0	0	0	0	0
thinking	4	4	4	4	4	3	3	3	3	3
feeling	3	3	3	3	3	2	2	2	2	2
intelligent	10	8	8	7	7	5	4	4	4	4
appearance	20	16	13	12	10	9	9	7	6	6
strength	12	9	7	6	6	6	6	6	6	6
weakness	9	7	6	5	5	5	5	5	5	3
outdoor	7	7	7	7	6	6	6	5	5	3
indoor	6	4	3	2	1	1	1	1	1	1
male toys	8	8	8	6	5	4	4	4	3	3
female toys	4	2	2	1	1	0	0	0	0	0
male sports	4	4	2	2	2	1	1	0	0	0
female sports	4	2	2	1	1	1	1	1	1	1
active games	8	8	8	8	8	8	8	7	7	7
silent games	7	7	6	6	6	6	6	6	6	5
male adjectives	4	4	1	1	0	0	0	0	0	0
female adjectives	3	3	3	3	2	2	2	2	1	1

– Fortsetzung nächste Seite –

– Fortsetzung: Mindestwortanzahl Modell A –

	1	2	3	4	5	6	7	8	9	10
male professions	4	1	0	0	0	0	0	0	0	0
female professions	5	5	4	4	3	3	3	3	3	3
male qualities	7	6	5	5	4	3	3	2	1	1
female qualities	4	3	3	2	2	2	2	2	2	2
dominant	3	2	2	2	2	1	1	1	1	1
obedient	5	4	3	2	2	2	2	2	2	2
male subjects	6	6	6	4	3	3	2	2	1	1
female subjects	7	7	6	6	5	4	4	4	2	2

Tabelle 22: VerlagA: WEAT-Zielgruppen Worthäufigkeit vom verschiedenen Minima Wortanzahl

VerlagB: Anzahl der Wörter je WEAT Zielgruppenwörter nach Mindestwort Anzahl

	1	2	3	4	5	6	7	8	9	10
female list	7	7	7	7	7	7	7	7	6	6
male list	7	7	7	7	7	7	7	7	7	6
pleasant	6	6	5	5	5	5	5	5	5	5
unpleasent	7	7	6	5	5	5	4	4	4	4
career	7	5	4	4	4	3	3	3	3	3
family	7	7	7	7	6	6	6	6	6	6
maths	5	2	2	2	2	2	2	2	2	2
arts	8	7	6	5	5	5	2	1	1	0
science	6	5	5	4	4	4	4	1	1	1
arts2	8	6	5	4	4	4	2	1	1	0
thinking	5	5	5	4	4	4	4	4	4	4
feeling	3	3	3	3	3	3	3	3	3	3
intelligent	15	12	9	9	9	8	7	7	6	5
appearance	20	16	16	16	11	11	11	11	11	11
strength	12	12	12	11	10	8	8	8	8	7
weakness	12	11	10	7	4	4	4	4	4	3

– Fortsetzung nächste Seite –

– Fortsetzung: Mindestwortanzahl Modell B –

	1	2	3	4	5	6	7	8	9	10
outdoor	7	7	7	7	7	7	6	6	6	6
indoor	7	6	6	6	6	5	4	4	3	3
male toys	8	8	8	8	8	7	6	6	6	6
female toys	7	6	6	5	3	3	3	2	2	2
male sports	6	5	5	4	3	2	2	2	2	2
female sports	5	4	3	3	2	2	2	1	1	1
active games	8	8	8	8	7	7	7	7	7	7
silent games	6	6	6	6	6	6	6	6	6	6
male adjectives	4	4	3	2	2	2	2	2	2	2
female adjectives	5	5	4	4	4	4	4	4	2	2
male professions	5	5	2	2	2	2	0	0	0	0
female professions	6	5	5	4	4	4	4	4	4	4
male qualities	7	6	5	5	5	5	5	5	5	5
female qualities	6	5	5	3	3	2	2	2	2	2
dominant	4	3	3	3	2	1	1	1	1	1
obedient	6	5	4	4	4	3	3	3	3	3
male subjects	6	6	6	6	6	6	6	4	3	3
female subjects	7	7	7	7	6	6	6	6	6	5

Tabelle 23: VerlagB: WEAT-Zielgruppen Worthäufigkeit vom verschiedenen Minima Wortanzahl

VerlagA: Trainierte Modelle

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
36	100	2	1	200	3	11.216,565
198	95	2	2	300	3	11.347,876
186	100	1	13	300	3	11.378,045
114	95	3	3	300	2	11.410,540
122	90	2	3	50	1	11.554,730
95	95	2	13	100	3	11.593,487
5	100	2	5	100	3	12.051,948
81	100	2	3	100	2	12.126,009
87	95	3	5	100	1	12.235,165
187	85	3	3	200	3	12.348,416
76	85	2	5	50	2	12.348,426
125	95	1	5	50	1	12.609,919
94	80	3	2	400	2	12.618,520
40	100	2	1	400	1	12.681,438
146	75	3	2	200	2	12.698,721
151	85	2	8	400	1	13.040,921
139	95	1	8	500	1	13.084,146
108	90	3	1	200	1	13.115,931
175	100	3	2	25	1	13.146,623
39	90	2	2	300	3	13.180,859
59	70	3	1	300	2	13.269,960
22	95	2	5	100	1	13.279,440
134	85	3	3	200	3	13.374,842
158	100	3	1	25	1	13.529,202
168	95	1	2	50	1	13.649,695
169	90	3	2	500	5	13.697,829
57	90	3	1	500	5	13.722,183
137	70	3	2	50	2	13.838,821
138	100	3	8	300	5	14.211,257
190	85	3	5	500	2	14.492,076

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagA –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
170	65	3	13	400	1	14.575,111
107	100	2	1	500	8	14.808,220
101	80	3	1	100	3	14.853,312
60	80	2	8	25	1	15.120,236
131	100	1	8	50	5	15.125,227
73	80	2	8	300	2	15.189,919
181	90	1	8	500	1	15.233,008
156	100	3	3	100	5	15.356,183
74	85	1	5	500	1	15.426,904
49	95	2	2	200	1	15.441,569
121	90	2	1	400	1	15.498,875
199	95	2	3	400	2	15.572,966
192	100	1	5	300	5	15.581,342
144	65	3	2	50	3	15.642,261
44	95	2	8	200	8	15.734,478
120	85	1	2	100	5	15.753,135
149	95	1	8	400	3	15.753,774
33	95	2	8	25	2	15.818,330
123	70	2	5	200	1	15.888,695
41	60	3	8	50	1	15.893,903
1	90	2	5	400	1	15.950,354
174	70	3	1	100	8	15.994,516
86	70	3	13	100	5	16.121,824
173	70	3	1	200	5	16.135,567
0	70	1	3	25	1	16.193,859
25	85	2	5	300	2	16.222,318
52	70	3	13	500	2	16.251,000
143	90	2	5	400	3	16.260,849
85	65	3	8	200	1	16.488,098
185	65	3	8	200	2	16.560,693
97	65	3	8	300	5	16.561,595

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagA –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
132	90	1	1	100	5	16.642,382
96	80	2	1	400	1	16.677,144
51	90	3	5	400	5	16.775,211
145	95	1	8	50	5	16.779,388
191	90	1	2	200	5	17.026,695
61	100	3	8	500	8	17.083,745
117	70	2	13	200	2	17.222,414
89	75	2	13	200	5	17.339,151
48	95	2	3	500	8	17.371,080
178	60	3	1	300	2	17.467,736
54	65	1	13	300	1	17.574,775
15	100	1	1	200	1	17.724,174
163	70	3	8	50	5	17.725,912
147	75	3	1	500	5	17.740,818
155	85	2	13	500	8	17.806,209
53	95	1	1	300	5	17.824,533
45	80	2	2	400	8	17.903,723
13	70	3	3	500	3	18.000,360
128	90	2	8	400	8	18.036,933
55	70	3	1	400	8	18.098,471
63	85	2	3	500	2	18.172,880
7	75	3	8	300	5	18.253,979
10	95	2	3	300	8	18.310,890
105	80	2	5	200	5	18.392,959
164	65	3	3	500	3	18.428,411
8	85	1	2	300	3	18.448,302
150	85	3	1	100	13	18.544,989
67	80	3	13	300	8	18.640,686
58	80	2	2	100	3	18.681,275
43	70	3	13	50	5	18.798,055
90	100	2	8	300	8	18.944,109

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagA –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
112	90	3	2	25	3	18.948,402
165	90	1	13	500	2	19.112,827
179	95	3	3	500	8	19.115,312
154	75	2	8	100	5	19.150,766
14	75	1	3	50	3	19.154,459
4	60	1	3	25	1	19.337,754
78	60	3	1	100	1	19.441,834
206	90	1	3	500	2	19.536,306
115	85	1	3	200	1	19.633,579
34	80	1	8	25	2	19.665,386
177	85	1	13	50	5	19.683,029
130	65	3	13	500	5	19.833,759
32	90	1	1	400	8	19.909,813
20	90	3	2	300	13	19.984,936
6	55	3	3	400	2	20.020,668
11	55	3	2	300	1	20.039,748
172	80	1	13	50	3	20.078,927
109	80	1	2	50	2	20.176,529
182	75	2	13	500	8	20.278,262
83	75	2	5	500	2	20.300,034
207	75	2	3	50	5	20.322,904
183	75	1	1	400	1	20.418,184
193	85	1	1	400	3	20.442,787
46	100	1	5	100	13	20.463,650
194	65	3	13	100	8	20.487,787
77	60	2	5	100	1	20.550,517
71	65	2	8	25	2	20.567,898
142	75	2	1	500	2	20.707,707
82	85	2	8	100	8	20.746,343
116	55	3	13	100	5	20.812,521
113	85	1	13	400	13	20.919,013

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagA –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
196	65	1	13	200	3	21.014,348
140	60	2	8	300	3	21.069,346
189	75	1	2	200	3	21.078,094
126	65	2	2	300	8	21.111,479
176	80	1	2	300	3	21.157,215
98	75	1	3	400	3	21.490,043
93	60	1	8	25	1	21.516,518
159	55	3	3	50	2	21.633,257
70	65	2	3	100	2	21.739,129
208	65	2	2	300	3	21.867,140
79	55	3	8	25	3	22.053,696
184	75	2	13	300	8	22.159,870
205	80	2	2	300	13	22.261,680
12	95	1	3	300	13	22.436,543
102	70	1	1	500	1	22.439,273
195	80	1	1	25	1	22.453,559
29	80	2	5	400	8	22.454,104
30	60	3	1	400	8	22.601,116
80	80	3	5	400	13	22.659,997
9	90	2	5	25	5	22.756,252
65	65	2	1	25	3	22.845,293
38	80	1	2	100	2	22.861,527
62	55	3	1	400	5	22.971,516
2	70	3	5	100	8	23.080,238
27	65	2	13	500	2	23.143,697
91	80	2	8	200	13	23.255,039
28	80	3	13	500	13	23.392,171
75	60	3	8	200	5	23.510,464
103	95	1	13	50	13	23.858,482
106	55	2	2	500	2	23.915,673
23	100	1	5	50	8	23.953,132

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagA –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
42	85	3	3	400	13	24.228,777
19	60	3	5	200	5	24.249,657
26	65	1	1	50	2	24.298,030
72	75	3	3	50	8	24.516,443
100	90	1	8	400	13	24.889,208
111	95	1	2	500	13	24.903,411
18	85	2	3	200	13	25.154,476
66	55	1	1	400	1	25.192,750
56	60	1	8	50	3	25.323,464
203	70	1	13	25	3	25.410,408
204	55	2	8	200	8	25.472,558
141	60	1	13	50	3	25.582,006
21	70	3	2	500	13	25.629,215
171	60	1	13	50	2	25.736,192
119	55	1	3	100	2	26.044,236
201	80	3	13	50	8	26.088,769
152	75	2	5	25	5	26.101,377
180	60	1	1	100	3	26.186,756
136	65	1	5	100	8	26.349,103
88	65	2	13	25	5	26.488,501
84	75	1	5	300	8	26.670,357
92	85	2	2	50	13	26.910,252
124	60	3	2	400	13	27.410,731
133	75	1	2	100	13	27.546,010
99	70	3	1	50	13	27.939,412
209	60	2	3	500	8	28.274,464
47	65	2	13	200	13	28.333,339
160	70	1	5	500	13	28.402,159
148	55	2	5	200	5	28.465,261
200	70	3	3	100	13	29.294,731
129	55	1	5	200	5	29.428,438

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagA –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
167	65	1	8	25	3	29.565,689
188	60	1	1	300	3	30.275,213
161	55	2	5	300	5	30.413,088
127	55	1	2	200	3	30.507,409
68	100	2	3	25	8	30.872,024
162	75	2	5	50	13	32.050,596
197	60	3	13	100	13	32.256,181
157	85	2	3	25	8	32.597,211
37	75	2	3	25	8	32.771,014
17	55	1	3	200	2	32.905,245
135	60	3	8	25	8	32.990,438
153	100	1	13	25	13	33.396,927
24	55	1	1	200	2	34.006,756
110	55	3	2	100	13	34.332,818
118	60	3	5	50	13	35.015,326
202	70	1	2	25	13	35.411,695
69	60	1	3	400	13	36.182,280
64	75	1	13	25	13	36.942,109
3	55	1	5	25	8	37.201,404
166	90	1	8	25	13	37.234,708
31	100	3	2	25	13	37.415,220
104	55	2	5	400	13	38.510,445
35	55	1	5	50	8	38.774,755
50	100	3	13	25	13	41.653,203
16	55	2	13	25	13	47.297,741

Tabelle 24: VerlagA: Testmodelle

VerlagB: Trainierte Modelle

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
148	100	3	1	100	2	20.498,244
187	100	3	2	300	2	21.810,660
81	100	2	1	200	3	21.829,566
205	100	3	5	200	1	22.089,208
68	85	5	1	300	1	22.948,913
117	90	3	1	400	1	23.417,731
158	90	5	13	300	1	23.473,742
201	90	4	5	100	1	23.783,152
19	100	2	3	400	2	23.877,815
165	100	2	3	300	1	24.294,194
95	95	5	1	100	3	24.488,970
128	95	2	3	200	3	24.859,716
135	80	5	5	100	1	25.695,748
161	100	3	13	200	3	25.842,260
74	95	5	2	500	3	26.025,825
190	75	4	1	200	2	26.421,229
166	75	5	1	500	1	26.467,823
144	85	5	2	100	2	26.488,558
100	85	5	13	500	2	26.537,609
114	90	2	1	400	3	26.783,213
26	80	4	3	200	2	26.792,184
99	90	2	2	200	1	27.188,550
36	95	1	13	400	2	27.271,150
58	90	2	5	500	2	27.471,435
141	80	4	5	200	2	28.087,969
139	90	5	8	500	3	28.149,789
14	75	5	5	400	2	29.207,081
90	100	1	1	500	3	29.481,264
17	75	5	2	100	2	29.658,398
160	80	5	8	100	2	29.756,846

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagB –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
49	85	3	13	400	3	29.917,016
82	70	4	1	500	1	30.070,263
115	95	5	2	400	5	30.378,633
179	75	3	1	50	1	30.540,156
93	90	2	8	500	3	30.568,422
127	80	3	8	100	2	30.646,736
180	80	5	2	500	3	31.180,251
162	90	4	1	25	1	31.390,638
138	80	3	3	300	3	31.525,291
31	100	5	13	300	5	31.668,311
85	75	2	1	500	2	32.038,195
154	65	4	1	400	1	32.067,983
70	95	5	13	25	1	32.212,219
20	85	1	13	300	2	32.220,020
147	100	1	8	400	5	32.232,819
104	80	3	13	300	2	32.474,266
88	80	4	5	500	3	32.580,957
40	100	3	5	25	1	32.641,664
28	90	1	3	100	1	32.973,049
67	100	1	5	500	5	33.236,682
94	85	2	13	300	5	33.375,121
38	80	3	2	500	5	33.521,580
208	85	4	13	25	1	33.611,546
126	95	1	2	300	5	33.734,606
146	70	2	5	300	1	33.939,304
51	60	5	8	400	1	34.248,922
64	90	3	3	400	5	34.282,084
150	60	5	3	500	1	34.387,659
5	85	1	8	100	2	34.393,073
133	70	4	1	300	5	34.603,826
12	55	5	5	100	1	34.705,203

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagB –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
72	80	4	3	500	3	34.744,059
96	70	4	8	100	2	34.870,426
197	70	2	5	50	1	35.107,887
61	85	2	3	300	3	35.395,898
153	70	4	1	50	2	35.573,130
16	75	2	2	200	3	35.589,380
63	70	2	8	400	2	35.708,901
35	95	4	8	300	5	35.792,257
33	90	1	13	200	5	35.997,455
198	80	2	1	50	3	36.316,649
25	70	1	13	50	1	36.557,059
24	95	2	13	200	5	36.622,757
53	55	3	13	100	1	36.867,730
172	80	5	13	400	5	37.326,635
108	65	4	3	25	1	37.532,182
101	70	4	3	400	3	37.795,009
209	90	4	1	100	8	37.805,556
65	90	4	2	200	8	38.032,285
116	80	3	1	200	8	38.282,525
142	70	3	5	100	3	38.411,752
175	60	4	3	25	1	38.716,638
157	70	4	1	300	8	39.186,374
136	75	5	2	100	5	39.326,016
6	80	2	8	200	5	39.592,387
173	55	4	8	200	1	39.670,650
1	75	1	3	50	1	39.817,582
111	80	1	5	300	2	39.943,805
123	65	1	8	400	1	40.133,901
143	55	5	5	400	3	40.327,980
57	60	1	13	200	1	40.627,946
69	95	4	8	500	8	40.774,032

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagB –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
3	55	3	5	300	2	40.995,692
164	85	2	2	300	8	41.064,630
183	85	4	1	25	2	41.076,322
124	60	4	3	50	2	41.582,241
177	60	4	5	50	2	41.693,766
152	75	1	13	50	2	41.879,026
125	60	2	1	300	3	41.944,441
32	70	3	3	300	5	41.953,991
178	65	2	2	25	1	42.082,309
174	75	1	3	500	5	42.790,501
113	95	5	5	200	8	42.851,157
137	95	3	8	500	8	42.890,949
92	90	2	1	300	13	42.939,822
193	70	1	1	200	5	42.945,283
106	95	5	2	200	8	43.248,570
109	80	1	3	100	5	43.723,692
44	55	5	8	500	3	43.733,688
189	65	1	5	500	1	43.953,837
18	95	5	2	25	2	44.016,559
199	90	5	8	300	8	44.266,223
41	60	2	2	400	2	44.606,921
176	80	1	3	500	5	44.721,205
21	90	3	3	400	8	44.755,889
151	70	1	3	25	1	45.109,687
204	65	2	1	400	8	45.460,009
182	90	4	3	100	8	45.505,877
188	65	1	1	50	1	45.520,304
54	100	3	2	100	8	45.561,364
50	85	3	1	400	13	45.633,883
83	85	3	5	25	2	45.792,637
103	60	3	2	500	5	46.221,106

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagB –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
186	85	3	5	50	3	46.346,244
47	70	1	8	50	3	46.908,380
29	80	2	5	50	3	47.062,666
121	60	3	2	50	3	47.074,775
27	100	2	2	25	3	47.266,985
105	75	5	13	25	2	47.531,173
73	65	4	8	300	5	47.533,398
80	65	2	5	100	5	47.600,190
0	80	1	8	50	3	47.756,016
119	100	1	13	50	5	47.952,290
97	70	3	2	25	2	47.972,120
130	55	3	13	100	3	48.377,849
191	55	3	5	500	3	48.405,791
89	65	1	3	100	2	48.427,490
122	70	5	13	200	8	49.079,483
102	60	2	3	500	3	49.217,777
46	95	1	3	25	2	49.834,889
163	60	4	8	400	5	49.935,359
203	65	3	5	400	5	50.453,576
120	65	2	1	200	13	50.518,541
206	60	5	2	300	8	51.018,310
140	90	3	13	200	8	51.057,137
84	65	1	2	300	5	51.131,151
10	65	4	8	50	5	51.356,005
9	55	2	8	300	2	51.571,903
129	55	1	2	200	1	52.111,947
43	85	2	5	500	13	53.168,713
45	90	1	2	100	13	53.653,927
134	65	4	13	400	8	53.754,473
56	60	3	3	300	5	53.868,934
167	65	4	8	200	8	54.512,188

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagB –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
91	55	5	2	300	8	54.628,989
98	55	5	1	25	3	54.853,060
60	70	1	1	50	8	55.102,252
181	100	5	8	50	5	56.932,002
15	55	5	2	500	8	57.095,110
8	55	3	2	400	8	57.152,634
202	75	4	2	200	13	57.205,963
156	95	3	13	400	13	57.321,998
22	65	5	3	100	8	57.772,855
7	95	4	3	100	13	57.937,666
170	85	5	1	25	5	58.489,076
66	95	3	13	300	13	58.546,858
132	55	1	8	500	3	58.992,872
112	65	2	2	500	13	59.324,122
4	55	2	13	25	3	59.370,332
159	75	3	3	25	3	59.377,713
171	75	1	1	50	13	59.650,980
86	60	1	13	400	8	60.188,470
48	90	2	3	50	8	60.201,109
118	75	4	5	50	5	60.367,290
52	70	5	5	50	8	60.778,546
39	75	3	3	500	13	61.071,208
2	95	3	13	200	13	61.266,348
87	100	4	13	500	13	61.457,542
131	60	1	8	200	8	61.749,315
169	75	4	2	100	13	62.238,505
207	95	5	13	400	13	62.940,605
196	60	1	5	200	8	63.219,081
76	65	2	8	400	13	64.649,431
42	100	2	13	50	8	64.719,501
195	65	3	3	200	13	65.181,422

– Fortsetzung nächste Seite –

– Fortsetzung: Trainierte Modelle VerlagB –

Modell	Epochs	min-Word	Window	Vector	negSample	Losses
184	55	5	3	50	8	65.469,959
62	65	5	5	300	13	66.254,479
71	75	2	1	50	13	67.000,969
55	55	2	2	400	13	68.994,650
79	75	2	8	25	5	69.009,099
145	85	4	13	200	13	69.621,677
34	75	1	8	25	5	70.162,202
77	100	5	8	100	13	71.183,198
149	80	4	5	100	13	71.225,647
185	85	5	8	100	13	73.546,512
13	55	3	5	50	8	74.303,485
107	55	4	2	100	13	74.442,335
155	55	1	2	400	13	75.765,934
11	70	4	1	25	8	77.344,209
78	100	3	5	25	8	77.803,466
30	60	2	5	25	5	78.816,436
75	60	1	3	50	8	83.979,717
23	85	1	8	50	13	89.008,942
110	60	4	13	50	13	95.624,191
59	95	4	3	25	13	97.172,481
192	60	3	1	25	13	97.885,456
37	85	2	5	25	13	114.034,486
194	100	1	8	25	13	115.368,180
200	85	2	13	25	13	117.136,002
168	70	1	8	25	13	130.645,927

Tabelle 25: VerlagB: Testmodelle

VerlagA: WEAT Zielgruppenwörter

Kategorie	Zielliste X	Zielliste Y
pleasant vs. unpleasant	[Liebe, Frieden, wunderbar, Freude, Lachen, glücklich]	[furchtbar, schrecklich, Böse, Krieg]
career vs. family	[Unternehmen, Geschäft]	[Zuhause, Eltern, Kind, Familie, Verwandte]
maths vs. arts	[Mathematik, zahlen]	[Tanz]
science vs. arts2	[Physik, Chemie, Einstein]	[Tanz]
thinking vs. feeling	[Geist, verstehen, Denken, Wissen]	[Gefühl, empfinden, verstehen]
intelligent vs. appearance	[wissbegierig, neugierig, treffend, aufmerksam, weise, klug, logisch, intelligent]	[häuslich, schlank, sportlich, modisch, dringen, hässlich, gesund, fett, schwach, dünn, hübsch, schön, stark]
strength vs. weakness	[machen, stark, Befehl, laut, gewinnen, anführen, Schreien]	[schwach, ängstlich, schüchtern, folgen, verlieren, ängstlich]
outdoor vs. indoor	[draußen, Außen, Natur, Garten, Baum, See, Berg]	[Innen, Küche, Zuhause]
male vs. female toys	[Ball, Schlag, Lkw, Auto, Fahrrad, Pistole, Soldat, blau]	[Puppe, Rosa]
male vs. female sports	[Fußball]	[turnen, tanzen]
active vs. quite games	[fliegen, fahren, springen, klettern, schwimmen, rutschen, tauchen, hüpfen]	[lesen, schreiben, beobachtet, verstecken, zeichnen, malen]
male vs. female adjectives	[begeben]	[achten, begeben, erfolgreich]
male vs. female professions	[]	[Friseur, Plan, Lehrer, Lehrerin]
male vs. female qualities	[erfolgreich, klug, Abenteuer, verdienen, Meister]	[passiv, Opfer, erfolglos]

– Fortsetzung nächste Seite –

– Fortsetzung: WEAT Zielgruppenwörter VerlagA–

Kategorie	Zielliste X	Zielliste Y
dominant vs. obedient	[befehlen, überlegen]	[aufmerksam, höflich, zwingen]
male vs. female subjects	[Mathematik, Physik, Wissenschaft, Chemie, Sport, Technik]	[Bildung, Biologie, Medizin, Sprache, englisch, Musik]

Tabelle 26: VerlagA: WEAT Zielgruppenwörter

VerlagB: WEAT Zielgruppenwörter

Kategorie	Zielliste X	Zielliste Y
pleasant vs. unpleasant	[Liebe, wunderbar, Freude, Lachen, glücklich]	[Qual, furchtbar, schrecklich, Böse, Krieg]
career vs. family	[Unternehmen, Büro, Geschäft, Karriere]	[Zuhause, Eltern, Kind, Familie, Cousin, Verwandte]
maths vs. arts	[Mathematik, zahlen]	[Kunst, Tanz, Literatur, Roman, Skulptur]
science vs. arts2	[Physik, Chemie, Einstein, Experiment]	[Kunst, Tanz, Literatur, Roman]
thinking vs. feeling	[Geist, verstehen, Denken, Wissen]	[Gefühl, empfinden, verstehen]
intelligent vs. appearance	[genial, einfühlsam, neugierig, aufmerksam, weise, klug, clever, logisch, intelligent]	[schlank, sportlich, hässlich, gesund, attraktiv, fett, schwach, dünn, hübsch, schön, stark]
strength vs. weakness	[machen, stark, Befehl, laut, kühn, gelingen, anführen, Schreien, dynamisch, Gewinn]	[schwach, schüchtern, folgen, verlieren]
outdoor vs. indoor	[draußen, Außen, Natur, Garten, Baum, See, Berg]	[Innen, Küche, Haushalt, Zuhause, Sofa, Schlafzimmer]
male vs. female toys	[Ball, Schlag, Lkw, Auto, Fahrrad, Pistole, Soldat, blau]	[Puppe, schminken, Schmuck]

– Fortsetzung nächste Seite –

– Fortsetzung: WEAT Zielgruppenwörter VerlagB–

Kategorie	Zielliste X	Zielliste Y
male vs. female sports	[Basketball, Fußball]	[Volleyball, Tanz]
active vs. silent games	[fliegen, fahren, springen, klettern, schwimmen, rutschen, tauchen]	[lesen, schreiben, beobachtet, verstecken, zeichnen, malen]
male vs. female adjectives	[begeben, mürrisch]	[verehren, achten, begeben, erfolgreich]
male vs. female professions	[Offizier, Offizier]	[Friseur, Plan, Lehrer, Lehrerin]
male vs. female qualities	[erfolgreich, klug, Abenteuer, verdienen, Meister]	[Gehorsam, passiv, Opfer]
dominant vs. obedient	[überlegen, Autorität]	[Gehorsam, aufmerksam, höflich, zwingen]
male vs. female subjects	[Mathematik, Physik, Wissenschaft, Chemie, Sport, Technik]	[Kunst, Bildung, Medizin, Sprache, Englisch, Musik]

Tabelle 27: VerlagB: WEAT Zielgruppenwörter

VerlagA: Berufsgendergaps

Beruf	Gendergab
Feuerwehrmann	-0.212
Dichter	-0.199
König	-0.196
Forscher	-0.188
Inspektor	-0.188
Meister	-0.175
Ordensbruder	-0.171
Arbeiter	-0.170
Kriminalinspektor	-0.161
Goldgräber	-0.160
Pilot	-0.144

– Fortsetzung nächste Seite –

– Fortsetzung: Berufsgendergaps VerlagA–

Beruf	Gendergab
Präsident	-0.136
Jurist	-0.135
Wirt	-0.134
Kapitän	-0.134
Professor	-0.122
Bankdirektor	-0.121
Gärtner	-0.121
Soldat	-0.120
Beamter	-0.118
Staatspräsident	-0.115
Bäckermeister	-0.115
Wärter	-0.113
Chef	-0.112
Gemeindearzt	-0.111
Bettler	-0.111
Direktorin	-0.109
Maurer	-0.106
Erfinder	-0.102
Geselle	-0.102
Doktor	-0.089
Kaufmann	-0.089
Prinzessin	-0.089
Friseur	-0.086
Steuermann	-0.084
Arzt	-0.083
Führer	-0.082
Lehrkraft	-0.070
Bauer	-0.061
Flugbegleiter/in	-0.059
Polizist	-0.058
Köchin	-0.056

– Fortsetzung nächste Seite –

– Fortsetzung: Berufsgendergaps VerlagA –

Beruf	Gendergab
Direktor	-0.034
Ordner	-0.031
Schülerin	-0.030
Arbeitgeber	-0.024
Richter	-0.014
Bäcker	-0.005
Lehrer	-0.003
Maurerin	0.007
Lehrerin	0.008
Detektivinnen	0.009
Autor	0.021
Hersteller	0.034
Schüler	0.051
Wissenschaftler	0.076
Lehrperson	0.078
Plan	0.097
Maler	0.106
Lehre	0.134

Tabelle 28: VerlagA: Verschiedene Berufe und ihr Gendergaps.

Negative Werte zeigen eine Bias zu Männern, positive Werte eine Bias zu Frauen. TOP10 der beliebtesten Lehrberufe für *Frau*, *Männer* und *beide Geschlechter*, Quelle: [2]

VerlagB: Berufsgendergaps

Beruf	Gendergab
Präsident	-0.114
König	-0.071
Händler	-0.064
Bauer	-0.061
Forscher	-0.052
Kapitän	-0.037
Apotheker	-0.037

– Fortsetzung nächste Seite –

– Fortsetzung: Berufsgendergaps VerlagB–

Beruf	Gendergab
Tierarzt	-0.032
Bäckermeister	-0.022
Schmied	-0.020
Diener	-0.016
Offizier	-0.008
Professor	-0.006
Inspektor	-0.006
Arbeiter	0.001
Meister	0.004
Soldat	0.023
Verkäufer	0.036
Friseur	0.040
Chef	0.041
Kaufmann	0.042
Königin	0.042
Müller	0.044
Richter	0.045
Plan	0.047
Schneider	0.047
Erfinder	0.048
Polizist	0.052
Direktor	0.052
Assistentin	0.063
Schüler	0.063
Gärtner	0.068
Feuerwehrmann	0.069
Lehrer	0.070
Zimmermann	0.076
Dichter	0.078
Arzt	0.081
Führer	0.081

– Fortsetzung nächste Seite –

– Fortsetzung: Berufsgendergaps VerlagB–

Beruf	Gendergab
Prinzessin	0.082
Lehrperson	0.095
Doktor	0.095
Ehefrau	0.103
Autor	0.118
Lehrerin	0.123
Maler	0.149
Schülerin	0.153

Tabelle 29: VerlagB: Verschiedene Berufe und ihr Gendergaps.

Negative Werte zeigen eine Bias zu Männern, positive Werte eine Bias zu Frauen. TOP10 der beliebtesten Lehrberufe für *Frau*, *Männer* und *beide Geschlechter*, Quelle: [2]

Anhang B: Listen

Stop Liste

Quelle: [65] erweitert um „–“ für die Satzzeichen, von Hanover-Tagger

Stopliste: [a, ab, aber, aber, ach, acht, achte, achten, achter, achttes, ag, alle, allein, allem, allen, aller, allerdings, alles, allgemeinen, als, als, also, am, an, andere, anderen, andern, anders, au, auch, auch, auf, aus, ausser, außer, ausserdem, außerdem, b, bald, bei, beide, beiden, beim, beispiel, bekannt, bereits, besonders, besser, besten, bin, bis, bisher, bist, c, d, da, dabei, dadurch, dafür, dagegen, daher, dahin, dahinter, damals, damit, danach, daneben, dank, dann, daran, darauf, daraus, darf, darfst, darin, darüber, darum, darunter, das, das, dasein, daselbst, dass, daß, dasselbe, davon, davor, dazu, dazwischen, dein, deine, deinem, deiner, dem, dementsprechend, demgegenüber, demgemäss, demgemäß, demselben, demzufolge, den, denen, denn, denn, denselben, der, deren, derjenige, derjenigen, dermassen, dermaßen, derselbe, derselben, des, deshalb, desselben, dessen, deswegen, d.h, dich, die, diejenige, diejenigen, dies, diese, dieselbe, dieselben, diesem, diesen, dieser, dieses, dir, doch, dort, drei, drin, dritte, dritten, dritter, drittes, du, durch, durchaus, dürfen, dürft, durfte, durften, e, eben, ebenso, ehrlich, ei, ei,, ei,, eigen, eigene, eigenen, eigener, eigenes, ein, einander, eine, einem, einen, einer, eines, einige, einigen, einiger, einiges, einmal, einmal, eins, elf, en, ende, endlich, entweder, entweder, er, Ernst, erst, erste, ersten, erster, erstes, es, etwa, etwas, euch, f, früher, fünf, fünfte, fünften, fünfter, fünftes, für, g, gab, ganz, ganze, ganzen, ganzer, ganzes, gar, gedurft, gegen, gegenüber, gehabt, gehen, geht, gekannt, gekonnt, gemacht, gemocht, gemusst, genug, gerade, gern, gesagt, gesagt, geschweige, gewesen, gewollt, geworden, gibt, ging, gleich, gott, gross, groß, grosse, große, grossen, großen, grosser, großer, grosses, großes, gut, gute, guter, gutes, h, habe, haben, habt, hast, hat, hatte, hätte, hatten, hätten, heisst, her, heute, hier, hin, hinter, hoch, i, ich, ihm, ihn, ihnen, ihr, ihre, ihrem, ihren, ihrer, ihres, im, im, immer, in, in, indem, infolgedessen, ins, irgend, ist, j, ja, ja, jahr, jahre, jahren, je, jede, jedem, jeden, jeder, jedermann, jedermanns, jedoch, jemand, jemandem, jemanden, jene, jenem, jenen, jener, jenes, jetzt, k, kam, kann, kannst, kaum, kein, keine, keinem, keinen, keiner, kleine, kleinen, kleiner, kleines, kommen, kommt, können, könnt, konnte, könnte, konnten, kurz, l, lang, lange, lange, leicht, leide, lieber, los, m, machen, macht, machte, mag, magst, mahn, man, manche, manchem, manchen, mancher, manches, mann, mehr, mein, meine, meinem, meinen, meiner,

meines, mensch, menschen, mich, mir, mit, mittel, mochte, möchte, mochten, mögen, möglich, mögt, morgen, muss, muß, müssen, musst, müsst, musste, mussten, n, na, nach, nachdem, nahm, natürlich, neben, nein, neue, neuen, neun, neunte, neunten, neunten, neuntes, nicht, nicht, nichts, nie, niemand, niemandem, niemanden, noch, nun, nun, nur, o, ob, ob, oben, oder, oder, offen, oft, oft, ohne, ordnung, p, q, r, recht, rechte, rechten, rechter, rechtes, richtig, rund, s, sa, sache, sagt, sagte, sah, satt, schlecht, Schluss, schon, sechs, sechste, sechsten, sechster, sechstes, sehr, sei, sei, seid, seien, sein, seine, seinem, seinen, seiner, seines, seit, seitdem, selbst, selbst, sich, sie, sieben, siebente, siebenten, siebenter, siebentes, sind, so, solange, solche, solchem, solchen, solcher, solches, soll, sollen, sollte, sollten, sondern, sonst, sowie, später, statt, t, tag, tage, tagen, tat, teil, tel, tritt, trotzdem, tun, u, über, überhaupt, übrigens, uhr, um, und, und?, uns, unser, unsere, unserer, unter, v, vergangenen, viel, viele, vielem, vielen, vielleicht, vier, vierte, vierten, vierter, viertes, vom, von, vor, w, wahr?, während, währenddem, währenddessen, wann, war, wäre, waren, wart, warum, was, wegen, weil, weit, weiter, weitere, weiteren, weiteres, welche, welchem, welchen, welcher, welches, wem, wen, wenig, wenig, wenige, weniger, wenigstens, wenn, wenn, wer, werde, werden, werdet, wessen, wie, wie, wieder, will, willst, wir, wird, wirklich, wirst, wo, wohl, wollen, wollt, wollte, wollten, worden, wurde, würde, wurden, würden, x, y, z, z.b, zehn, zehnte, zehnten, zehnter, zehntes, zeit, zu, zuerst, zugleich, zum, zum, zunächst, zur, zurück, zusammen, zwanzig, zwar, zwar, zwei, zweite, zweiten, zweiter, zweites, zwischen, zwölf, –]

Liste weiblicher Vornamen

Quelle: [68]

Liste weiblicher Vornamen: [Aaliyah, Aaltje, Abbey, Abigal, Ada, Adele, Adelheid, Adelina, Adina, Adrian, Adriana, Aenna, Agatha, Agnes, Aida, Aileen, Aimée, Aitana, Aithne, Ajlin, Akela, Alamea, Alana, Alani, Alara, Alaula, Alba, Alberte, Alea, Aleha, Alena, Alessa, Alessandra, Alessia, Alex, Alexa, Alexandra, Alexia, Alexis, Alexsandra, Aleya, Alica, Alice, Alicia, Alida, Aliena, Alina, Aline, Alisa, Alisha, Alisia, Alison, Alissa, Aliy, Aliya, Alizee, Alla, Allegra, Ally, Allyssa, Alma, Almina, Almuth, Aloha, Aluna, Alva, Alysa, Alyssa, Amadea, Amalia, Amalie, Amanda, Amani, Amaryllis, Amber, Amelia, Amelie, Ameline, Amely, Amica, Amie, Amina, Amira, Amita, Amke, Amrei, Amy, Ana, Anabel, Anabell, Anastasia, Anda, Andrea, Andriane, Andrina, Andy, Anela, Angela, Angelica, Angelika, Angeliki,

Angelina, Angélique, Anica, Aniela, Anika, Anina, Anita, Anja, Anke, Ann, Anna, Annabel, Annabell, Annabella, Annabelle, Annalena, Annbritt, Ann-Britt, Anne, Annegret, Anneke, Anneli, Annelie, Annelina, Annemarie, Anne-Marie, Annesca, Annett, Annette, Anni, Annica, Annie, Annika, Annilie, Annina, Annkathrin, Ann-Kathrin, Annkatrin, Anny, Anouk, Anselina, Anthea, Antigone, Antje, Antonia, Antonie, Antonietta, Antonina, Anuheia, Anushka, Apikalia, Arabella, Ariane, Arianna, Ariel, Arlene, Arven, Arwen, Ashley, Ashly, Asta, Astrid, Asya, Athina, Aurea, Aurelia, Aurelie, Ava, Aveline, Avena, Ayaka, Ayana, Ayla, Aylin, Aysu, Ayuna, Azalea, Babette, Bahareh, Baila, Baldrun, Balthilde, Banu, Barbara, Bärbel, Barbie, Bartolomea, Bastienne, Batjah, Bea, Beate, Beatrice, Beatrix, Becky, Beeke, Begonia, Beixing, Belana, Belina, Belinda, Bella, Belli, Benazir, Benedicta, Benedikta, Benedikte, Benice, Benita, Benja, Bente, Berat, Berenice, Berenike, Bergild, Berit, Bernadette, Berta, Beryll, Beth, Bethany, Bettina, Betty, Beverly, Bianca, Bianka, Bibi, Bibiana, Bienke, Bine, Birga, Birgit, Birgitte, Birka, Birklinde, Birte, Bjella, Bjelle, Björk, Blair, Blanca, Blossom, Boswen, Blue, Bluebell, Bo, Bodil, Bogumila, Bonnie, Bonny, Breanna, Brenda, Brenna, Bridget, Brietta, Brigitte, Brinja, Britanny, Britney, Britta, Brooke, Brundhild, Bryanna, Bryndis, Bulan, Burga, Cäcilie, Caecilia, Caio, Caitlin, Caitriona, Caja, Calla, Callista, Callisto, Camellia, Cami, Camilla, Camille, Cara, Caren, Cariba, Carina, Carla, Carlotta, Carmen, Carmina, Caro, Carola, Carole, Carolin, Carolina, Caroline, Carolyn, Carry, Cassandra, Cassia, Cassidy, Cassiopeia, Cataleya, Cate, Catharina, Catherine, Cathleen, Cathlin, Cathrine, Cathy, Caya, Caylee, Cécile, Cecilia, Celes, Celestine, Celia, Celin, Celina, Celine, Cendrine, Ceres, Cettina, Chadia, Chalyse, Chandra, Chanel, Chantal, Charis, Charleen, Charlie, Charline, Charlize, Charlot, Charlott, Charlotta, Charlotte, Chelsea, Chenoa, Cher, Cheyenne, Chiana, Chiara, Chinara, Chloe, Chloé, Chris, Christa, Christel, Christiana, Christiane, Christien, Christin, Christina, Christine, Ciara, Cilla, Cim, Cindy, Cinzia, Claire, Clara, Clarice, Clarissa, Claudia, Clea, Clementine, Cleo, Cleopatra, Clover, Coco, Colette, Colleen, Connie, Conny, Constance, Constanze, Cora, Coralie, Cordula, Corin, Corina, Corinna, Cornelia, Corona, Cosima, Costia, Cydnee, Cynthia, Dafne, Dagmar, Dagny, Dahlia, Daisy, Dala, Dalia, Daliah, Daline, Damara, Damira, Dana, Danai, Dani, Danica, Daniekje, Daniela, Danielle, Danika, Danuta, Dany, Daphne, Daria, Darina, Darja, Darleen, Darlin, Darya, Dasianera, Davide, Davina, Davinia, Debbie, Debora, Deborah, Deelee, Deetje, Deike, Dela, Delenn, Delia, Delila, Delilah, Delinda, Deloris, Delphine, Demeter, Demi,

Dena, Denise, Deolinda, Desiree, Désirée, Destiny, Devi, Diana, Diandra, Diane, Dido, Dietgard, Dietje, Dilara, Dina, Dinah, Dion, Domenica, Domenika, Dominika, Dominique, Dona, Donatella, Donnice, Dora, Doreen, Dori, Dorina, Doris, Dorisa, Dorkas, Doro, Dorothea, Dorothee, Dörte, Dunja, Dünya, Dylan, Dylane, Dyre, Dyrken, Ebba, Ece, Edda, Edelgard, Edeltraud, Edgarda, Edina, Edith, Editha, Eefje, Effie, Eija, Eika, Eike, Eila, Eileen, Eilika, Eireann, Eireen, Ejla, Ekaterina, Ela, Elaine, Elanaz, Elani, Elanie, Elayne, Elea, Eleanor, Elektra, Elele, Elena, Eleni, Elenia, Elenor, Elenora, Eleonora, Eleonore, Elfi, Elfriede, Elia, Eliana, Eliane, Elikapeka, Elin, Elina, Elis, Elisa, Elisabet, Elisabeth, Elisabetta, Elise, Elisha, Eliza, Elke, Ella, Ellen, Ellis, Elmira, Elna, Èlodie, Eloise, Elonie, Elora, Elsa, Else, Eltje, Eluana, Elvira, Emanuela, Emanuele, Emelie, Emely, Emielia, Emilia, Emilie, Emily, Emina, Emira, Emma, Emmelie, Emmeline, Emmely, Emmi, Emmy, Engelina, Enie, Enissa, Eniz, Enna, Ennie, Enrica, Enrike, Enya, Erica, Erika, Erin, Ermelina, Erna, Ernestine, Eske, Esmé, Esmeralda, Estefania, Estella, Estelle, Ester, Esther, Estrella, Etienne, Eugenie, Euphemia, Europa, Eva, Eve, Evelin, Evelyn, Evi, Evina, Evita, Eyleen, Eyvette, Fabia, Fabienne, Fabiola, Fabrice, Fadia, Faith, Faiza, Faizar, Falka, Fania, Fanie, Fanny, Farah, Faralda, Farina, Fatima, Fatme, Fay, Fedora, Fedra, Fee, Feelija, Felice, Felicia, Felicitas, Felina, Felipa, Felize, Felizitas, Female, Femke, Fenja, Fenna, Fernanda, Fiala, Fibi, Fidelia, Fides, Fijara, Filiz, Filomena, Fina, Finette, Finja, Finn, Finnja, Fiona, Fiorella, Firat, Fjella, Flavia, Fleur, Flora, Florence, Florens, Florentina, Florentine, Flores, Floretta, Floria, Floriane, Florin, Florina, Florisa, Fortuna, Fotini, Frana, Franca, Frances, Francesca, Francine, Franja, Franka, Frantje, Franzisca, Franziska, Frauuke, Freda, Frederieke, Frederike, Freimuth, Frej, Freya, Freyja, Fria, Frida, Friderike, Friderun, Fridonlina, Frieda, Friede, Friedegard, Friedel, Friederieke, Friederike, Friis, Fritz, Fritz, Fuyuko, Gabriel, Gabriela, Gabriele, Gabrielle, Gaby, Gaia, Gail, Galaxina, Gamze, Ganya, Gasira, Gea, Geena, Geerke, Geertje, Geeske, Geli, Gelja, Gemma, Genevieve, Genoveva, Gentiana, Georgia, Georgina, Geraldine, Gerda, Geri, Gerit, Gerrit, Gertraud, Gertrud, Gesa, Gesche, Gesha, Gesina, Geske, Giancarmine, Gianna, Gianni, Giannina, Gila, Gilda, Gill, Gillian, Gilliane, Gina, Ginella, Ginger, Gioia, Giona, Giovanna, Gisela, Giselle, Giselle, Gitte, Giulia, Giulijana, Gladys, Glenn, Gloria, Godja, Gotje, Gottlindis, Grace, Grazia, Graziela, Greta, Grete, Griseldis, Grit, Gritt, Gudrun, Guilia, Guinevere, Guiseppa, Gül, Gunda, Gundel, Gunilla, Gustava, Gustave, Gwen, Gwenda, Gwendolin, Gwendolyn, Gwynedd, Gwyneth, Gyula, Hadassa, Hadia, Hadice, Hai-

ley, Halina, Hallgard, Hana, Hanako, Hanami, Hanka, Hanke, Hanna, Hannah, Hanne, Hanneke, Hannelore, Hanni, Harper, Harriet, Haruka, Hauke, Haukea, Haunani, Hauoli, Havin, Hazel, Healani, Heather, Hedda, Hedi, Hedone, Hedwig, Hege, Heide, Heiderose, Heidi, Heidje, Heidrun, Heike, Heilke, Heinke, Helen, Helena, Helene, Helga, Helgrit, Helia, Helin, Hella, Hellen, Hellenä, Hellrun, Helma, Helmina, Hendrieke, Hendrike, Hendrikje, Henna, Henriette, Henrike, Henrikje, Hermine, Herta, Hidekel, Hila, Hilaria, Hilde, Hildegard, Hilke, Hina, Hjördis, Hokulani, Holda, Holly, Honorata, Hortensia, Huguette, Hulda, Hyacinthe, Iara, Iasmina, Ida, Idabella, Idalina, Iduna, Iekika, Ignatia, Ihana, Ike, Ilana, Ilaria, Ildiko, Ileana, Ileya, Iliana, Ilisabat, Ilka, Ilkay, Ilknur, Ilona, Ilse, Imani, Imelda, Imera, Imilia, Imke, Immanuel, Ina, Indira, Indra, Ineke, Ines, Inessa, Inga, Inge, Ingeborg, Ingela, Ingmari, Ingrid, Ingvelde, Inike, Iniki, Inka, Inken, Innozentia, Inoa, Insa, Invana, Invidia, Io, Ioana, Iolana, Iolanthe, Ionita, Iordana, Iphigeneia, Iphigenia, Ira, Irem, Irene, Irina, Iris, Irma, Irmela, Irmgard, Irmtraud, Isa, Isabel, Isabell, Isabella, Isabelle, Isamara, Iseabail, Isis, Isolde, Isra, Itziar, Iulia, Iva, Ivana, Ivanka, Ivette, Ivonne, Ivy, Iwalani, Jackline, Jacky, Jacqueline, Jade, Jaden, Jael, Jakoba, Jakobe, Jale, Jalma, Jamie, Jamila, Jana, Janah, Jane, Janet, Janett, Janette, Janice, Janina, Janine, Janique, Janis, Janka, Janna, Janne, Janneke, Jaqueline, Jara, Jarina, Jascha, Jasmin, Jasmina, Jean, Jeanette, Jeanina, Jeanine, Jeanna, Jeanne, Jeannette, Jella, Jenna, Jennifer, Jenny, Jeromina, Jessamyn, Jesse, Jessi, Jessica, Jessie, Jessika, Jessy, Jette, Jil, Jill, Jillian, Joaline, Joana, Joanna, Jocelyn, Jocelyne, Jodie, Joelina, Joeline, Joelle, Johanna, Joke, Jola, Jolanda, Jolene, Jolie, Jolien, Jolin, Jolina, Joline, Jolyne, Jona, Jonah, Jonna, Jordan, Jordana, Jorina, Jorinde, Jorja, Josefin, Josefina, Josefine, Josepha, Josephin, Josephina, Josephine, Josi, Josie, Josina, Josy, Joy, Joyce, Juanita, Judit, Judith, Jula, Julande, Jule, Jules, Juli, Julia, Juliana, Julianne, Julianna, Julianne, Julie, Julien, Juliet, Juliette, Julika, Julina, Julissa, Juna, Juno, Juri, Justine, Jutta, Jytte, Kader, Kaelyn, Kahula, Kai, Kaiko, Kaila, Kaimana, Kainalu, Kainoa, Kaipo, Kaiulani, Kaj, Kaja, Kakalina, Kalama, Kalani, Kalea, Kalena, Kalia, Kalinda, Kalua, Kalypso, Kamaka, Kamalei, Kamilla, Kanela, Kanoa, Kara, Kareene, Karen, Karin, Karina, Karla, Karli, Karlotta, Karola, Karolin, Karolina, Karoline, Kasandra, Kassandra, Kassiopeia, Kasumi, Katalin, Katarina, Kate, Katharina, Käthe, Kathi, Kathleen, Kathrin, Kati, Katie, Katima, Katja, Katniss, Katrin, Katrina, Kaulana, Kauthar, Kawai, Kawelo, Kay, Kaya, Kayla, Kayleigh, Kea, Keaka, Keao, Keawe, Kehaulani, Keira, Keke, Kekepania, Kekoa,

Kelani, Kelda, Kelly, Kendal, Kendra, Kennya, Keola, Keolani, Keona, Keonaona, Kersten, Kerstin, Keshia, Kevina, Keyla, Khadija, Khiria, Kiana, Kiani, Kiara, Kilikina, Kim, Kimberley, Kimberly, Kimi, Kini, Kira, Kiri, Kiria, Kirima, Kirsten, Kirsti, Kitty, Klara, Klarissa, Klaudia, Klementine, Kleopatra, Klothilde, Konny, Konrada, Konrade, Konradina, Konstantina, Konstanze, Kora, Kordula, Kornelia, Kriemhild, Kris, Krister, Kristin, Kristina, Kristine, Kronborg, Krysante, Kunigunde, Kusuma, Kylie, Kyra, Kyrene, Lærke, Laeticia, Laetitia, Laetizia, Lahela, Laila, Laiza, Lale, Lanakila, Lanea, Lani, Lania, Lani-Malu, Lara, Laren, Lari, Larina, Larissa, Läticia, Lätizia, Laura, Laureen, Lauren, Laurentia, Laurina, Laurine, Lavea, Lavina, Laya, Layla, Lea, Leah, Lean, Leana, Leandra, Leanne, Lee, Leena, Leia, Leialoha, Leila, Leilai, Leilani, Leimomi, Leinani, Leja, Lena, Lene, Leni, Lenja, Lenni, Lenny, Lenya, Leo, Leona, Leonarda, Leoni, Leonie, Leonor, Leonora, Leonore, Leslie, Leticia, Letitia, Letizia, Levinia, Levke, Lewe, Lexa, Leyla, Lhea, Lia, Liah, Liana, Liane, Lianne, Liddy, Liecha, Lieselotte, Lieven, Lif, Lil, Lili, Lilia, Lilian, Liliana, Liliane, Lilinoe, Lilith, Lill, Lillemor, Lillesol, Lilli, Lillian, Lillith, Lilly, Lilou, Lily, Lilyan, Lina, Linda, Line, Linette, Linn, Linnea, Lionne, Lis, Lisa, Lisann, Lisanne, Lisette, Liss, Lissi, Lissy, Liv, Liva, Livia, Liya, Liz, Liza, Loana, Lois, Lokelani, Lola, Lonie, Loreen, Loreena, Lorena, Loretta, Loryn, Lotta, Lotte, Lotti, Lou, Louica, Louisa, Louise, Lovina, Lovis, Lua, Luan, Luana, Luca, Lucca, Lucia, Lucian, Luciana, Lucie, Lucienne, Lucille, Lucina, Lucrezia, Lucy, Ludmila, Ludmilla, Ludowika, Ludwine, Luisa, Luise, Luka, Lukka, Lula, Lulu, Luna, Luzia, Luzie, Lya, Lydia, Lynn, Lynne, Lys, Lysann, Maaike, Mabel, Madeleine, Madeline, Mádhuri, Madita, Madlen, Madlene, Madlin, Madline, Maelle, Magdalena, Maggie, Magnolia, Mahealani, Mahina, Maija, Maikai, Maike, Maila, Maile, Mailien, Mailin, Maira, Maischa, Maite, Maithe, Maja, Majella, Majira, Majvi, Makamae, Makana, Makani, Makanui, Mala, Maleen, Malena, Mali, Malia, Malie, Malin, Malina, Malou, Malu, Maluhia, Mana, Mandy, Manja, Manoa, Manolja, Manon, Manuel, Manuela, Mara, Marah, Marama, Marcelina, Marcella, Marcia, Marcy, Mareen, Marei, Mareike, Mareile, Mareke, Maren, Maresa, Margarete, Margarethe, Margarita, Margit, Margitta, Marguerite, Maria, Marian, Marianne, Maribelle, Marica, Marie, Marieke, Mariel, Mariela, Mariele, Mariella, Marielle, Marietta, Marika, Marike, Marin, Marina, Marine, Marion, Marisa, Marisol, Marissa, Marit, Marita, Marja, Marla, Marle, Marleen, Marlen, Marlana, Marlene, Marlies, Marlin, Marniq, Marou, Marta, Martha, Marthe, Martina, Martine, Martje, Marusha, Mary, Marybel, Marybelle,

Mascha, Masha, Mathilda, Mathilde, Matilda, Mattanja, Mattea, Matthea, Maud, Maura, Maureen, Maxi, Maxie, Maxima, Maxime, Maximiliane, Maxin, Maxine, Maya, Maydé, Maylea, Mealla, Meallá, Meena, Meike, Melanie, Mele, Melika, Melina, Melinda, Meline, Melisa, Melisande, Melissa, Melody, Melubo, Menami, Mercedes, Meredith, Meret, Merian, Merida, Meriem, Merit, Merle, Merlinde, Merrit, Merrith, Merritt, Messalina, Mete, Metta, Mette, Mexine, Mia, Micaela, Michaela, Michelle, Michelle, Midori, Mieke, Mika, Mila, Milena, Miléne, Mililani, Milla, Millane, Mimi, Mina, Minna, Mira, Mireia, Mireille, Mirell, Miriam, Mirja, Mirjam, Mirna, Mitra, Moana, Momilani, Momo, Momoko, Momona, Mona, Monique, Monisha, Morgaine, Muirgheal, Muriel, Myha, Mylene, Myriam, Myrtle, Nadda, Nadeen, Nadescha, Nadezhda, Nadia, Nadine, Nadja, Nadjeschda, Nadya, Naemi, Naëmi, Naemie, Naika, Naima, Naja, Nakita, Nala, Nalani, Naliandra, Nalu, Nana, Nancy, Nandina, Nane, Naneah, Nani, Nanja, Nanna, Nannerl, Nannette, Naomi, Naruko, Narumol, Nasrin, Nastasja, Nastassja, Natacha, Natalie, Natalija, Natascha, Natasha, Nathaira, Nathalie, Nathaly, Neah, Neala, Neea, Neeke, Neela, Neele, Neelia, Neeltje, Neila, Nela, Nele, Nelenia, Nella, Nelli, Nellie, Nelly, Nena, Nerina, Nevana, Neyla, Nia, Nicki, Nicky, Nicola, Nicole, Nicoletta, Nika, Nike, Nikita, Nikki, Nikola, Nikole, Nikolina, Nilda, Nimué, Nina, Ninette, Ninja, Noa, Noah, Noée, Noel, Noelani, Noelia, Noelle, Noëma, Noemi, Nohea, Nola, Noomi, Noortje, Nora, Noraida, Noralie, Norberta, Norina, Norma, Nova, Nuccia, Nuna, Nurduha, Nuria, Nurit, Nuzana, Nyala, Nyota, Oana, Oceane, Océane, Octavia, Oda, Odalinde, Odellia, Odette, Odile, Odilgard, Odina, Odine, Ofelia, Ohana, Okelaani, Okelani, Okka, Oksana, Ola, Olana, Oleksandra, Olena, Olessa, Olga, Oliana, Olina, Oline, Olive, Olivia, Olwen, Olwyn, Olympe, Olympia, Omara, Ona, Ondria, Onna, Onorata, Onorina, Oona, Oonagh, Ophelia, Ophira, Oralee, Oralía, Orania, Orazia, Orela, Orelly, Oriana, Orikida, Orla, Orlaith, Orlanda, Ornella, Orpha, Orsola, Orsolya, Ortensia, Ortraud, Ortrun, Osane, Osia, Osma, Ostara, Oswald, Otfriede, Othilde, Ottilia, Ottilie, Ottonie, Ouassima, Ourania, Ova, Oxana, Oya, Oyama, Öykü, Padma, Padme, Paisley, Palila, Palina, Palma, Paloma, Pam, Pamela, Pamina, Pamuk, Pandora, Panja, Pansy, Panthea, Paola, Paolina, Paopao, Paris, Parmida, Patrice, Patricia, Patrizia, Patty, Pauahi, Paula, Pauleen, Paulien, Paulina, Pauline, Pearl, Peetje, Peggy, Peja, Penelope, Penina, Pennilyn, Peppa, Peppina, Perle, Pernilla, Perpetua, Persephone, Peterka, Petra, Petrona, Petunia, Pherenike, Philia, Philine, Philippa, Philomena, Phoebe, Phuong, Phyllis, Pia, Pia-Moana, Piara, Pietra, Pi-

na, Pinella, Piper, Pippa, Pippi, Pippilotta, Piroshka, Pixie, Placida, Polina, Polly, Poppy, Princess, Prisca Sofia, Priscilla, Prudence, Prunella, Pua, Pualani, Puanani, Pulcheria, Puneh, Pya, Qadira, Qamar, Qaskiya, Qefsere, Qence, Qendresa, Qesra, Qetsiyah, Qi, Qian, Qianqian, Qiara, Qihua, Qing, Qiturah, Quabena, Quadeisha, Quanda, Quanitta, Quanna, Quartilla, Queena, Queenie, Quella, Quendeline, Quendolin, Quendresa, Quenill, Quentaya, Quentea, Quentina, Quenzhané, Queosha, Querida, Querube, Quete, Quetzal, Quetzalli, Quiaira, Quiana, Quila, Quindelia, Quinka, Quinlee, Quinn, Quinta, Quintana, Quintessa, Quintia, Quintilia, Quintilla, Quintillion, Quirina, Quirine, Quisha, Quiterie, Quitina, Quitterie, Qulyndreia, Qunyquekya, Quoc, Quorra, Quririne-Louise, Quynh, Qzinyang, Qzislaine, Rabea, Rachel, Rachelle, Radegund, Rafaela, Ragna, Rahel, Raiatea, Raimunda, Raissa, Ramina, Ramona, Rana, Randi, Rani, Rania, Ranja, Raphaela, Raquel, Rasmine, Rauni, Rayen, Rea, Rebecca, Rebekka, Regina, Reike, Reina, Reka, Relana, Remigia, Remy, Rena, Renate, Renee, Renée, Renesmee, Resa, Resi, Rhea, Rhianna, Rhonda, Ria, Rica, Ricarda, Rieke, Rika, Rike, Rikke, Risa, Rita, Roberta, Robertina, Robin, Robinia, Rodina, Rolande, Romana, Romie, Romina, Romy, Ronia, Ronja, Ronya, Rory, Rosa, Rosabella, Rosalia, Rosalie, Rosalina, Rosalyn, Rosamunde, Rosana, Rosanna, Rosanne, Rose, Roseanne, Rosemarie, Rosemary, Rosina, Roswita, Rowena, Roxana, Roxane, Ruby, Rufina, Ruhama, Runa, Ruth, Ryleigh, Saba, Sabeth, Sabine, Sabrina, Sahra, Saida, Saima, Sakura, Sally, Salma, Salome, Sam, Samantha, Samara, Samia, Samira, Samoa, Samuela, Sana, Sanaina, Sande-Ann, Sandra, Sandy, Sandya, Sanja, Sanoe, Sanya, Saphia, Saphira, Sara, Sarah, Saralena, Sari, Sarina, Sascha, Sasha, Saskia, Sastra, Savannah, Saviya, Sayuri, Scarlett, Sebastiane, Seda, Seetha, Ségolène, Selenia, Selina, Seline, Selma, Semih, Sena, Senta, Serafine, Seraphine, Severina, Shalisar, Shana, Shania, Shanice, Shannon, Shari, Sharli, Sharon, Shayenne, Sheena, Sheila, Shelby, Shelly, Shermin, Sheryl, Shiloh, Shirin, Shirley, Shosha, Shoshana, Siana, Sibel, Sibylla, Sibylle, Sidney, Sidonia, Sieglinde, Signe, Sigourney, Sigrid, Sigrun, Sila, Sileas, Silene, Silja, Silka, Silke, Sille-Dahl, Silva, Silvana, Silvia, Simay, Simona, Simone, Sina, Sinah, Sindy, Sinead, Singa, Sinja, Sintje, Siri, Sissy, Sita, Sixtina, Skadi, Smeralda, Smilla, Sofia, Sofie, Sole, Solea, Solveig, Sonia, Sonja, Sontje, Sookie, Sophia, Sophie, Soraya, Stacey, Stacy, Stefania, Stefanie, Steffi, Stella, Stephanie, Stina, Stine, Sude, Sue, Suela, Sulola, Sümeyye, Sumi, Summer, Suna, Sünje, Sunna, Sunnhild, Sunniva, Sunny, Susan, Susann, Susanna, Susanne, Suvi, Suzan, Suzanne, Suzette, Svantje, Svea, Sveja, Svenja,

Svetlana, Swantje, Swintha, Sybille, Sydney, Tabea, Tabitha, Tahlee, Tahnee, Taina, Taira, Taisia, Talea, Talida, Taline, Talisha, Tallulah, Tally, Tamara, Tamika, Tamila, Tamina, Tamlyn, Tania, Taniela, Tanisha, Tanja, Tara, Tarah, Taralyn, Taria, Tasha, Tatjana, Tatum, Tayra, Teelke, Teena, Teeske, Tela, Tenea, Teresa, Tereza, Tessa, Tessy, Teyana, Thalia, Thalisa, Thalke, Thamara, Thassia, Thayet, Thea, Theda, Thekla, Thelma, Theodora, Theofilia, Theophanu, Theres, Theresa, Therese, Theresia, Theresita, Thivya, Thomai, Thomasina, Thora, Thordis, Thore, Thorina, Thusnelda, Tia, Tiara, Tibora, Tiffany, Tilda, Tilia, Timea, Timotea, Tina, Tine, Tinja, Tinka, Tinke, Tisa, Tizia, Tiziana, Tjada, Tjorven, Tobia, Tokessa, Tomke, Tomma, Tommelena, Tomoko, Toni, Tonia, Tonie, Tora, Tosca, Toula, Toyah, Traude, Trine, Trisha, Trixi, Trude, Trudy, Tsunami, Tuala, Tugce, Tula, Tya, Uadjit, Ualani, Ualda, Uatchit, Ubalda, Uberta, Ubon, Ucke, Udale, Ude, Udela, Udele, Udita, Uha, Uhura, Uinise, Ukaleq, Ulaaka, Ulani, Ulema, Ulfa, Ulfhild, Uli, Uliana, Ulima, Ulinka, Uljana, Ulka, Ulla, Ulli, Ulrica, Ulrike, Ulrique, Uluaki, Ululani, Ulva, Ulyssa, Uma, Umairah, Umaiza, Umay, Umbrielle, Umeko, Umina, Umpyma, Una, Unathi, Undine, Unnea, Uota, Urania, Urassaya, Urbana, Urda, Uriel, Urmirna, Urraca, Ursa, Ursel, Ursina, Ursula, Urte, Uruma, Uschi, Usha, Uta, Utahna, Ute, Utina, Utopia, Uzma, Uzza, Vaclava, Vada, Vahdina, Vaiana, Vaike, Valborga, Valda, Valea, Valentina, Valentine, Valeria, Valerie, Valeska, Valja, Valka, Valkyrie, Vally, Valmira, Vanadis, Vanessa, Vangelia, Varinja, Vasca, Vasilija, Vaya, Veerle, Velma, Veloria, Venera, Venja, Venke, Venus, Venya, Vera, Verena, Verence, Verona, Veronika, Vianne, Viatrix, Vibeke, Vica, Vicki, Vicky, Victoria, Vida, Vika, Viktoria, Vilana, Vilja, Vilma, Vinaya, Vincenta, Vincenza, Vineta, Viola, Violaine, Violet, Violetta, Viona, Vipke, Virginia, Virginie, Viveka, Vivian, Viviana, Vivianne, Vivien, Vivienne, Vladimira, Vlinda, Vroni, Waclawa, Wadjda, Waida, Waiola, Wakanda, Walburga, Waldruth, Waleah, Walentina, Walfriede, Wallis, Wally, Walpurgis, Waltkita, Waltraud, Waltrun, Wanda, Wanessa, Wanja, Waranya, Waris, Warwara, Weda, Wedeke, Weerta, Weertje, Wega, Weike, Weilev, Wencke, Wendelina, Wendula, Wendy, Wenke, Wera, Werena, Weronika, Weya, Whitney, Whoopi, Wiara, Wibke, Wicky, Wiebeke, Wiebke, Wieka, Wiekke, Wienke, Wiesje, Wigburga, Wikolia, Wiktoria, Wilburgis, Wilfriede, Wilhelmina, Wilhelmine, Willow, Wilma, Winnie, Winnifred, Winona, Wiola, Wisgard, Wisteria, Wiyada, Wolke, Wren, Wyanet, Xabelle, Xabrina, Xahara, Xailyn, Xaiya, Xally, Xamara, Xamira, Xana, Xanana, Xandra, Xandy, Xaniyah, Xantara, Xanthe, Xanthia, Xanthippe, Xanthou-

la, Xanya, Xara, Xarielle, Xavannah, Xavia, Xavienna, Xaylee, Xela, Xelena, Xena, Xenaida, Xeni, Xenia, Xeona, Xerena, Xerina, Xezal, Xhemile, Xhesika, Xhevahire, Xhuliana, Xhyla, Xi, Xia, Xiang, Xiao, Xiaomi, Xiara, Xienna, Ximena, Xin, Xina, Xinger, Xinxin, Xiomara, Xiva, Xochitle, Xofia, Xophia, Kristina, Xuan, Xue, Xuki, Xuna, Xuri, Xyleigh, Xylia, Xylina, Xylona, Xynthia, Xyra, Yade, Yadira, Yael, Yaffa, Yagmur, Yahel, Yakira, Yalda, Yaletha, Yamila, Yamuna, Yanamaria, Yandra, Yanika, Yannah, Yannie, Yannina, Yante, Yanthana, Yara, Yareli, Yaren, Yasemin, Yasmeen, Yasmin, Yasmina, Yasmine, Yasna, Yaurelis, Yehudit, Yekatarina, Yella, Yellena, Yentl, Yesenia, Yessica, Yildiz, Yingvild, Ylaina, Ylenia, Yllka, Ylua, Ylva, Ylvi, Yoana, Yohanna, Yoko, Yola, Yolaine, Yolan, Yolanda, Yolande, Yolli, Yosefa, Yosefine, Yoselin, Youna, Yren, Ysabella, Ysraela, Yuki, Yulia, Yuliana, Yuma, Yuna, Yuri, Yvaine, Yvana, Yveline, Yvette, Yvonne, Zaba, Zadie, Zahara, Zahra, Zahraa, Zaida, Zaina, Zakia, Zamira, Zandra, Zanina, Zara, Zarah, Zarifa, Zarina, Zazie, Zäzilie, Zazou, Zdenka, Zedena, Zeena, Zehra, Zeinab, Zelda, Zélenya, Zelia, Zeliha, Zelinda, Zelisa, Zeljka, Zelma, Zénaïde, Zenia, Zenta, Zenzi, Zera, Zereena, Zeynep, Zezilia, Zia, Zilfije, Zilly, Zina, Zinnia, Zisan, Zita, Ziva, Zivana, Zlata, Zoe, Zoé, Zoë, Zoey, Zofia, Zofie, Zohar, Zola, Zora, Zorana, Zorya, Zoya, Zsanett, Zsuzsa, Zuleika, Zumera, Zuri, Zuzana, Zwaantje, Zydrune, Zyndi]

Liste männlicher Vornamen

Quelle: [67]

Liste männliche Namen: [Aaron, Abdul, Abel, Abraham, Achim, Adam, Adolf, Adreon, Adrian, Adriano, Adrien, Aeneas, Ahe, Aheahe, Aidan, Aiden, Aika, Aimo, Akamai, Akamu, Akela, Aki, Akoni, Alain, Alan, Alarich, Albert, Albrecht, Alec, Alessandro, Alessio, Alex, Alexander, Alexej, Alexis, Alfons, Alfred, Ali, Alika, Aljoscha, Allard, Aloha, Alois, Alrik, Alvaro, Alwin, Amadeus, Amandus, Amaranth, Amel, Amelio, Amir, Amiran, Amon, Anais, Anakin, Anders, Andre, André, Andrea, Andreas, Andrej, Andres, Andrew, Andrico, Andrik, Andy, Angus, Anian, Aniani, Anil, Annick, Anno, Ano, Anouck, Anouk, Anselm, Ansgar, Anthony, Antoine, Anton, Antonie, Antonio, Antonios, Antonius, Aolani, Aolaa, Aouli, Aragorn, Aramis, Arendt, Ares, Ari, Arian, Ariel, Arik, Aris, Arlan, Arman, Armand, Armin, Arndt, Arne, Arnit, Arno, Arnold, Aron, Arthur, Artur, Arved, Arvid, Arwed, Asger, Asmus, Athan, Attila, August, Augustin, Aurel, Aurelian, Aurelius, Avino, Axel, Baal, Bahar, Bailong, Baker, Balduin, Balthasar, Banyan, Barack, Barnabas, Barney, Barthold, Bar-

tholomäus, Bashar, Basil, Bastian, Beat, Beatus, Bekim, Bela, Béla, Ben, Benedict, Benedikt, Benicio, Benitio, Benja, Benjamin, Bennet, Bennett, Benno, Benny, Bent, Bente, Beowulf, Beppo, Berend, Berkan, Bernd, Bernhard, Bert, Berthold, Bertie, Bertil, Bertolt, Bilal, Bilge, Bill, Billal, Bing, Birger, Birk, Bjarne, Björn, Blair, Blue, Bo, Bob, Bodo, Bogdan, Bolek, Bone, Bonifatius, Bonito, Bono, Boris, Bosse, Brad, Bradley, Brandolf, Brandon, Brandulf, Branko, Brendan, Brian, Brios, Broder, Bronco, Bruce, Bruno, Brutus, Bryan, Bryson, Burak, Burkhard, Caesar, Caesari-on, Caiside, Caius, Cajus, Caleb, Callisto, Callum, Calvin, Cameron, Camillo, Can, Candid, Carl, Carlo, Carlos, Carmine, Carolus, Carsten, Carter, Casimir, Caspar, Casper, Cassian, Cassim, Cassius, Cay, Cayden, Cebraill, Cecil, Cedar, Cedric, Cedrick, Cedrik, Cem, Cenk, Cerrin, Cesare, Cevin, Ceykob, Chad, Chaim, Chang, Charles, Charley, Charlie, Charly, Chason, Chawai, Chelion, Chester, Chlodomer, Chlodwig, Chris, Christer, Christfried, Christian, Christóbal, Christof, Christofer, Christoph, Christopher, Chrysantos, Chuck, Cicero, Ciel, Cináed, Ciril, Claas, Clarence, Clark, Clas, Claudio, Claudius, Claus, Clemens, Clément, Cliff, Clint, Cody, Colin, Collin, Connor, Conny, Conor, Conrad, Constantin, Corbin, Corbinian, Corin, Cornelius, Cornell, Corvin, Cosmo, Cuno, Curt, Cypress, Cyrus, Daan, Dag, Dagobert, Dagur, Dakotah, Dale, Damaso, Dameon, Damian, Damien, Damir, Damon, Dan, Dana, Dandelion, Dani, Daniel, Danielo, Danilo, Dankmar, Dankwart, Danny, Dante, Dany, Danyel, Darian, Dario, Darius, Dave, David, Davut, Dean, Decio, Degenhard, Deik, Delf, Demokrit, Denir, Denis, Deniz, Dennis, Denny, Denzel, Derek, Desiderius, Desmond, Detlev, Devid, Devin, Devis, Devon, Dexter, Dhiren, Dian, Dick, Diebald, Diego, Dieter, Diethard, Dietmar, Dietrich, Dilan, Dimitri, Dimitrios, Dirk, Dix, Djamal, Django, Dolf, Domenic, Domenico, Domenik, Dominic, Dominik, Dominique, Don, Donar, Dorian, Douglas, Drago, Drake, Dries, Duane, Duke, Duncan, Dustin, Dylan, Ebbo, Eberhard, Ebrahim, Eckard, Ed, Eddie, Eddy, Edgar, Edmont, Edmund, Edoardo, Eduard, Edward, Edwin, Eelke, Efe, Egbert, Eginhardt, Egon, Ehrenfried, Ehrhard, Eike, Eimo, Einar, Ekin, Elex, Elia, Elian, Èlian, Elias, Elijah, Elikolani, Elio, Eliot, Elisa, Elm, Elmar, Elmo, Elton, Elvin, Elvis, Elyas, Emanuel, Emiel, Emil, Emilian, Emilio, Emirhan, Emre, Endrik, Eneas, Engelbert, Enis, Ennio, Enno, Eno, Enrico, Enrik, Enrique, Enzo, Ephraim, Erasmus, Erdal, Eric, Erich, Erik, Erin, Erkan, Ernest, Ernesto, Ernie, Ernst, Erol, Eros, Erwin, Esad, Esben, Esbjörn, Esko, Espen, Esteban, Ethan, Etienne, Eugen, Eugène, Evan, Everett, Evim, Ewald, Ewgenij, Eyck, Ezra, Fabian, Fabien, Fabienne,

Fabijan, Fabio, Fabius, Fabricio, Fadi, Faisal, Falco, Falk, Faolan, Fardin, Fares, Farin, Faris, Farold, Farouk, Fatih, Faustino, Fedder, Fedja, Feivel, Felian, Felias, Felipe, Felix, Fenno, Ferdi, Ferdinand, Fergus, Ferhat, Fernando, Fidel, Fiete, Filibert, Filip, Filippo, Filiz, Filomeno, Fin, Findus, Finjas, Finjus, Finlay, Finn, Finnegan, Finnjan, Finnlay, Finnley, Fionn, Fiorello, Fips, Fjell, Flavio, Flemming, Flint, Florent, Florentin, Florian, Florin, Floris, Flynn, Folkert, Folkmar, Forest, Frana, Francis, Francisco, Franciszek, Franco, Francois, Franjo, Frank, Frans, Franz, Franziskus, Fred, Freddy, Frederic, Frederick, Frederik, Fredrik, Freerk, Frerk, Friderik, Frido, Fridolin, Fridtjof, Friedel, Friedemann, Friedemar, Frieder, Friedhelm, Friedjof, Friedrich, Frieso, Friis, Frisgaard, Frits, Fritz, Fritzzi, Frodo, Fulvian, Furkan, Fynn, Gabor, Gabriel, Gaetano, Gaio, Galahad, Galib, Gandalf, Gandolf, Garret, Gary, Gaspard, Gaston, Gauthier, Gawain, Gebhard, Gebko, Gedeon, Gefion, Gene, Geoffrey, Georg, George, Georgios, Gerald, Gérard, Gerd, Gereon, Gerhard, Gerit, Gernot, Gero, Gerold, Gerome, Gerrit, Gerwald, Géza, Giacomo, Gian, Gianluca, Gibril, Gideon, Giesbert, Gil, Gilbert, Gildo, Gilles, Gino, Giorgio, Giovanni, Gisbert, Giulio, Giuseppe, Glen, Glenn, Goddard, Godehard, Gojko, Gonzales, Göran, Gordian, Gordon, Gottfried, Gotthard, Gottlieb, Götz, Graciano, Graham, Grayson, Gregor, Gregory, Grenander, Griffin, Grischa, Guido, Guillaume, Guillermo, Gunnar, Gunter, Günter, Gunther, Günther, Guntram, Güray, Gustaf, Gustav, Gustave, Gustavo, Guy, Gwydion, Haakon, Hadrian, Hagen, Hajo, Hakan, Hakim, Hakon, Haku, Halvar, Hamid, Hamza, Hanale, Hani, Hanini, Hannes, Hanno, Hans, Harald, Hardi, Hardy, Harper, Harrison, Harro, Harry, Harsh, Hartmut, Hartwig, Harvey, Hasan, Hasso, Hauke, Haulani, Healani, Hedlef, Heiko, Heiner, Heino, Heinrich, Heinz, Hektor, Helge, Helgo, Hellwig, Helmut, Helmuth, Hendric, Hendrik, Henk, Henner, Hennes, Henning, Henri, Henrich, Henricus, Henrik, Henrique, Henry, Hergen, Heribert, Herkules, Hermann, Hermes, Herold, Hieronymus, Hikialani, Hildebrand, Hilko, Hilmar, Hilmer, Hinnerk, Hinrich, Hjalte, Holger, Holm, Holokai, Homer, Honi, Horacio, Hosea, Howard, Hubert, Hubertus, Hugh, Hugo, Humphrey, Hussain, Hyazinth, Iacobus, Iakopa, Iakovo, Ian, Iason, Ibo, Ibrahim, Ido, Idris, Iggy, Ignacio, Ignatius, Ignaz, Igor, Ihmel, Ihno, Ikaia, Ikaika, Ikarus, Ike, Ikenna, Ilan, Ilario, Ilay, Ileas, Ilham, Ilian, Ilias, Ilja, Ilyas, Imilian, Immanuel, Immo, Imran, Imre, Iñaki, Indigo, Ingbert, Ingmar, Ingo, Ingolf, Ingvar, Ingwald, Ingwin, Innocenzo, Ioakim, Ioane, Ioannis, Iokepa, Iokua, Iordanis, Iosif, Ira, Irénée, Ireneus, Irving, Irwin, Isa, Isaak, Isachar, Isaf, Isaiah, Isbert, Isebrand, Isfried, Isgar, Isidor, Ismael, Ismet, Issam, Iu-

piter, Ivan, Ivar, Iven, Ives, Ivo, Iwan, Jacek, Jacob, Jacques, Jaden, Jago, Jakob, Jakobus, Jakub, Jamell, James, Jamie, Jan, Janek, Janik, Janin, Janis, Janko, Jann, Janne, Jannek, Jannes, Janni, Jannic, Jannick, Jannik, Jannis, Jano, Janosch, Janus, Jaque, Jarne, Jarno, Jaro, Jarom, Jaron, Jarred, Jason, Jasper, Jax, Jay, Jean, Jeannetto, Jeffrey, Jeffry, Jeldrik, Jelko, Jendrik, Jens, Jeremias, Jérémie, Jeremo, Jeremy, Jermaine, Jerome, Jerrik, Jesko, Jesper, Jessamine, Jesse, Jessi, Jessie, Jessy, Jim, Jimmy, Jo, Joachim, Joakim, Joas, Jobst, Joe, Joel, Joerge, Joey, Johan, Johann, Johannes, John, Jolando, Jon, Jona, Jonah, Jonas, Jonathan, Jonny, Jooris, Joost, Jöran, Jordan, Jorden, Jördis, Jordon, Jordy, Jörg, Jorge, Jorgen, Joris, Jörn, Jorvik, Jos, Joscha, Joschka, Joschua, José, Josef, Joseph, Joshua, Josiah, Jost, Josua, Jovin, Joyce, Juan, Jule, Jules, Julian, Julien, Julius, Junias, Junis, Jupp, Jürgen, Juri, Justin, Justino, Justus, Jusuf, Kaami, Kaan, Kader, Kahale, Kahekili, Kahiau, Kahikilani, Kahikina, Kahili, Kaholo, Kahoni, Kahua, Kahula, Kai, Kaihologo, Kaikane, Kaiko, Kaili, Kaimana, Kainoa, Kaipo, Kaj, Kajetan, Kajus, Kalama, Kalani, Kale, Kaleb, Kaleho, Kalei, Kaleo, Kaliko, Kalino, Kalle, Kalua, Kamaka, Kamal, Kamalei, Kameron, Kamil, Kamuela, Kan, Kana, Kanani, Kane, Kaniela, Kanoa, Kanuha, Kanye, Kapena, Kapueo, Kapula, Kapuni, Karim, Karl, Karlheinz, Karli, Karol, Karsten, Kasimir, Kaspar, Kasper, Kassian, Kauai, Kaulana, Kawai, Kawekani, Kawelo, Kawena, Kawika, Kawikani, Kay, Kaya, Kazimir, Keahi, Keahilani, Keaka, Keala, Kealamauloa, Kealani, Kealoha, Kealohi, Kealohilani, Keano, Keanu, Keanush, Keao, Keawe, Keiki, Keikilani, Keith, Keke, Keko, Kelar, Kellan, Kelly, Kelvin, Ken, Kenai, Kendrick, Kennedy, Kenneth, Kenny, Keno, Keoki, Keola, Keonaona, Keone, Kepano, Kerim, Kerrin, Kersten, Kester, Ketak, Ketil, Kevin, Keyn, Khaled, Kian, Kieran, Kilian, Killian, Kilohana, Kim, Kimo, Kimon, Kini, Kiran, Kirian, Kirk, Kirsten, Kjeld, Kjell, Klaas, Klaudius, Klaus, Klemens, Knox, Koa, Kolja, Kolya, Konane, Konani, Konny, Konrad, Konradin, Konstantin, Koray, Korbinian, Kornelius, Kosmas, Kosmo, Kostja, Kris, Kristian, Kristof, Kristofer, Kualii, Kuba, Kudret, Kukane, Kulani, Kunal, Kunibert, Kuno, Kurt, Kyrill, Laars, Ladislav, Lahahana, Laith, Lambert, Lambrecht, Lanakila, Lance, Lancelot, Landolf, Laron, Lars, Larus, Lasse, Laurenc, Laurence, Laurens, Laurent, Laurenz, Laurin, Laurits, Lauritz, Laurus, Lavrans, Lean, Leander, Leandro, Leann, Lee, Leialoha, Leif, Len, Lenard, Lenhard, Lenn, Lennard, Lennart, Lennert, Lennon, Lennox, Lenny, Leo, Leolani, Leon, Leonard, Leonardo, Leonce, Leonhard, Leonid, Leonidas, Leopold, Leroy, Leto, Levend, Levent, Levente, Levi, Levian, Levin, Le-

win, Lex, Liam, Lian, Lias, Lienhard, Likeke, Lillemor, Linnaeus, Lino, Linus, Lio, Lion, Lionel, Lior, Loic, Lois, Loke, Loki, Lono, Lopaka, Lorenz, Lorenzo, Loris, Lothar, Lou, Louis, Lovis, Loys, Luan, Luc, Luca, Lucas, Lucian, Luciano, Lucio, Ludger, Ludwig, Lui, Luis, Luitpold, Luka, Lukas, Luke, Lukian, Lutz, Luuk, Ly-sander, Maarten, Madox, Mads, Magnus, Maik, Mailo, Maison, Makaio, Makamae, Makana, Makani, Makanui, Makoa, Maksim, Malek, Maleko, Malin, Malio, Malte, Malthe, Malu, Mando, Manfred, Manolo, Manuel, Marc, Marcel, Marcelas, Marces, Marcin, Marcio, Marcius, Marco, Marcus, Marek, Maria, Marian, Marik, Marin, Marino, Marinus, Mario, Maris, Marius, Mark, Markus, Marlin, Marlo, Marlon, Marten, Martin, Martinik, Marty, Marvin, Marwin, Massimiliano, Massimo, Matej, Matheo, Mathias, Mathis, Matiss, Mats, Matt, Matteo, Mattes, Matthäus, Mattheo, Matthes, Matthew, Matthias, Matti, Mattia, Mattias, Matties, Mattis, Matys, Maui, Maurice, Maurus, Maverick, Max, Maxi, Maxim, Maxime, Maximilian, Maximo, Maximus, Mehdi, Mehmet, Melchior, Melvin, Menowin, Merdan, Merle, Merlin, Mert, Mewes, Mica, Micha, Michael, Michel, Michele, Mick, Miguel, Mika, Mikain, Mikala, Mike, Miki, Mikka, Mikkil, Miklas, Miko, Mikos, Milan, Milian, Milo, Miltiades, Mio, Mirko, Miro, Mischa, Mitch, Mo, Moani, Mohamed, Moje, Momo, Montgomery, Moritz, Moriz, Morris, Morten, Mortimer, Morton, Moses, Mourice, Munir, Murat, Mustafa, Myron, Nael, Nahele, Nahor, Nakoa, Nalu, Namir, Nanook, Nanuk, Naoki, Napoleon, Naseem, Nash, Nasir, Nathan, Nathaniel, Naturo, Neal, Nedim, Neil, Neilos, Nejdet, Nelio, Nelo, Nelson, Nemo, Nemuel, Neo, Nepomuk, Neptun, Nero, Nestor, Neven, Neville, Nevio, Nic, Nicholas, Nick, Nicki, Nicklas, Nickolas, Nicky, Niclas, Nico, Nicodemus, Nicola, Nicolai, Nicolas, Nicolay, Nielas, Niels, Nielson, Nigel, Nihan, Nik, Nikas, Nikhil, Nikita, Nikki, Niklas, Niko, Nikola, Nikolai, Nikolaos, Nikolas, Nikolaus, Nikon, Nilas, Niles, Nillas, Nils, Nimrod, Nino, Nirzad, Nis, Nithard, Niven, Njörd, Noa, Noah, Noam, Noel, Noelani, Nohea, Nojan, Nolan, Norbert, Nordian, Noriaki, Norick, Norik, Norman, Norris, Norwin, Novak, Nuriel, Oakley, Obasi, Oberon, Ocke, Octavian, Odan, Oddo, Oded, Odin, Ohad, Ohlsen, Oke, Okeanos, Oktav, Olaf, Olai, Olav, Olavi, Olcay, Olde, Ole, Oleander, Oleg, Olek, Olf, Olias, Oliver, Olof, Olrik, Omar, Omer, Ondrej, Onno, Onophrios, Onorato, Ontje, Onur, Ophelius, Orazio, Orell, Oren, Orfeas, Orhan, Orion, Orkan, Orlando, Orman, Orpheus, Orry, Orson, Ortwald, Ortwin, Osama, Oscar, Osiris, Oskar, Osman, Oswald, Oswin, Otfried, Othello, Othniel, Otis, Otfried, Ottmar, Otto, Ottokar, Ove, Owen, Özden, Paavo, Pablo, Pace, Paco, Paddy, Pako, Pamir, Pan, Pancrazio,

Paolo, Pär, Paris, Parker, Parsifal, Parzival, Pascal, Patrice, Patrick, Patrik, Pauahi, Paul, Paulo, Paulus, Pawel, Pedja, Pedro, Peer, Peet, Pejo, Pekka, Pelle, Peni, Pepe, Peppino, Peppone, Per, Percival, Percy, Peregrin, Pero, Perry, Perseus, Pervin, Petar, Peter, Petrus, Peyman, Pharrell, Phil, Phileas, Philibert, Philip, Philipp, Phillip, Phillipp, Phillipus, Philo, Philomeno, Phoenix, Phuc, Pier, Pierce, Pierre, Piet, Pieter, Pietro, Pika, Pino, Piotr, Pippin, Pit, Pitt, Pius, Placido, Pluto, Poseidon, Pusat, Puya, Pyrros, Qadim, Qamil, Qani, Qassem, Qayin, Qazim, Qemal, Qenco, Qendrim, Qendron, Qerim, Qerkin, Qeynan, Quintavius, Qodrat, Quiriakus, Quaashie, Quablan, Quadarius, Quade, Quagmire, Quaid, Quain, Quaiss, Quan, Quanah, Quang, Quanmain, Quannah, Quarto, Quashawn, Quasimodo, Quazim, Quelan, Quentin, Quentino, Quigley, Quill, Quillan, Quim, Quince, Quincy, Quinnell, Quinlan, Quinn, Quino, Quint, Quinten, Quintino, Quinto, Quinton, Quintrell, Quintus, Quique, Quirin, Quirino, Quirinus, Quisito, Quoc, Quon, Quirinus, Quyen, Qwara, Qyshawn, Ra, Raban, Radek, Radimir, Radoslav, Radulf, Rafael, Rafe, Raffael, Ragnar, Raidon, Raif, Raik, Raimo, Raimon, Raimund, Rainald, Rainer, Rainier, Ralf, Ralph, Raman, Ramin, Ramirus, Ramon, Randolph, Raoul, Raphael, Rashid, Rasmus, Rasputin, Raven, Ravi, Ravin, Rayk, Reece, Reed, Reein, Reik, Reinhold, Rembrandt, Rémi, Remo, Remus, Remy, Ren, Renard, Rene, René, Renée, Renzo, Resa, Retho, Reuben, Ricardo, Riccardo, Richard, Rick, Rickmer, Rico, Ridley, Riley, Ringo, Roald, Rob, Robbie, Robbin, Robert, Roberto, Robin, Rocco, Rochus, Rocky, Rod, Roderich, Roderick, Rodney, Rodrigo, Rodriguez, Roger, Roland, Romain, Roman, Romeo, Rometh, Romuald, Romualdo, Romulus, Romy, Ron, Ronan, Ronas, Ronny, Ross, Rouven, Roy, Ruben, Rudi, Rüdiger, Rudolf, Rudy, Rufus, Ruitong, Rune, Rupert, Ruprecht, Russell, Ruven, Ruwen, Ryan, Ryker, Saffron, Sagara, Sage, Said, Salim, Salomo, Salomon, Salvador, Salvatore, Sam, Sami, Samir, Sammy, Samson, Samu, Samuel, Samy, Sandrin, Sandro, Sandy, Sanja, Santiago, Santino, Santo, Sarankan, Sascha, Saturn, Saulus, Savin, Scott, Sean, Sebald, Sebastian, Sébastien, Selasi, Selin, Semias, Semjon, Semon, Seppe, Serge, Sergej, Sergius, Serhat, Severin, Shaun, Shayan, Sheldon, Sherlock, Sibo, Sidney, Siegfried, Siegmar, Siegmund, Sigurd, Silas, Silvan, Silvester, Silvio, Simeon, Simon, Sinan, Sirius, Sirko, Siva, Sky, Skye, Slobodan, Snorre, Sofus, Söhnke, Sönke, Soran, Sören, Sorin, Sorrel, Spencer, Stachus, Stacy, Staffan, Stan, Stanislaw, Stanley, Steen, Stefan, Stefano, Steffen, Sten, Stephan, Steven, Stuart, Sulayman, Sullivan, Svante, Sven, Svend, Sverre, Sydney, Taako, Taavi, Taddäus, Tade, Tadeo, Tade-

us, Talha, Tamaro, Tamas, Tamino, Tamme, Tammo, Tamo, Tanner, Tarek, Tarius, Tassilo, Tasso, Tattius, Täve, Tayler, Tazio, Ted, Telamon, Terence, Teresio, Tetsno, Thaddäus, Thade, Thankmar, Thees, Theis, Theo, Theobald, Theodor, Theophil, Thibault, Thiemo, Thies, Thietmar, Thilo, Thimo, Thimon, Thomas, Thor, Thoralf, Thorben, Thore, Thorin, Thorsten, Thure, Tiago, Tiberius, Tibo, Tiemon, Tijl, Tijs, Til, Till, Tillmann, Tilman, Tilo, Tim, Timan, Timm, Timo, Timofej, Timon, Timotheus, Timothy, Timur, Tino, Titian, Titus, Titzian, Tizian, Tjaard, Tjalf, Tjarden, Tjark, Tjorven, Tobias, Tobin, Todd, Toge, Tolga, Tom, Tomas, Tomek, Tomke, Tommy, Tomo, Toni, Tonio, Tony, Torak, Toralf, Torben, Torge, Torin, Torje, Torwald, Toto, Trautmar, Trevor, Tristan, Trond, Tua, Ture, Tycho, Tyler, Ubald, Ubbe, Ubbo, Ubert, Ubeyd, Udai, Udalbert, Uday, Uden, Udo, Udomar, Uffe, Ugnius, Ugo, Ugur, Uhuru, Uilliam, Ukko, Uladislau, Uland, Ulbert, Ulf, Ulfilas, Ulfred, Ulfried, Ulli, Ullrich, Ulmer, Ulrich, Ulukaan, Uluwehi, Ulwig, Ulysses, Umair, Umar, Umberto, Umer, Umi, Ummo, Umran, Umut, Unathi, Uno, Untamo, Unwin, Uodalrich, Uranus, Uraz, Urbain, Urban, Uriah, Urijah, Urim, Urmas, Urs, Ursin, Urvil, Usain, Usama, Usef, Usman, Uthelm, Uther, Uthman, Utz, Uwe, Uz, Uzay, Uziah, Uzziel, Vaclav, Vadim, Vaid, Vaijk, Valdemar, Vale, Valence, Valentiano, Valentin, Valentino, Valerian, Vali, Valmont, Valter, Vance, Vangelis, Vanja, Vanya, Varun, Varus, Vasco, Vasili, Vasya, Vaughn, Veikko, Veit, Veith, Veland, Velasco, Veli, Veljko, Venanzio, Venko, Vergil, Verner, Vernon, Vero, Viano, Vicente, Vico, Victor, Vidal, Vidar, Viggo, Vijay, Viktor, Vilfredo, Vilhelm, Vilius, Vilson, Vinc, Vince, Vincent, Vinzent, Vishna, Vitali, Vitezslav, Vito, Vitomir, Vitus, Vivaldo, Vivek, Vivian, Vladimir, Vladislav, Vojislav, Volkan, Volker, Volkmar, Volodya, Waast, Waclaw, Wadim, Wahid, Waldemar, Waldo, Waldomir, Walentin, Waleri, Walid, Walker, Wallace, Walt, Walter, Walther, Wanja, Wapacha, Warren, Warrick, Wasim, Wassili, Wataru, Watson, Wayne, Weert, Weerth, Wehrhart, Weiland, Welmer, Wendelin, Wenko, Wenzel, Werner, Wesley, Wichert, Wido, Widolf, Widukind, Wiebe, Wieland, Wigand, Wigbald, Wigbert, Wiggo, Wikko, Wiktor, Wilbert, Wilbur, Wilfried, Wilhelm, Wiliam, Wilke, Wilko, Willem, Willi, William, Willibald, Willrich, Willy, Wilm, Wilmar, Wilsson, Wim, Winfried, Wini, Winston, Wiprecht, Wito, Wittich, Wladimir, Wojtek, Wolf, Wolfgang, Wolfram, Wolodja, Woodrow, Woody, Wotan, Wulf, Wulmar, Wyatt, Xabat, Xabi, Xabian, Xachary, Xackery, Xade, Xadrian, Xael, Xaiver, Xamir, Xancho, Xander, Xandor, Xanjo, Xanthos, Xantus, Xari, Xav, Xaver, Xavi, Xavian, Xavier, Xavior, Xayden, Xayvion, Xemerius,

Xeno, Xenon, Xenophilus, Xenophon, Xenos, Xerik, Xero, Xerxes, Xeth, Xhabir, Xhaiden, Xhavit, Xhelal, Xhemail, Xherdan, Xhevat, Xhevdet, Xhoi, Xhulijan, Xiang, Xiao, Xilas, Ximeno, Ximon, Xinxin, Xiomar, Xitali, Xizir, Xoaquin, Xoey, Xola, Xolani, Xort, Xosé, Xu, Xuan, Xylas, Xyler, Xylon, Xyrell, Xyrome, Xystus, Xzavien, Yaadon, Yadid, Yadier, Yadigar, Yadriel, Yael, Yago, Yaiden, Yakup, Yale, Yamato, Yamir, Yandel, Yandric, Yang, Yanick, Yaniel, Yanik, Yann, Yannek, Yannes, Yanni, Yannic, Yannick, Yannie, Yannik, Yannis, Yanuel, Yaqoub, Yarden, Yared, Yaron, Yaroslav, Yarrow, Yasin, Yasir, Yasser, Yazan, Yeagar, Yehudi, Yel, Yem, Jeremiah, Yeshua, Yevgeni, Yiannis, Yilmaz, Yorgos, Yitzhak, Yoan, Yohann, Yonas, Yonatan, Yonathan, Yorick, York, Yorrik, Yoshi, Yoshua, Yosiah, Younes, Youri, Yovani, Ysidro, Yuan, Yuhki, Yuki, Yule, Yunis, Yunus, Yuri, Yussuf, Yuval, Yuvan, Yven, Yves, Yvor, Zaan, Zac, Zacharias, Zachary, Zafar, Zafer, Zahid, Zahur, Zaid, Zaine, Zaire, Zakai, Zamari, Zamir, Zammert, Zander, Zandro, Zarek, Zarik, Zaven, Zavian, Zayden, Zaylen, Zaylon, Zayn, Zayvier, Zbigniew, Zdenko, Zeb, Zebadiah, Zederik, Zedric, Zedrik, Zekiel, Zelindo, Zenas, Zeno, Zenon, Zepellin, Zeph, Zephanja, Zephyr, Zerres, Zeus, Zhenya, Zia, Ziad, Ziam, Zidane, Ziggy, Zigismund, Zinedine, Zion, Ziryan, Zisan, Zitomir, Zlatan, Zlatko, Zoel, Zohaib, Zohan, Zoltan, Zoran, Zorro, Zsolt, Zygmund, Zygmunt, Zylar, Zylvanio, Zyriak]

Liste genderneutrale Vornamen

Erstellt aus Einträgen von aus den beiden Vornamenslisten Liste weiblicher Vornamen und Liste männlicher Vornamen.

List der genderneutralen Vornamen: [Akela, Alex, Alexis, Aloha, Andrea, Anouk, Ariel, Benja, Bente, Blair, Blue, Bo, Charlie, Chris, Conny, Dani, Dany, Dominique, Dona, Dori, Dylan, Eike, Elia, Elis, Erin, Finn, Florin, Friis, Gerrit, Hanne, Healani, Ira, Isa, Jade, Jamie, Janis, Janne, Jean, Jesse, Jessi, Jessie, Jordan, Jules, Juli, Kahula, Kaiko, Kainoa, Kaipo, Kaj, Kalama, Kalani, Kalua, Kamaka, Kamalei, Kanoa, Kaulana, Kawai, Kawelo, Kay, Kaya, Keaka, Keao, Keawe, Keke, Keko, Kelly, Keola, Kersten, Kim, Kini, Kirsten, Konny, Kris, Lanakila, Lee, Lois, Lou, Lovis, Luca, Luka, Lys, Makamae, Makana, Makanui, Marian, Marlin, Maxi, Maxime, Merle, Michele, Mika, Momo, Nicki, Nicky, Nicola, Nika, Nikita, Nikki, Nikola, Noah, Nohea, Nova, Patrice, Pauahi, Qi, Quanna, Quinn, Remy, Renee, Robin, Sam, Sandy, Sanja, Sascha, Sidney, Silva, Stacy, Tela, Tjorven, Tomke, Toni, Ude, Ulli, Vivian, Wanja, Xi, Xin, Yael, Yuki, Yuri, Zia, Zisan]

Doch Gender Bedeutung im Deutschen:

Liste weiblicher Namen : [Ada, Aida, Alessa, Alexa, Alla, Alva, Amira, Ana, Ann, Antonie, Aurelia, Bea, Brenda, Cami, Caro, Cassia, Dana, Daria, Devi, Emilia, Eva, Eve, Evi, Fabia, Fabienne, Filiz, Finja, Finnja, Floria, Friede, Fritzi, Geri, Gill, Hanna, Hilde, Imilia, Io, Irene, Iva, Jane, Jeanne, Jessy, Jola, Josi, Joy, Jule, Julie, Kaimana, Karli, Kea, Keona, Kira, Kiri, Kora, Lauren, Lea, Leia, Lena, Leona, Leoni, Lia, Lil, Linn, Lua, Lucia, Mali, Malu, Maria, Mila, Noa, Noelani, Nola, Norma, Octavia, Oda, Olive, Orla, Osma, Pam, Pippi, Ragna, Rena, Resa, Rica, Romy, Sara, Sila, Sina, Siri, Thora, Tia, Tizia, Tora, Uma, Una, Valeria, Vida, Wilma, Xavia, Xia, Xuan, Yannie, Zlata, Zoe, Zora]

Liste männlicher Vornamen : [Adrian, Andy, Callisto, Corin, Etienne, Frana, Gabriel, Glenn, Gustave, Harper, Hauke, Ike, Jona, Jonah, Juri, Kai, Lean, Lenny, Leo, Lucian, Makani, Manuel, Marin, Nalu, Noel, Ola, Quoc, Thore, Tobia,]

Quelle für die Einschätzung des Genders:

Akela weibl. <https://www.firstname.de/Vorname/Akela/> [25]

Aloha weibl. <https://vornamen.blog/Aloha> [71]

Dona weibl. <https://www.baby-vornamen.de/Maedchen/D/Do/Dona/> [6]

Dori weibl. <https://www.baby-vornamen.de/Maedchen/D/Do/Dori/> [6]

Elia unisex <https://www.baby-vornamen.de/Jungen/E/El/Elia/> [6]

Friis männl. <https://www.baby-vornamen.de/Jungen/F/Fr/Friis/> [6]

Hanne weibl. <https://www.baby-vornamen.de/Maedchen/H/Ha/Hanne/> [6]

Healani unisex <https://babynamemeaningz.com/Healani-meaning-11511> [9]

Kahula unisex <https://babynames.com/name/kahula> [8]

Kainoa männl. <http://www.leonie.io/at/vornamen/Kainoa> [3]

Kaipo unisex <https://charlies-names.com/de/kaipo/>

Kalama unisex <https://www.babycenter.de/babynome/29351/kalama> [7]

Kalua unisex <https://www.hawaiiurlaub.de/hawaiianische-namen-babynamen/> [33]

Kamaka unisex <https://www.thenamemeaning.com/kamaka/> [10]

Kamalei unisex <https://www.babycenter.de/babynome/29425/kamalei> [7]

Kanoa männl. <https://www.baby-vornamen.de/Jungen/K/Ka/Kanoa/#:~:text=>

Kanoa%20ist%20in%20Deutschland%20ein,Jahr%202015%20mit%20Platz%20207. [6]

Kaulana unisex <https://babynames.com/name/kaulana> [4]

Kawai männl. <http://www.leonie.io/de/vornamen/Kawai> [3]

alle anderen: www.vorname.at [70]

Anhang C: Listings

Modifizierter Permutation Test zu vergleichen, der Hyperparameter

```
def permutationTest(testgrupp , controllgrupp , iter):  
    ulist = testgrupp + controllgrupp  
  
    test_value = statistics.mean(testgrupp)  
                - statistics.mean(controllgrupp)  
  
    count = 0  
    for t in range(iter):  
        plist = (random_permutation(ulist , len(ulist)))  
        x = plist [len(testgrupp):]  
        y = plist [:len(controllgrupp)]  
        if statistics.mean(x) - statistics.mean(y)  
        > test_value:  
            count = count + 1  
  
    return count/iter
```

Listing 4: Modifizierter Permutation Test für den Hyperparameter-Vergleich

Anhang D: Gesetzestext für Gutachterkommission

§ 9. (1) Das zu beschließende Gutachten hat 1. die Feststellung hinsichtlich der Erfüllung der Erfordernisse gemäß § 14 Abs. 2 des Schulunterrichtsgesetzes zu enthalten, insbesondere hinsichtlich a) der Übereinstimmung mit der vom Lehrplan vorgeschriebenen Bildungs- und Lehraufgabe sowie den didaktischen Zielsetzungen und den wesentlichen Inhalten des Lehrstoffes,

b) der Berücksichtigung des Grundsatzes der Selbsttätigkeit des Schülers und der aktiven Teilnahme des Schülers am Unterricht, c) der Berücksichtigung des Grundsatzes der Anpassung des Schwierigkeitsgrades an das Auffassungsvermögen des Schülers (Schüleradäquatheit des Unterrichtsmittels in bezug auf Aufnahmekapazität, Alter, Interessen, Bedürfnisse und Möglichkeiten der Schüler), d) der sachlichen Richtigkeit des Inhaltes und seiner Übereinstimmung mit dem jeweiligen Stand des betreffenden Wissensgebietes, unter Berücksichtigung der den Sachbereich berührenden Normen im Sinne des Normengesetzes, BGBl. Nr. 240/1971, und der sonstigen technischen Vorschriften, e) der ausreichenden Berücksichtigung der Lebenswelt der Schüler sowie ihrer zukünftigen Arbeitswelt einschließlich der spezifischen österreichischen und europäischen Verhältnisse, f) der staatsbürgerlichen Erziehung der Schüler, der Vermittlung demokratischer Einstellungen sowie der geltenden Rechtsvorschriften und der Anleitung zu selbsttätigem Handeln der Schüler, g) der sprachlichen Gestaltung und der guten Lesbarkeit (unter Einschluß der didaktischen Elemente der optischen Darstellung), h) der Zweckmäßigkeit vom Standpunkt des Materials, der Darstellung und der sonstigen Ausstattung und i) der Gleichbehandlung von Frauen und Männern und der Erziehung zur partnerschaftlichen Gestaltung der gesellschaftlichen Entwicklungen sowie 2. die Beurteilung zu enthalten, ob das Unterrichtsmittel a) in der vorliegenden Fassung geeignet oder b) unter der Auflage von Änderungen geeignet oder c) nicht geeignet erscheint. (2) In dem Gutachten ist die Schulart, allenfalls die Schulform bzw. die Fachrichtung und die Schulstufe (Klasse, Jahrgang), soweit es sich nicht um Berufsschulen handelt, sowie der Unterrichtsgegenstand, für den das Unterrichtsmittel geeignet

erscheint, zu bezeichnen. Im Falle des Abs. 1 Z 2 lit. b ist Art und Ausmaß der erforderlichen Änderungen aufzunehmen. Ferner ist bei Schulbüchern auszusprechen, ob das Werk als Teil der Grundausrüstung (Arbeitsbuch, Lesebuch, Sprachbuch, Liederbuch, Wörterbuch, Atlas, mathematisches Tabellenwerk) geeignet erscheint. [58]